

## LAB 01 | المختبر 01

# Neural Network Training

تدريب شبكة عصبية من الحل الابتدائي حتى التقارب

Forward Propagation, Backpropagation, Weight Update, and Convergence

الانتشار الأمامي والانتشار الخلفي وتحديث الأوزان والوصول إلى التقارب

Prepared by | إعداد: Dr.-Ing. Aouss Gabash

## Lab Objectives


- Implement a small neural network in MATLAB.
- Calculate forward propagation and loss.
- Implement analytical backpropagation.
- Update weights using gradient descent.
- Stop training when the error becomes smaller than  $\epsilon$ .

## أهداف المختبر

- تنفيذ شبكة عصبية صغيرة باستخدام MATLAB.
- حساب الانتشار الأمامي ودالة الخطأ.
- تنفيذ الانتشار الخلفي تحليليًا.
- تحديث الأوزان باستخدام الانحدار المتدرج.
- إيقاف التدريب عندما يصبح الخطأ أصغر من  $\epsilon$ .

## 1. Network Structure

1 Input  $\rightarrow$  2 Hidden Neurons  $\rightarrow$  1 Output



## 1. بنية الشبكة

1 → 2 → 1

دخول واحد، عصبونان مخفيان، وخرج واحد.

## 2. Activation Function

$$\sigma(z) = 1/(1 + e^{-z})$$

$$\sigma'(z) = \sigma(z)[1 - \sigma(z)]$$

## 2. دالة التنشيط

$$\sigma(z) = 1/(1 + e^{-z})$$

$$\sigma'(z) = \sigma(z)[1 - \sigma(z)]$$

### 3. MATLAB Sigmoid Function

```
sigma = @(z) 1 ./ (1 + exp(-z));
```

### 3. دالة Sigmoid في MATLAB

يحسب هذا السطر قيمة Sigmoid لأي قيمة  $z$ .

### 4. Initial Parameters

```
W.w1 = 0.4; W.w2 = -0.3;  
W.v1 = 0.2; W.v2 = 0.5;  
W.b1 = 0.1; W.b2 = -0.1; W.b3 = 0.0;
```

These are initial values; training will modify them.

### 4. القيم الابتدائية

تبدأ الشبكة بأوزان وانزياحات أولية ثم تعدلها أثناء التدريب.

### 5. Training Sample

```
x = 1;  
t = 0.8;
```

$x = input, t = desired target$

## 5. عينة التدريب

x هو الدخل و t هي القيمة المطلوبة.

## 6. Forward Propagation

$$z_1 = w_1x + b_1, h_1 = \sigma(z_1)$$

$$z_2 = w_2x + b_2, h_2 = \sigma(z_2)$$

$$z_3 = v_1h_1 + v_2h_2 + b_3, y = \sigma(z_3)$$

## 6. الانتشار الأمامي

يتم حساب خرج العصبونين المخفيين ثم استخدامهما لحساب خرج الشبكة النهائي.

## 7. MATLAB Forward Propagation

```
z1 = W.w1*x + W.b1; h1 = sigma(z1);  
z2 = W.w2*x + W.b2; h2 = sigma(z2);  
z3 = W.v1*h1 + W.v2*h2 + W.b3;  
y = sigma(z3);
```

## 7. الانتشار الأمامي في MATLAB

تنفذ هذه الأسطر المعادلات السابقة مباشرة.

### 8. Loss Function

$$E = 1/2(y - t)^2$$

$$E = 0.5*(y - t)^2;$$

### 8. دالة الخطأ

كلما اقترب  $y$  من  $t$  انخفضت  $E$ .

### 9. Output Error

$$\delta_3 = (y - t)y(1 - y)$$

$$d0 = (y - t) * y * (1 - y);$$

$dO$  represents  $\partial E / \partial z_3$ .

## 9. خطأ طبقة الخرج

تمثل dO تأثير دخل عصبون الخرج على الخطأ النهائي.

## 10. Output-Layer Gradients

$$\partial E / \partial v_1 = \delta_3 h_1, \partial E / \partial v_2 = \delta_3 h_2, \partial E / \partial b_3 = \delta_3$$

$$dV1 = dO * h_1; \quad dV2 = dO * h_2; \quad dB3 = dO;$$

## 10. تدرجات طبقة الخرج

نحسب تأثير كل وزن وانزياح في طبقة الخرج على دالة الخطأ.

## 11. Hidden-Layer Error

$$\delta_1 = \delta_3 v_1 h_1 (1 - h_1), \delta_2 = \delta_3 v_2 h_2 (1 - h_2)$$

$$d1 = dO * W.v1 * h1 * (1 - h1);$$

$$d2 = dO * W.v2 * h2 * (1 - h2);$$

## 11. خطأ الطبقة المخفية

ينتقل تأثير الخطأ من الخرج إلى العصبونات المخفية عبر الأوزان  $V_1$  و  $V_2$ .

## 12. Input-to-Hidden Gradients

$$\partial E / \partial w_1 = \delta_1 x, \partial E / \partial w_2 = \delta_2 x$$

```

dW1 = d1*x;  dB1 = d1;
dW2 = d2*x;  dB2 = d2;

```

## 12. تدرجات الأوزان الأولى

نحصل على مشتقات الخطأ بالنسبة للأوزان والانزياحات بين الدخل والطبقة المخفية.

## 13. Gradient Descent Update

$$w(new) = w(old) - \eta \partial E / \partial w$$

```

W.w1 = W.w1 - eta*dW1;  W.w2 = W.w2 - eta*dW2;
W.v1 = W.v1 - eta*dV1;  W.v2 = W.v2 - eta*dV2;
W.b1 = W.b1 - eta*dB1;  W.b2 = W.b2 - eta*dB2;
W.b3 = W.b3 - eta*dB3;

```

## 13. تحديث الأوزان

يتم تحديث كل معامل بعكس اتجاه التدرج لتقليل الخطأ.

## 14. Learning Rate

```
eta = 0.5;
```

### $\eta$ too small

Training becomes slow.

### $\eta$ too large

Training may oscillate or diverge.

## 14. معدل التعلم

القيمة الصغيرة جدًا تبطئ التدريب، والكبيرة جدًا قد تجعل التدريب غير مستقر.

## 15. Stopping Criterion

```
epsilon = 1e-6;  
maxEpochs = 10000;
```

*Stop when  $E < \varepsilon$*



## 15. معيار التوقف

يتوقف التدريب عندما يصبح الخطأ أصغر من  $\epsilon$  أو يصل إلى الحد الأقصى للدورات.

## 16. Complete MATLAB Program

```

clear; clc; close all;
sigma = @(z) 1 ./ (1 + exp(-z));
x = 1; t = 0.8;
eta = 0.5; epsilon = 1e-6; maxEpochs = 10000;
W.w1 = 0.4; W.w2 = -0.3;
W.v1 = 0.2; W.v2 = 0.5;
W.b1 = 0.1; W.b2 = -0.1; W.b3 = 0.0;
lossHist = zeros(1,maxEpochs);
epoch = 0; converged = false;

while ~converged && epoch < maxEpochs
    epoch = epoch + 1;
    z1 = W.w1*x + W.b1; h1 = sigma(z1);
    z2 = W.w2*x + W.b2; h2 = sigma(z2);
    z3 = W.v1*h1 + W.v2*h2 + W.b3; y = sigma(z3);
    E = 0.5*(y - t)^2; lossHist(epoch) = E;
    d0 = (y - t) * y * (1 - y);
    dV1 = d0*h1; dV2 = d0*h2; dB3 = d0;
    d1 = d0*W.v1*h1*(1-h1);
    d2 = d0*W.v2*h2*(1-h2);
    dW1 = d1*x; dB1 = d1;
    dW2 = d2*x; dB2 = d2;
    W.w1 = W.w1 - eta*dW1; W.w2 = W.w2 - eta*dW2;
    W.v1 = W.v1 - eta*dV1; W.v2 = W.v2 - eta*dV2;
    W.b1 = W.b1 - eta*dB1; W.b2 = W.b2 - eta*dB2;
    W.b3 = W.b3 - eta*dB3;
    converged = E < epsilon;
end


disp(W)
fprintf('Epochs = %d\n',epoch)
fprintf('Final output y = %.6f\n',y)
fprintf('Target t = %.6f\n',t)
fprintf('Final error E = %.10f\n',E)
figure
semilogy(1:epoch,lossHist(1:epoch),'LineWidth',1.6)
grid on
xlabel('Epoch'); ylabel('Loss E')
title('Neural Network Training Convergence')

```

## 16. البرنامج الكامل في MATLAB

يجمع البرنامج الانتشار الأمامي وحساب الخطأ والانتشار الخلفي وتحديث الأوزان وفحص التقارب ضمن حلقة تدريب واحدة.

## 17. Training Loop



## 17. حلقة التدريب

الأوزان الابتدائية ← الانتشار الأمامي ← الخطأ ← الانتشار الخلفي ← التحديث ← التكرار

## 18. Convergence Plot

```
semilogy(1:epoch, lossHist(1:epoch), 'LineWidth', 1.6)
```

A descending curve indicates that the network is learning.

## 18. منحنى التقارب

يظهر المقياس اللوغاريتمي انخفاض الخطأ عبر عدة مراتب عشرية بوضوح.

## 19. Experiment 1 — Learning Rate

```
eta = 0.05;
eta = 0.5;
eta = 2.0;
```

Compare epochs, stability, and final loss.

## 19. التجربة 1 — معدل التعلم

غير  $\eta$  وقارن سرعة التقارب والاستقرار والخطأ النهائي.

## 20. Experiment 2 — Initial Weights

$W.w1$

$W.w2$

$W.v1$

$W.v2$

Different initial conditions may produce different training paths.

## 20. التجربة 2 — الأوزان الابتدائية

غير القيم الابتدائية ولاحظ تأثيرها على مسار التدريب وعدد الدورات.

## 21. Power-System Interpretation

$x = PreviousLoad, t = FutureLoad$

$x = [Load, Temperature, Time, PVPower, ...]$

The mathematics of backpropagation remains the same.

## 21. التفسير في نظم الطاقة

يمكن استخدام آلية التدريب نفسها للتنبؤ بالحمل أو الطاقة المتجددة أو تقدير حالات التشغيل.

## 22. Lab Tasks

1. Run the original program.
2. Record final output and epochs.
3. Change the learning rate.
4. Change the initial weights.
5. Change the target  $t$ .
6. Explain every gradient expression.
7. Explain why the loss decreases.

## 22. مهام المختبر

1. شغل البرنامج.
2. سجل الخرج وعدد الدورات.
3. غير معدل التعلم.
4. غير الأوزان الابتدائية.
5. غير  $t$ .
6. اشرح معادلات التدرج.
7. اشرح سبب انخفاض الخطأ.



## Questions

1. What does  $dO$  represent?
2. Why does  $dO$  contain  $y(1-y)$ ?
3. Why is  $dV1 = dO * h1$ ?
4. Why does the hidden error contain  $W.v1$ ?
5. Why do we subtract the gradient?
6. What happens if  $\eta$  is too large?
7. What is the role of  $\epsilon$ ?

## أسئلة المختبر

1. ماذا تمثل  $dO$  ؟
2. لماذا تحتوي على  $y(1-y)$  ؟
3. لماذا  $dV1=dO*h1$  ؟
4. لماذا يحتوي خطأ الطبقة المخفية على  $W.v1$  ؟
5. لماذا نطرح التدرج ؟
6. ماذا يحدث إذا كانت  $\eta$  كبيرة ؟
7. ما وظيفة  $\epsilon$  ؟

# References | المراجع

المراجع العامة المستخدمة في هذا المقرر

[1] A. Gabash, *Flexible Optimal Operations of Energy Supply Networks with Renewable Energy Generation and Battery Storage*. Saarbrücken, Germany: Südwestdeutscher Verlag für Hochschulschriften, 2014.

[2] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th Global ed. Harlow, U.K.: Pearson Education Limited, 2022.

[3] A. Gabash, "Energy Market Transition and Climate Change: A Review of TSOs-DSOs C++ Framework from 1800 to Present," *Energies*, vol. 16, no. 17, Art. no. 6139, 2023, doi: 10.3390/en16176139.

[4] A. Gabash, *AI Applications in Electrical Power Systems*, Version 1.0, 2026. [Online]. Available: <https://aoussgabash.com>

# Publication Information | معلومات النشر

|                  |                                                               |
|------------------|---------------------------------------------------------------|
| Document         | Laboratory 01 · Neural Network Training                       |
| Course           | AI Applications in Electrical Power Systems                   |
| Author           | Dr.-Ing. Aouss Gabash                                         |
| Version          | 1.0                                                           |
| Publication year | 2026                                                          |
| Official website | <a href="https://aoussgabash.com">https://aoussgabash.com</a> |
| Citation style   | IEEE                                                          |

**Recommended citation:**

Gabash, A. (2026). Neural Network Training. AI Applications in Electrical Power Systems, Laboratory 01, Version 1.0. <https://aoussgabash.com>

---

المرجع المقترح:

أوس غباش، 2026، مخبر 01، تطبيقات الذكاء الاصطناعي في أنظمة الطاقة الكهربائية، الإصدار 1.0، <https://aoussgabash.com>

---

© 2026 Dr.-Ing. Aouss Gabash. Educational use with attribution to the author and official website.