

## LAB 03 | المختبر 03

# Machine Learning Load Forecasting

التنبؤ بالحمل الكهربائي باستخدام التعلم الآلي

Linear Regression, Training, Prediction, and Error Evaluation

الانحدار الخطي والتدريب والتنبؤ وتقييم الخطأ

Prepared by | إعداد | Dr.-Ing. Aouss Gabash

## Lab Objectives

- Understand load forecasting as supervised learning.
- Construct a simple load dataset.
- Estimate linear-regression parameters in MATLAB.
- Predict load from temperature.
- Calculate MAE, MSE, and RMSE.
- Visualize actual and predicted load.

## أهداف المختبر

- فهم التنبؤ بالحمل كمسألة تعلم خاضع للإشراف.
- إنشاء مجموعة بيانات بسيطة.
- تقدير معاملات الانحدار الخطي في MATLAB.
- التنبؤ بالحمل اعتماداً على درجة الحرارة.
- حساب MAE و MSE و RMSE.
- رسم الحمل الحقيقي والمتنبأ به.

## 1. Load-Forecasting Problem

$$FutureLoad = f(HistoricalData, Weather, Time, ...)$$

In this introductory example, temperature is the only input.

Temperature  $\rightarrow$  Electrical Load

## 1. مسألة التنبؤ بالحمل

يهدف التنبؤ بالحمل إلى تقدير الطلب المستقبلي اعتمادًا على البيانات التاريخية والعوامل المؤثرة.

بيئ ابرهكلال محل ا  $\rightarrow$  قرار حل اة جرد

## 2. Supervised Learning

$x \rightarrow t$

$x = Temperature[^{\circ}C], t = ElectricalLoad[MW]$

The model learns the input-output relationship from labeled examples.

## 2. التعلم الخاضع للإشراف

لكل عينة تدريب نعرف قيمة الدخل والقيمة الصحيحة المطلوبة.

بيئ ابرهكلال محل ا  $\rightarrow$  قرار حل اة جرد

### 3. Example Dataset

| Sample | Temperature [°C] | Load [MW] |
|--------|------------------|-----------|
| 1      | 10               | 105       |
| 2      | 12               | 110       |
| 3      | 14               | 116       |
| 4      | 16               | 121       |
| 5      | 18               | 128       |
| 6      | 20               | 134       |
| 7      | 22               | 141       |
| 8      | 24               | 147       |
| 9      | 26               | 154       |
| 10     | 28               | 162       |

### 3. مجموعة البيانات

تمثل كل عينة درجة حرارة مقاسة والحمل المقابل لها.

هذه بيانات تعليمية مبسطة وليست بيانات شبكة حقيقية.

### 4. Enter the Data in MATLAB

```
temperature = [10 12 14 16 18 20 22 24 26 28]';  
loadMW = [105 110 116 121 128 134 141 147 154 162]';
```

## 4. إدخال البيانات إلى MATLAB

يحوّل رمز الفاصلة العليا المتجهات إلى متجهات عمودية.

## 5. Linear Regression Model

$$\hat{y} = \beta_0 + \beta_1 x$$

- $\beta_0$ : intercept
- $\beta_1$ : slope
- $x$ : temperature
- $\hat{y}$ : predicted load

## 5. نموذج الانحدار الخطي

$$\hat{y} = \beta_0 + \beta_1 x$$

يمثل  $\beta_0$  الجزء الثابت، بينما يمثل  $\beta_1$  مقدار تغير الحمل مع تغير درجة الحرارة.

## 6. Prediction Error

$$e_i = t_i - \hat{y}_i$$

A good model should produce small residual errors.

## 6. خطأ التنبؤ

$$e_i = t_i - \hat{y}_i$$

يمثل الخطأ الفرق بين الحمل الحقيقي والحمل المتوقع به.

## 7. Least-Squares Principle

$$J(\beta_0, \beta_1) = \sum [t_i - (\beta_0 + \beta_1 x_i)]^2$$

Training selects the parameters that minimize the squared residuals.

## 7. مبدأ المربعات الصغرى

يتم اختيار المعاملات التي تجعل مجموع مربعات الأخطاء أصغر ما يمكن.

## 8. Matrix Form

$$t = X\beta + e$$

$$\hat{\beta} = (X^T X)^{-1} X^T t$$

```
X = [ones(size(temperature)) temperature];
beta = X \ loadMW;
```

## 8. الصيغة المصفوفية

يستخدم MATLAB العامل \ لحل مسألة المربعات الصغرى بكفاءة عددية.

## 9. Calculate Predictions

```
predictedLoad = X*beta;
```

$$\hat{y} = X\beta^{\wedge}$$

## 9. حساب التنبؤات

يتم ضرب مصفوفة المدخلات بمعاملات النموذج للحصول على الحمل المتنبأ به.

## 10. Error Metrics

$$MAE = (1/N) \sum |e_i|$$

$$MSE = (1/N) \sum e_i^2$$

$$RMSE = \sqrt{MSE}$$

```
errors = loadMW - predictedLoad;
MAE = mean(abs(errors));
MSE = mean(errors.^2);
RMSE = sqrt(MSE);
```

## 10. مقاييس الخطأ

تقيس MAE و MSE و RMSE الفرق بين القيم الحقيقية والمتنبأ بها بطرائق مختلفة.

## 11. Predict a New Load Value

```
newTemperature = 30;  
newLoad = beta(1) + beta(2)*newTemperature;
```

$$\hat{y}_{new} = \beta_0 + \beta_1 x_{new}$$

## 11. التنبؤ بقيمة جديدة

يمكن استخدام النموذج المدرب لتقدير الحمل عند درجة حرارة لم تستخدم أثناء التدريب.

## 12. Complete MATLAB Program

```
clear; clc; close all;

temperature = [10 12 14 16 18 20 22 24 26 28]';
loadMW = [105 110 116 121 128 134 141 147 154 162]';

X = [ones(size(temperature)) temperature];
beta = X \ loadMW;
predictedLoad = X*beta;
errors = loadMW - predictedLoad;

MAE = mean(abs(errors));
MSE = mean(errors.^2);
RMSE = sqrt(MSE);

fprintf('Intercept beta0 = %.4f\n',beta(1))
fprintf('Slope beta1 = %.4f MW/°C\n',beta(2))
fprintf('MAE = %.4f MW\n',MAE)
fprintf('MSE = %.4f MW^2\n',MSE)
fprintf('RMSE = %.4f MW\n',RMSE)

newTemperature = 30;
newLoad = beta(1) + beta(2)*newTemperature;
fprintf('Predicted load at %.1f °C = %.4f MW\n',newTemperature,newLoad)

figure
scatter(temperature,loadMW,55,'filled'); hold on
plot(temperature,predictedLoad,'LineWidth',1.8)
grid on
xlabel('Temperature [°C]')
ylabel('Electrical Load [MW]')
legend('Measured Load','Linear Regression','Location','best')
title('Electrical Load Forecasting')
```



## 12. البرنامج الكامل في MATLAB

ينشئ البرنامج النموذج ويحسب التنبؤات ومقاييس الخطأ ويرسم القيم المقاسة والمتنبأ بها.

## 13. Interpretation of the Slope

$$\beta_1 = \Delta Load / \Delta Temperature$$

A positive slope means that load increases as temperature increases in this dataset.

## 13. تفسير الميل

يمثل  $\beta_1$  مقدار تغير الحمل المتوقع عند تغير درجة الحرارة بمقدار درجة واحدة.

## 14. Training and Testing

A realistic workflow separates data into training and test subsets.

Dataset  $\rightarrow$  Training Set + Test Set

Test data must not be used when estimating model parameters.

## 14. التدريب والاختبار

يجب تقييم النموذج على بيانات لم تستخدم أثناء التدريب للحصول على تقييم أكثر واقعية.

## 15. Experiments

1. Add noise to the load data.
2. Remove one sample and retrain.
3. Use only the first seven samples for training.
4. Predict the last three samples.

5. Add time or previous load as a second input.

## 15. التجارب

1. أضف ضجيجًا إلى بيانات الحمل.
2. احذف عينة وأعد التدريب.
3. استخدم العينات السبع الأولى للتدريب.
4. تنبأ بالعينات الثلاث الأخيرة.
5. أضف الزمن أو الحمل السابق كدخل ثانٍ.

## 16. Lab Tasks

1. Run the complete program.
2. Record  $\beta_0$  and  $\beta_1$ .
3. Calculate predictions manually for two temperatures.
4. Calculate MAE, MSE, and RMSE.
5. Plot measured and predicted load.
6. Explain whether the linear model is suitable.

## 16. مهام المختبر

1. شغل البرنامج.
2. سجل  $\beta_0$  و  $\beta_1$ .
3. احسب تنبؤين يدويًا.
4. احسب MAE و MSE و RMSE.
5. ارسم الحمل الحقيقي والمتنبأ به.
6. ناقش مدى ملاءمة النموذج الخطي.



## Questions

1. Why is load forecasting supervised learning?
2. What do  $\beta_0$  and  $\beta_1$  represent?
3. Why are errors squared in least squares?
4. What is the difference between MAE and RMSE?
5. Why should test data remain unseen during training?
6. What additional inputs could improve forecasting?

## أسئلة المختبر

1. لماذا يعد التنبؤ بالحمل تعلمًا خاضعًا للإشراف؟
2. ماذا يمثل  $\beta_0$  و  $\beta_1$ ؟
3. لماذا نقوم بتربيع الأخطاء؟
4. ما الفرق بين MAE و RMSE؟
5. لماذا يجب عدم استخدام بيانات الاختبار في التدريب؟
6. ما المدخلات الإضافية التي قد تحسن التنبؤ؟

# References | المراجع

المراجع العامة المستخدمة في هذا المقرر

[1] A. Gabash, *Flexible Optimal Operations of Energy Supply Networks with Renewable Energy Generation and Battery Storage*. Saarbrücken, Germany: Südwestdeutscher Verlag für Hochschulschriften, 2014.

[2] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th Global ed. Harlow, U.K.: Pearson Education Limited, 2022.

[3] A. Gabash, "Energy Market Transition and Climate Change: A Review of TSOs-DSOs C+++ Framework from 1800 to Present," *Energies*, vol. 16, no. 17, Art. no. 6139, 2023, doi: 10.3390/en16176139.

[4] A. Gabash, *AI Applications in Electrical Power Systems*, Version 1.0, 2026. [Online]. Available: <https://aoussgabash.com>

# Publication Information | معلومات النشر

|                  |                                                               |
|------------------|---------------------------------------------------------------|
| Document         | Laboratory 03 · Machine Learning Load Forecasting             |
| Course           | AI Applications in Electrical Power Systems                   |
| Author           | Dr.-Ing. Aouss Gabash                                         |
| Version          | 1.0                                                           |
| Publication year | 2026                                                          |
| Official website | <a href="https://aoussgabash.com">https://aoussgabash.com</a> |
| Citation style   | IEEE                                                          |

**Recommended citation:**

Gabash, A. (2026). Machine Learning Load Forecasting. AI Applications in Electrical Power Systems, Laboratory 03, Version 1.0. <https://aoussgabash.com>

---

المرجع المقترح:

أوس غباش، 2026، مخبر 03، تطبيقات الذكاء الاصطناعي في أنظمة الطاقة الكهربائية، الإصدار 1.0، <https://aoussgabash.com>

---

© 2026 Dr.-Ing. Aouss Gabash. Educational use with attribution to the author and official website.