

LAB 04 | المختبر 04

AI-Based PV Power Forecasting

التنبؤ بقدرة الأنظمة الكهروضوئية باستخدام الذكاء الاصطناعي

Solar Irradiance, Temperature, Multiple Regression, and Forecasting

الإشعاع الشمسي ودرجة الحرارة والانحدار متعدد المتغيرات والتنبؤ

Prepared by | إعداد: Dr.-Ing. Aouss Gabash



Learning Outcomes

مخرجات التعلم

1. Implement a MATLAB workflow for supervised machine learning.
تنفيذ سير عمل في MATLAB حول التعلم الآلي المراقب.
2. Interpret numerical results, plots, and engineering implications.
تفسير النتائج العددية والرسوم والدلالات الهندسية.
3. Validate the implementation and discuss limitations.
التحقق من صحة التنفيذ ومناقشة حدوده.



Prerequisite sites

المتطلبات
السابقة

Basic statistics, vectors, and MATLAB fundamentals.

الإحصاء الأساسي
والمتجهات ومبادئ
.MATLAB



Lab Objectives

- Understand PV forecasting as supervised learning.
- Use irradiance and temperature as input features.
- Build a multiple linear-regression model.
- Interpret model parameters physically.
- Forecast PV output for new weather conditions.
- Evaluate predictions using MAE, MSE, and RMSE.

Supervised
Machine Learning |
التعلم الآلي المراقب

أهداف المختبر

- فهم التنبؤ بقدرة PV كمسألة تعلم خاضع للإشراف.
- استخدام الإشعاع الشمسي ودرجة الحرارة كمداخل.
- بناء نموذج انحدار خطي متعدد المتغيرات.
- تفسير معاملات النموذج فيزيائيًا.
- التنبؤ بالقدرة لظروف جووية جديدة.
- تقييم التنبؤ باستخدام MAE و MSE و RMSE.

1. PV Forecasting Problem

$$PPV = f(G, T, \dots)$$

- G: solar irradiance [W/m²]
- T: temperature [°C]
- P_{PV}: electrical power [kW]

1. مسألة التنبؤ بقدرة PV

تعتمد قدرة النظام الكهروضوئي أساسًا على الإشعاع الشمسي، كما تتأثر بدرجة الحرارة وعوامل أخرى.

$$PPV = f(G, T, \dots)$$

2. Why Use Two Inputs?

Solar Irradiance G

Higher irradiance generally increases available PV power.

Temperature T

Higher cell temperature often reduces conversion efficiency.

PV forecasting is therefore a useful multivariable learning problem.

2. لماذا نستخدم مدخلين؟

يرفع الإشعاع القدرة المتاحة عادةً، بينما قد يؤدي ارتفاع حرارة الخلايا إلى انخفاض الكفاءة.

3. Example Dataset

Sample	G [W/m ²]	T [°C]	PV Power [kW]
1	200	15	18
2	300	18	27
3	400	20	36
4	500	22	44
5	600	25	52
6	700	27	60
7	800	30	67
8	900	32	74
9	1000	35	81
10	850	38	68

3. مجموعة البيانات

تحتوي كل عينة على الإشعاع ودرجة الحرارة وقدرة PV المقاسة.

البيانات تعليمية ومبسطة لفهم الخوارزمية.

4. Enter Data in MATLAB

```
G = [200 300 400 500 600 700 800 900 1000 850]';
T = [15 18 20 22 25 27 30 32 35 38]';
Ppv = [18 27 36 44 52 60 67 74 81 68]';
```

4. إدخال البيانات في MATLAB

نخزن الإشعاع ودرجة الحرارة والقدرة في ثلاثة متجهات عمودية.

5. Multiple Linear-Regression Model

$$\hat{P}_{PV} = \beta_0 + \beta_1 G + \beta_2 T$$

- β_0 : intercept
- β_1 : irradiance coefficient
- β_2 : temperature coefficient

5. نموذج الانحدار متعدد المتغيرات

$$\hat{P}_{PV} = \beta_0 + \beta_1 G + \beta_2 T$$

يمثل β_1 تأثير الإشعاع و β_2 التأثير المرتبط بدرجة الحرارة.

6. Matrix Form

$$\hat{P} = X\beta$$

$$\hat{\beta} = (X^T X)^{-1} X^T P$$

```
X = [ones(size(G)) G T];
beta = X \ Ppv;
```

6. الصيغة المصفوفية

يستخدم MATLAB العامل \ لحل مسألة المربعات الصغرى بكفاءة عددية.

7. Calculate Predictions

```
predictedPpv = X*beta;
```

$$\hat{P} = X\hat{\beta}$$

7. حساب التنبؤات

نضرب مصفوفة المدخلات بمعاملات النموذج للحصول على القدرة المتنبأ بها.

8. Error Metrics

$$MAE = (1/N) \sum |e_i|$$

$$MSE = (1/N) \sum e_i^2$$

$$RMSE = \sqrt{MSE}$$

```
errors = Ppv - predictedPpv;
MAE = mean(abs(errors));
MSE = mean(errors.^2);
RMSE = sqrt(MSE);
```

8. مقاييس الخطأ

تقيس MAE و MSE و RMSE الفروق بين القدرة الحقيقية والمتنبأ بها.

9. Forecast New Weather Conditions

```
Gnew = 750;
Tnew = 28;
Pnew = [1 Gnew Tnew]*beta;
```

$$\hat{P}^{new} = \beta_0 + \beta_1 G_{new} + \beta_2 T_{new}$$

9. التنبؤ لظروف جديدة

يمكن استخدام النموذج المدرب للتنبؤ بالقدرة عند إشعاع ودرجة حرارة جديدين.

10. Complete MATLAB Program

```

clear; clc; close all;

G = [200 300 400 500 600 700 800 900 1000 850]';
T = [15 18 20 22 25 27 30 32 35 38]';
Ppv = [18 27 36 44 52 60 67 74 81 68]';

X = [ones(size(G)) G T];
beta = X \ Ppv;
predictedPpv = X*beta;
errors = Ppv - predictedPpv;

MAE = mean(abs(errors));
MSE = mean(errors.^2);
RMSE = sqrt(MSE);

fprintf('beta0 = %.6f\n',beta(1))
fprintf('beta1 = %.6f kW/(W/m^2)\n',beta(2))
fprintf('beta2 = %.6f kW/°C\n',beta(3))
fprintf('MAE = %.4f kW\n',MAE)
fprintf('MSE = %.4f kW^2\n',MSE)
fprintf('RMSE = %.4f kW\n',RMSE)

Gnew = 750;
Tnew = 28;
Pnew = [1 Gnew Tnew]*beta;
fprintf('Forecast at G=%.1f W/m^2 and T=%.1f °C: %.4f\n',Gnew,Tnew,Pnew)

figure
plot(Ppv,'o-','LineWidth',1.5); hold on
plot(predictedPpv,'s--','LineWidth',1.5)
grid on
xlabel('Sample')
ylabel('PV Power [kW]')
legend('Measured','Predicted','Location','best')
title('PV Power Forecasting')

```


10. البرنامج الكامل في MATLAB

يبني البرنامج النموذج ويحسب التنبؤات ومقاييس الخطأ ويعرض القدرة المقاسة والمتنبأ بها.

11. Parameter Interpretation

β_1

Expected change in PV power for one-unit irradiance increase while temperature is fixed.

β_2

Expected change in PV power for one-degree temperature increase while irradiance is fixed.

11. تفسير المعاملات

يمثل كل معامل تأثير أحد المدخلات مع تثبيت المدخل الآخر.

12. Model Limitations

- Real PV behavior is nonlinear.
- Cloud motion introduces fast variability.
- Cell temperature differs from ambient temperature.
- Shading, orientation, and inverter limits are ignored.
- Extrapolation beyond training data can be unreliable.

12. حدود النموذج

السلوك الحقيقي غير خطي ويتأثر بالسحب والحرارة والتظليل والاتجاه وحدود العاكس، لذلك يعد النموذج هنا تعليميًا ومبسّطًا.

13. Experiments

1. Train using irradiance only.
2. Compare one-input and two-input models.
3. Add random noise to the measurements.
4. Reserve the last samples for testing.
5. Add time of day as a third feature.

13. التجارب

1. درّب النموذج باستخدام الإشعاع فقط.
2. قارن نموذج المدخل الواحد بمدخلين.
3. أضف ضجيجًا إلى القياسات.
4. استخدم العينات الأخيرة للاختبار.
5. أضف ساعة اليوم كميزة ثالثة.

14. Lab Tasks

1. Run the complete program.
2. Record β_0 , β_1 , and β_2 .
3. Calculate one forecast manually.
4. Calculate MAE, MSE, and RMSE.
5. Plot measured and predicted power.
6. Discuss whether coefficient signs are physically reasonable.

14. مهام المختبر

1. شغل البرنامج.
2. سجل β_0 و β_1 و β_2 .
3. احسب تنبؤًا واحدًا يدويًا.
4. احسب MAE و MSE و RMSE.
5. ارسم القدرة المقاسة والمتنبأ بها.
6. ناقش منطق الإشارات الفيزيائية للمعاملات.



Questions

1. Why is PV forecasting supervised learning?
2. Why are irradiance and temperature useful inputs?
3. What do β_1 and β_2 represent?
4. Why can a linear model be insufficient?
5. What is the purpose of a test set?
6. What additional inputs could improve forecasting?

أسئلة المختبر

1. لماذا يعد التنبؤ بقدرة PV تعلمًا خاضعًا للإشراف؟
2. لماذا يعد الإشعاع ودرجة الحرارة مدخلين مهمين؟
3. ماذا يمثل β_1 و β_2 ؟
4. لماذا قد لا يكفي النموذج الخطي؟
5. ما وظيفة بيانات الاختبار؟
6. ما المدخلات الإضافية التي قد تحسن التنبؤ؟

References | المراجع

المراجع العامة المستخدمة في هذا المقرر

- [1] A. Gabash, *Flexible Optimal Operations of Energy Supply Networks with Renewable Energy Generation and Battery Storage*. Saarbrücken, Germany: Südwestdeutscher Verlag für Hochschulschriften, 2014.
- [2] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th Global ed. Harlow, U.K.: Pearson Education Limited, 2022.
- [3] A. Gabash, "Energy Market Transition and Climate Change: A Review of TSOs-DSOs C+++ Framework from 1800 to Present," *Energies*, vol. 16, no. 17, Art. no. 6139, 2023, doi: 10.3390/en16176139.
- [4] A. Gabash, *AI Applications in Electrical Power Systems*, Version 1.0, 2026. [Online]. Available: <https://aoussgabash.com>

Recommended citation:

Gabash, A. (2026). AI-Based PV Power Forecasting. AI Applications in Electrical Power Systems, Laboratory 04, Version 1.0. <https://aoussgabash.com>

المرجع المقترح:

أوس غباش، 2026، مخبر 04، تطبيقات الذكاء الاصطناعي في أنظمة الطاقة الكهربائية، الإصدار 1.0، <https://aoussgabash.com>

© 2026 Dr.-Ing. Aouss Gabash. Educational use with attribution to the author and official website.