

LAB 09 | المختبر 09

Short-Term Load Forecasting with LSTM

التنبؤ قصير الأمد بالحمل الكهربائي باستخدام LSTM

Data Preparation, Sequence Learning, Testing, and Error Analysis

تجهيز البيانات وتعلم المتتاليات والاختبار وتحليل الأخطاء

Prepared by | إعداد: Dr.-Ing. Aouss Gabash

Laboratory Objectives

- Generate or import hourly electrical-load data.
- Create lagged sequences for one-step-ahead forecasting.
- Normalize data without test-data leakage.
- Build and train an LSTM regression network.
- Evaluate MAE, RMSE, and MAPE.
- Compare LSTM with a persistence baseline.

أهداف المختبر

- إنشاء أو استيراد بيانات حمل ساعية.
- بناء متتاليات دخل للتنبؤ بخطوة واحدة.
- تطبيع البيانات دون تسريب معلومات الاختبار.
- بناء وتدريب شبكة LSTM للانحدار.
- تقييم MAE و RMSE و MAPE.
- مقارنة LSTM بخط أساس يعتمد على آخر قيمة.

1. Problem Definition

$$[P_{t-23}, \dots, P_t] \rightarrow P_{t+1}$$

Sequence length = 24 hours; target = next-hour load.

1. تعريف المسألة

نستخدم قيم الحمل خلال الساعات الأربع والعشرين السابقة لتوقع حمل الساعة التالية.

2. Requirements


- MATLAB
- Deep Learning Toolbox
- No external dataset is required for the basic version.

The script generates a realistic synthetic profile that can later be replaced by measured CSV data.

2. المتطلبات

يلزم MATLAB مع Deep Learning Toolbox، ويمكن لاحقًا استبدال البيانات الاصطناعية بملف CSV حقيقي.

3. Data Preparation Workflow



3. خطوات تجهيز البيانات

يجب الحفاظ على الترتيب الزمني وتقسيم البيانات زمنيًا، ثم حساب معاملات التطبيع من بيانات التدريب فقط.

4. LSTM Network

```
layers = [  
    sequenceInputLayer(1)  
    lstmLayer(64, 'OutputMode', 'last')  
    dropoutLayer(0.20)  
    fullyConnectedLayer(32)  
    reluLayer  
    fullyConnectedLayer(1)  
    regressionLayer  
];
```

4. بنية شبكة LSTM

تستقبل الشبكة متتالية حمل بطول 24 ساعة وتنتج قيمة عددية واحدة للحمل التالي.

5. Complete MATLAB Script

```

%% Lab 09: Short-Term Load Forecasting using LSTM
clear; clc; close all;
rng(7);

%% Generate hourly load data
nDays = 180;
N = 24*nDays;
t = (0:N-1)';
hour = mod(t,24);
day = floor(t/24);
weekday = mod(day,7);

dailyPattern = 120 + 28*sin(2*pi*(hour-7)/24) ...
    + 10*sin(4*pi*(hour-5)/24);
weeklyPattern = 8*(weekday<5) - 7*(weekday>=5);
seasonPattern = 12*sin(2*pi*day/180);
temperature = 18 + 8*sin(2*pi*(hour-14)/24) ...
    + 5*sin(2*pi*day/180) + 1.2*randn(N,1);

loadMW = dailyPattern + weeklyPattern + seasonPattern ...
    + 0.9*max(temperature-22,0) ...
    + 0.5*max(12-temperature,0) ...
    + 2.5*randn(N,1);

%% Create 24-hour sequences
seqLen = 24;
numSamples = N-seqLen;
X = cell(numSamples,1);
Y = zeros(numSamples,1);
for k = 1:numSamples
    X{k} = loadMW(k:k+seqLen-1)';
    Y(k) = loadMW(k+seqLen);
end

%% Chronological split
nTrain = floor(0.70*numSamples);
nVal = floor(0.15*numSamples);
idxTrain = 1:nTrain;
idxVal = nTrain+1:nTrain+nVal;
idxTest = nTrain+nVal+1:numSamples;

XTrain=X(idxTrain); YTrain=Y(idxTrain);
XVal=X(idxVal); YVal=Y(idxVal);
XTest=X(idxTest); YTest=Y(idxTest);

```

```

%% Normalize with training statistics only
trainValues = cell2mat(XTrain);
mu = mean(trainValues,'all');
sigma = std(trainValues,0,'all');
XTrainN = cellfun(@(x)(x-mu)/sigma,XTrain,'UniformOutput',false);
XValN = cellfun(@(x)(x-mu)/sigma,XVal,'UniformOutput',false);
XTestN = cellfun(@(x)(x-mu)/sigma,XTest,'UniformOutput',false);
YTrainN = (YTrain-mu)/sigma;
YValN = (YVal-mu)/sigma;

%% Define and train the network
layers = [
    sequenceInputLayer(1)
    lstmLayer(64,'OutputMode','last')
    dropoutLayer(0.20)
    fullyConnectedLayer(32)
    reluLayer
    fullyConnectedLayer(1)
    regressionLayer
];

options = trainingOptions('adam', ...
    'MaxEpochs',80, ...
    'MiniBatchSize',64, ...
    'InitialLearnRate',1e-3, ...
    'GradientThreshold',1, ...
    'Shuffle','never', ...
    'ValidationData',{XValN,YValN}, ...
    'ValidationFrequency',30, ...
    'ValidationPatience',8, ...
    'Verbose',false, ...
    'Plots','training-progress');

net = trainNetwork(XTrainN,YTrainN,layers,options);

%% Predict and reverse normalization
YPredN = predict(net,XTestN,'MiniBatchSize',64);
YPred = YPredN*sigma + mu;
YPersistence = cellfun(@(x)x(end),XTest);

%% Performance indicators
errLSTM = YPred-YTest;
errBase = YPersistence-YTest;
MAE_LSTM = mean(abs(errLSTM));
RMSE_LSTM = sqrt(mean(errLSTM.^2));

```

```

MAPE_LSTM = 100*mean(abs(errLSTM./YTest));
MAE_Base = mean(abs(errBase));
RMSE_Base = sqrt(mean(errBase.^2));
MAPE_Base = 100*mean(abs(errBase./YTest));

Results = table([MAE_Base;MAE_LSTM], ...
    [RMSE_Base;RMSE_LSTM], ...
    [MAPE_Base;MAPE_LSTM], ...
    'VariableNames',{'MAE_MW','RMSE_MW','MAPE_percent'}, ...
    'RowNames',{'Persistence','LSTM'});
disp(Results)

%% Plot predictions
nShow = min(240,length(YTest));
figure
plot(YTest(1:nShow),'k','LineWidth',1.35); hold on
plot(YPersistence(1:nShow),'--','LineWidth',1.0)
plot(YPred(1:nShow),'LineWidth',1.2)
grid on
xlabel('Test hour'); ylabel('Load (MW)')
legend('Actual','Persistence','LSTM','Location','best')
title('One-Step-Ahead Load Forecast')

figure
histogram(errLSTM,30)
grid on
xlabel('Prediction Error (MW)'); ylabel('Frequency')
title('LSTM Forecast Error Distribution')

```

5. البرنامج الكامل في MATLAB

ينشئ البرنامج البيانات والمتتاليات، ويقسمها زمنيًا، ويدرب LSTM، ثم يقارنها بخط أساس ويحسب مؤشرات الخطأ.

6. Evaluation Metrics

$$MAE = (1/N) \sum |\hat{y}_i - y_i|$$

Missing argument for \sqrt

$$MAPE = (100/N) \sum |(y_i - \hat{y}_i)/y_i|$$

6. مؤشرات التقييم

تقيس المؤشرات مقدار خطأ التنبؤ بوحدات مختلفة، ويجب تفسيرها إلى جانب خط الأساس.

7. Experiments

1. Change sequence length to 12, 48, or 168 hours.
2. Change the number of LSTM units.
3. Add temperature as a second feature.
4. Compare different learning rates.
5. Replace synthetic data with measured CSV data.

7. التجارب

1. غيّر طول المتتالية.
2. غيّر عدد وحدات LSTM.
3. أضف درجة الحرارة كميزة ثانية.
4. قارن معدلات تعلم مختلفة.
5. استبدل البيانات الاصطناعية ببيانات حقيقية.

8. Lab Tasks

1. Run the complete script.
2. Record LSTM and persistence metrics.
3. Plot actual and predicted loads.
4. Explain why chronological splitting is required.
5. Explain why normalization uses training data only.

6. Repeat at least two experiments.

8. مهام المختبر

1. شغل البرنامج الكامل.
2. سجل مؤشرات LSTM وخط الأساس.
3. ارسم الحمل الحقيقي والمتنبأ به.
4. اشرح ضرورة التقسيم الزمني.
5. اشرح سبب استخدام بيانات التدريب فقط للتطبيق.
6. نفذ تجربتين على الأقل.



Review Questions

1. Why is LSTM suitable for load forecasting?
2. What does OutputMode='last' mean?
3. What is data leakage?
4. Why compare with persistence?
5. What is the difference between MAE, RMSE, and MAPE?
6. How can weather variables improve the model?

أسئلة المراجعة

1. لماذا تناسب LSTM التنبؤ بالحمل؟
2. ماذا يعني OutputMode='last'؟
3. ما المقصود بتسريب البيانات؟
4. لماذا نقارن بخط أساس؟
5. ما الفرق بين MAE و RMSE و MAPE؟
6. كيف تحسن متغيرات الطقس النموذج؟

References | المراجع

المراجع العامة المستخدمة في هذا المقرر

- [1] A. Gabash, *Flexible Optimal Operations of Energy Supply Networks with Renewable Energy Generation and Battery Storage*. Saarbrücken, Germany: Südwestdeutscher Verlag für Hochschulschriften, 2014.
- [2] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th Global ed. Harlow, U.K.: Pearson Education Limited, 2022.
- [3] A. Gabash, "Energy Market Transition and Climate Change: A Review of TSOs-DSOs C+++ Framework from 1800 to Present," *Energies*, vol. 16, no. 17, Art. no. 6139, 2023, doi: 10.3390/en16176139.
- [4] A. Gabash, *AI Applications in Electrical Power Systems*, Version 1.0, 2026. [Online]. Available: <https://aoussgabash.com>

Recommended citation:

Gabash, A. (2026). Short-Term Load Forecasting with LSTM. AI Applications in Electrical Power Systems, Laboratory 09, Version 1.0. <https://aoussgabash.com>

المرجع المقترح:

أوس غباش، 2026، مخبر 09، تطبيقات الذكاء الاصطناعي في أنظمة الطاقة الكهربائية، الإصدار 1.0، <https://aoussgabash.com>

© 2026 Dr.-Ing. Aouss Gabash. Educational use with attribution to the author and official website.