

# Short-Term Load Forecasting with LSTM

## التنبؤ قصير الأمد بالحمل الكهربائي باستخدام LSTM

MATLAB practical laboratory: data preparation, sequence learning, testing, and error analysis

مخبر عملي باستخدام MATLAB: تجهيز البيانات، تعلم المتتاليات، الاختبار وتحليل الأخطاء

Prepared by | إعداد | Dr.-Ing. Aouss Gabash

### Laboratory Objectives

- Generate or import hourly electrical-load data.
- Create lagged input sequences for one-step-ahead forecasting.
- Normalize training data without leaking test information.
- Build and train an LSTM regression network.
- Evaluate predictions using MAE, RMSE, and MAPE.
- Compare the LSTM against a persistence baseline.

### أهداف المخبر

- إنشاء أو استيراد بيانات حمل كهربائي ساعية.
- بناء متتاليات دخل للتنبؤ بخطوة زمنية واحدة.
- تطبيع بيانات التدريب دون تسريب معلومات الاختبار.
- بناء وتدريب شبكة LSTM للانحدار.
- تقييم النتائج باستخدام MAE و RMSE و MAPE.
- مقارنة LSTM بخط أساس يعتمد على آخر قيمة.

## 1. Problem Definition

Use the previous 24 hourly load values to predict the next hour:

$$[P_{t-23}, \dots, P_t] \rightarrow P_{t+1}$$

Sequence length = 24

Regression

One-step ahead

## 1. تعريف المسألة

نستخدم قيم الحمل خلال الساعات الأربع والعشرين السابقة لتوقع حمل الساعة التالية.

## 2. Requirements

- MATLAB
- Deep Learning Toolbox
- No external dataset is required for the basic version

The code first creates a realistic synthetic load profile. It can later be replaced by measured CSV data.

## 2. المتطلبات

يلزم MATLAB مع Deep Learning Toolbox. يولد الكود بيانات تعليمية اصطناعية، ويمكن لاحقًا استبدالها بملف CSV حقيقي.

### 3. Complete MATLAB Script

```

%% Lab 09: Short-Term Load Forecasting using LSTM
clear; clc; close all;
rng(7); % Reproducible results

%% 1) Generate hourly load data
nDays = 180;
N = 24*nDays;
t = (0:N-1)';

hour = mod(t,24);
day = floor(t/24);
weekday = mod(day,7);

dailyPattern = 120 + 28*sin(2*pi*(hour-7)/24) ...
               + 10*sin(4*pi*(hour-5)/24);
weeklyPattern = 8*(weekday < 5) - 7*(weekday >= 5);
seasonPattern = 12*sin(2*pi*day/180);
temperature = 18 + 8*sin(2*pi*(hour-14)/24) ...
              + 5*sin(2*pi*day/180) + 1.2*randn(N,1);

loadMW = dailyPattern + weeklyPattern + seasonPattern ...
          + 0.9*max(temperature-22,0) ...
          + 0.5*max(12-temperature,0) ...
          + 2.5*randn(N,1);

%% 2) Plot the first two weeks
figure;
plot(t(1:24*14),loadMW(1:24*14),'LineWidth',1.2);
grid on;
xlabel('Hour'); ylabel('Load (MW)');
title('Synthetic Electrical Load - First 14 Days');

%% 3) Create 24-hour sequences
seqLen = 24;
numSamples = N-seqLen;

X = cell(numSamples,1);
Y = zeros(numSamples,1);

for k = 1:numSamples
    X{k} = loadMW(k:k+seqLen-1)'; % 1 x 24
    Y(k) = loadMW(k+seqLen);
end

%% 4) Chronological split: 70% / 15% / 15%

```

```

nTrain = floor(0.70*numSamples);
nVal    = floor(0.15*numSamples);

idxTrain = 1:nTrain;
idxVal    = nTrain+1:nTrain+nVal;
idxTest   = nTrain+nVal+1:numSamples;

XTrain = X(idxTrain); YTrain = Y(idxTrain);
XVal    = X(idxVal);   YVal    = Y(idxVal);
XTest   = X(idxTest);  YTest   = Y(idxTest);

%% 5) Normalize using TRAINING statistics only
trainValues = cell2mat(XTrain);
mu = mean(trainValues,'all');
sigma = std(trainValues,0,'all');

XTrainN = cellfun(@(x)(x-mu)/sigma,XTrain,'UniformOutput',false);
XValN    = cellfun(@(x)(x-mu)/sigma,XVal,'UniformOutput',false);
XTestN   = cellfun(@(x)(x-mu)/sigma,XTest,'UniformOutput',false);

YTrainN = (YTrain-mu)/sigma;
YValN    = (YVal-mu)/sigma;

%% 6) Define LSTM network
layers = [
    sequenceInputLayer(1)
    lstmLayer(64,'OutputMode','last')
    dropoutLayer(0.20)
    fullyConnectedLayer(32)
    reluLayer
    fullyConnectedLayer(1)
    regressionLayer
];

options = trainingOptions('adam', ...
    'MaxEpochs',80, ...
    'MiniBatchSize',64, ...
    'InitialLearnRate',1e-3, ...
    'GradientThreshold',1, ...
    'Shuffle','never', ...
    'ValidationData',{XValN,YValN}, ...
    'ValidationFrequency',30, ...
    'ValidationPatience',8, ...
    'Verbose',false, ...
    'Plots','training-progress');

```

```

%% 7) Train
net = trainNetwork(XTrainN,YTrainN,layers,options);

%% 8) Predict and reverse normalization
YPredN = predict(net,XTestN,'MiniBatchSize',64);
YPred = YPredN*sigma + mu;

%% 9) Persistence baseline
YPersistence = cellfun(@(x)x(end),XTest);

%% 10) Performance indicators
errLSTM = YPred-YTest;
errBase = YPersistence-YTest;

MAE_LSTM = mean(abs(errLSTM));
RMSE_LSTM = sqrt(mean(errLSTM.^2));
MAPE_LSTM = 100*mean(abs(errLSTM./YTest));

MAE_Base = mean(abs(errBase));
RMSE_Base = sqrt(mean(errBase.^2));
MAPE_Base = 100*mean(abs(errBase./YTest));

Results = table( ...
    [MAE_Base;MAE_LSTM], ...
    [RMSE_Base;RMSE_LSTM], ...
    [MAPE_Base;MAPE_LSTM], ...
    'VariableNames',{'MAE_MW','RMSE_MW','MAPE_percent'}, ...
    'RowNames',{'Persistence','LSTM'});

disp(Results);

%% 11) Plot predictions
nShow = min(240,length(YTest));

figure;
plot(YTest(1:nShow),'k','LineWidth',1.35); hold on;
plot(YPersistence(1:nShow),'--','LineWidth',1.0);
plot(YPred(1:nShow),'LineWidth',1.2);
grid on;
xlabel('Test hour'); ylabel('Load (MW)');
legend('Actual','Persistence','LSTM','Location','best');
title('One-Step-Ahead Load Forecast');

%% 12) Plot prediction error

```

```
figure;
histogram(errLSTM,30);
grid on;
xlabel('Prediction error (MW)');
ylabel('Frequency');
title('LSTM Prediction Error Distribution');
```

### 3. الكود الكامل في MATLAB

ينشئ الكود حملاً ساعياً يجمع نمطاً يومياً وأسبوعياً وموسمياً وتأثير درجة الحرارة والضجيج، ثم يبني متتاليات بطول 24 ساعة ويدرب LSTM.

## 4. Understanding the Data Model


$$P(t) = P_{daily}(t) + P_{weekly}(t) + P_{season}(t) + P_{temperature}(t) + noise$$

This is not intended to be a complete physical model. It is a controlled educational signal with realistic temporal structure.

### 4. فهم نموذج البيانات

الإشارة الاصطناعية ليست نموذجاً فيزيائياً كاملاً، لكنها تحتوي أنماطاً زمنية واقعية تساعد على فهم التنبؤ قبل استخدام بيانات حقيقية.

## 5. Why Chronological Splitting?




Never compute normalization statistics from the complete dataset. That would allow test-period information to influence training.



## 5. لماذا التقسيم الزمني؟

نريد محاكاة الاستخدام الحقيقي: يتعلم النموذج من الماضي ثم يُختبر على فترة أحدث لم يرها سابقًا.

## 6. Network Architecture



**OutputMode = last** means the network uses the final sequence representation to produce one forecast value.

## 6. بنية الشبكة

تستقبل الشبكة متتالية من 24 خطوة، ثم تلخصها LSTM في تمثيل واحد يُمرر إلى طبقات كاملة الاتصال لإنتاج قيمة الحمل المتوقعة.

## 7. Evaluation Metrics

$$MAE = mean(|\hat{y} - y|)$$

$$RMSE = \sqrt{mean((\hat{y} - y)^2)}$$

$$MAPE = 100 \cdot mean(|(\hat{y} - y)/y|)$$

A useful LSTM should outperform the persistence model. Otherwise, the added complexity is not justified.

## 7. مؤشرات التقييم

يُقاس MAE متوسط مقدار الخطأ، بينما يعاقب RMSE الأخطاء الكبيرة أكثر. أما MAPE فيعرض الخطأ كنسبة مئوية.

## 8. Expected Results

Exact values vary because of random initialization, but the following behavior is expected:

- Training and validation losses decrease and then stabilize.
- LSTM follows the daily load pattern and peaks.
- LSTM normally improves upon persistence for changing load periods.
- Larger errors may occur near sudden peaks or regime changes.

## 8. النتائج المتوقعة

يُفترض أن يتتبع النموذج النمط اليومي للحمل وأن يتفوق غالبًا على خط الأساس، مع بقاء أخطاء أكبر قرب القمم والتغيرات المفاجئة.

## 9. Student Tasks

1. Change the sequence length from 24 to 48 and compare RMSE.
2. Change the number of LSTM units: 16, 32, 64, and 128.
3. Remove dropout and observe training/validation behavior.
4. Add temperature as a second input feature.
5. Forecast 24 hours ahead instead of one hour ahead.
6. Replace synthetic data with measured load data from a CSV file.

## 9. مهام الطالب

1. غيّر طول المتتالية من 24 إلى 48 وقارن RMSE.
2. جرّب 16 و32 و64 و128 وحدة LSTM.
3. احذف طبقة Dropout وراقب التدريب والتحقق.
4. أضف درجة الحرارة كميزة دخل ثانية.
5. حوّل المسألة إلى توقع 24 ساعة مقبلة.
6. استبدل البيانات الاصطناعية ببيانات حقيقية من CSV.

## 10. Optional Extension: Two Input Features

Each sequence can contain load and temperature:

```
X2{k} = [loadMW(k:k+seqLen-1)'; ...
         temperature(k:k+seqLen-1)'];

layers2 = [
    sequenceInputLayer(2)
    lstmLayer(64, 'OutputMode', 'last')
    fullyConnectedLayer(1)
    regressionLayer
];
```

## 10. توسع اختياري: ميزتا دخل

تصبح كل خطوة زمنية متجهًا يحتوي الحمل ودرجة الحرارة، ويجب تغيير عدد ميزات طبقة الدخل إلى 2.

## 11. Laboratory Report

The report should contain:

- Problem statement and data description
- Network architecture
- Training options
- Plots of actual and predicted load
- MAE, RMSE, and MAPE comparison table

- Discussion of errors and limitations

## 11. تقرير المخبر

يجب أن يتضمن التقرير تعريف المسألة والبيانات، بنية الشبكة، إعدادات التدريب، الرسوم، جدول مؤشرات الخطأ، ومناقشة القيود والنتائج.

# References | المراجع

المراجع العامة المستخدمة في هذا المقرر

[1] A. Gabash, *Flexible Optimal Operations of Energy Supply Networks with Renewable Energy Generation and Battery Storage*. Saarbrücken, Germany: Südwestdeutscher Verlag für Hochschulschriften, 2014.

[2] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th Global ed. Harlow, U.K.: Pearson Education Limited, 2022.

[3] A. Gabash, "Energy Market Transition and Climate Change: A Review of TSOs-DSOs C++ Framework from 1800 to Present," *Energies*, vol. 16, no. 17, Art. no. 6139, 2023, doi: 10.3390/en16176139.

[4] A. Gabash, *AI Applications in Electrical Power Systems*, Version 1.0, 2026. [Online]. Available: <https://aoussgabash.com>

# Publication Information | معلومات النشر

|                  |                                                               |
|------------------|---------------------------------------------------------------|
| Document         | Laboratory 09 · Short-Term Load Forecasting with LSTM         |
| Course           | AI Applications in Electrical Power Systems                   |
| Author           | Dr.-Ing. Aouss Gabash                                         |
| Version          | 1.0                                                           |
| Publication year | 2026                                                          |
| Official website | <a href="https://aoussgabash.com">https://aoussgabash.com</a> |
| Citation style   | IEEE                                                          |

**Recommended citation:**  
Gabash, A. (2026). Short-Term Load Forecasting with LSTM. AI Applications in Electrical Power Systems, Laboratory 09, Version 1.0. <https://aoussgabash.com>

---

المرجع المقترح:

أوس غباش، 2026، مخبر 09، تطبيقات الذكاء الاصطناعي في أنظمة الطاقة الكهربائية، الإصدار 1.0، <https://aoussgabash.com>

---

© 2026 Dr.-Ing. Aouss Gabash. Educational use with attribution to the author and official website.