

# Load Forecasting with a Transformer

التنبؤ بالحمل الكهربائي باستخدام Transformer

MATLAB R2023b+ practical laboratory using self-attention and positional embeddings

مخبر عملي باستخدام الانتباه الذاتي والترميز الموضعي

د. م. أوس غباش | إعداد: Dr.-Ing. Aouss Gabash

## Laboratory Objectives

- Prepare hourly load sequences for transformer regression.
- Create feature embeddings and positional embeddings.
- Use multi-head self-attention in MATLAB.
- Train a one-step-ahead forecasting model.
- Compare transformer, persistence, and optionally LSTM results.
- Visualize attention-compatible temporal behavior and errors.

## أهداف المخبر

- تجهيز متتاليات حمل ساعية للانحدار.
- إنشاء تمثيل للميزات والمواضع.
- استخدام الانتباه الذاتي متعدد الرؤوس في MATLAB.
- تدريب نموذج لتوقع الساعة التالية.
- مقارنته بخط الأساس و LSTM اختياريًا.
- تحليل النتائج والأخطاء.

## 1. Software Requirement

Use MATLAB R2023b or newer with Deep Learning Toolbox because this laboratory uses `selfAttentionLayer` and `positionEmbeddingLayer`.

### 1. متطلبات البرنامج

يتطلب المخبر MATLAB R2023b أو أحدث مع Deep Learning Toolbox.

## 2. Forecasting Task

$$[P_{t-47}, \dots, P_t] \rightarrow P_{t+1}$$

48-hour window

One-step ahead

Regression

### 2. مسألة التنبؤ

نستخدم آخر 48 ساعة لتوقع حمل الساعة التالية، مما يسمح للنموذج بمشاهدة نمط يومي متتاليين.

## 3. Complete MATLAB Script

```

%% Lab 10: Transformer Load Forecasting
% MATLAB R2023b or newer
clear; clc; close all;
rng(10);

%% 1) Generate hourly load data
nDays = 240;
N = 24*nDays;
t = (0:N-1)';
hour = mod(t,24);
day = floor(t/24);
dow = mod(day,7);

temperature = 17 ...
    + 9*sin(2*pi*(hour-14)/24) ...
    + 6*sin(2*pi*day/240) ...
    + 1.5*randn(N,1);

daily = 115 ...
    + 24*sin(2*pi*(hour-7)/24) ...
    + 9*sin(4*pi*(hour-5)/24);

weekly = 9*(dow < 5) - 8*(dow >= 5);
seasonal = 10*sin(2*pi*day/240);

loadMW = daily + weekly + seasonal ...
    + 0.8*max(temperature-23,0) ...
    + 0.45*max(11-temperature,0) ...
    + 2.2*randn(N,1);

%% 2) Create sequence-to-one samples
seqLen = 48;
numSamples = N-seqLen;

X = cell(numSamples,1);
Y = zeros(numSamples,1);

for k = 1:numSamples
    X{k} = loadMW(k:k+seqLen-1)';    % 1 x 48

```

```

        Y(k) = loadMW(k+seqLen);                % next hour
    end

%% 3) Chronological split
nTrain = floor(0.70*numSamples);
nVal    = floor(0.15*numSamples);

iTrain = 1:nTrain;
iVal    = nTrain+1:nTrain+nVal;
iTest   = nTrain+nVal+1:numSamples;

XTrain = X(iTrain); YTrain = Y(iTrain);
XVal    = X(iVal);   YVal    = Y(iVal);
XTest   = X(iTest);  YTest   = Y(iTest);

%% 4) Normalize using training data only
trainMatrix = cell2mat(XTrain);
mu = mean(trainMatrix,'all');
sigma = std(trainMatrix,0,'all');

XTrainN = cellfun(@(x)(x-mu)/sigma,XTrain, ...
    'UniformOutput',false);
XValN = cellfun(@(x)(x-mu)/sigma,XVal, ...
    'UniformOutput',false);
XTestN = cellfun(@(x)(x-mu)/sigma,XTest, ...
    'UniformOutput',false);

YTrainN = (YTrain-mu)/sigma;
YValN    = (YVal-mu)/sigma;

%% 5) Transformer architecture
numFeatures = 1;
embedDim = 32;
numHeads = 4;
ffnDim = 64;

layers = [
    sequenceInputLayer(numFeatures,Name="input")
    fullyConnectedLayer(embedDim,Name="projection")
    positionEmbeddingLayer(embedDim,seqLen,Name="position")

```

```

        additionLayer(2,Name="add_position")

        selfAttentionLayer(numHeads,embedDim, ...
            DropoutProbability=0.10,Name="attention")
        additionLayer(2,Name="add_attention")
        layerNormalizationLayer(Name="norm1")

        fullyConnectedLayer(ffnDim,Name="ffn1")
        reluLayer(Name="relu")
        dropoutLayer(0.10,Name="dropout")
        fullyConnectedLayer(embedDim,Name="ffn2")
        additionLayer(2,Name="add_ffn")
        layerNormalizationLayer(Name="norm2")

        globalAveragePooling1dLayer(Name="pool")
        fullyConnectedLayer(1,Name="forecast")
        regressionLayer(Name="output")
    ];

    lgraph = layerGraph(layers);

    % Residual and positional connections
    lgraph = connectLayers(lgraph,"projection","add_position/in2");
    lgraph = connectLayers(lgraph,"add_position","add_attention/in2");
    lgraph = connectLayers(lgraph,"norm1","add_ffn/in2");

%% 6) Training options
options = trainingOptions("adam", ...
    MaxEpochs=70, ...
    MiniBatchSize=64, ...
    InitialLearnRate=1e-3, ...
    GradientThreshold=1, ...
    Shuffle="never", ...
    ValidationData={XValN,YValN}, ...
    ValidationFrequency=30, ...
    ValidationPatience=8, ...
    Verbose=false, ...
    Plots="training-progress");

%% 7) Train network

```

```

net = trainNetwork(XTrainN,YTrainN,lgraph,options);

%% 8) Test prediction
YPredN = predict(net,XTestN,MiniBatchSize=64);
YPred = YPredN*sigma + mu;

%% 9) Persistence baseline
YPersistence = cellfun(@(x)x(end),XTest);

%% 10) Performance metrics
metric = @(yp,yt) [ ...
    mean(abs(yp-yt)), ...
    sqrt(mean((yp-yt).^2)), ...
    100*mean(abs((yp-yt)./yt)) ];

mBase = metric(YPersistence,YTest);
mTrans = metric(YPred,YTest);

Results = array2table([mBase;mTrans], ...
    VariableNames={"MAE_MW","RMSE_MW","MAPE_percent"}, ...
    RowNames={"Persistence","Transformer"});

disp(Results);

%% 11) Plot forecasts
nShow = min(240,numel(YTest));
figure;
plot(YTest(1:nShow),"k",LineWidth=1.35); hold on;
plot(YPersistence(1:nShow),"--",LineWidth=1.0);
plot(YPred(1:nShow),LineWidth=1.2);
grid on;
xlabel("Test Hour");
ylabel("Load (MW)");
legend("Actual","Persistence","Transformer", ...
    Location="best");
title("Transformer One-Step-Ahead Load Forecast");

%% 12) Error analysis
e = YPred-YTest;

```


```
figure;
histogram(e,30);
grid on;
xlabel("Prediction Error (MW)");
ylabel("Frequency");
title("Transformer Error Distribution");

figure;
scatter(YTest,YPred,10,"filled");
grid on; axis equal;
xlabel("Actual Load (MW)");
ylabel("Predicted Load (MW)");
title("Actual versus Predicted Load");
```

### 3. الكود الكامل

ينشئ الكود بيانات حمل، يبنّي نوافذ بطول 48 ساعة، يطبّعها اعتمادًا على التدريب فقط، ثم يبنّي Encoder صغيرًا بانتباه متعدد الرؤوس.

## 4. Network Structure



### 4. بنية الشبكة

تُرفع الإشارة من ميزة واحدة إلى 32 قناة، ثم يضاف الترميز الموضعي، وبعد الانتباه والشبكة الأمامية يجمع المتوسط الزمني التمثيل لإنتاج التوقع.

## 5. Residual Connections

$$y = \text{LayerNorm}(x + \text{Attention}(x))$$

$$z = \text{LayerNorm}(y + \text{FFN}(y))$$

The MATLAB graph explicitly connects the block input to the second input of each addition layer.

### 5. الوصلات المتبقية

تُجمع إشارة الدخل مع خرج الانتباه، ثم يُجمع خرج المرحلة الأولى مع خرج الشبكة الأمامية. تساعد هذه الوصلات على استقرار التدريب.

## 6. Important Hyperparameters



| Parameter           | Value | Meaning                       |
|---------------------|-------|-------------------------------|
| Sequence length     | 48    | Two days of hourly history    |
| Embedding dimension | 32    | Internal feature space        |
| Attention heads     | 4     | Four relationship subspaces   |
| FFN dimension       | 64    | Nonlinear processing capacity |
| Dropout             | 0.10  | Regularization                |

## 6. المعاملات المهمة

يمكن تغيير طول النافذة وبعد التمثيل وعدد الرؤوس وحجم الشبكة الأمامية ونسبة الإسقاط لدراسة أثرها في الدقة والكلفة.

## 7. Expected Behavior

- The transformer should learn the daily load cycle.
- It should usually outperform persistence when the load is changing.
- Validation loss should stop improving before training loss if overfitting begins.
- Peak hours may remain harder to predict.

A transformer is not automatically better than LSTM. Performance depends on data volume, window length, features, and tuning.

## 7. السلوك المتوقع

يُفترض أن يتعلم النموذج النمط اليومي، لكن التفوق على LSTM ليس مضمونًا، بل يعتمد على كمية البيانات والميزات والإعدادات.

## 8. Student Experiments

1. Test sequence lengths 24, 48, 72, and 168.
2. Test 1, 2, 4, and 8 attention heads.
3. Change embedding dimension from 32 to 64.
4. Add temperature and hour-of-day features.
5. Replace global average pooling with last-step indexing.
6. Compare with Lab 09 LSTM using identical data and splits.

## 8. تجارب الطالب

1. جرّب نوافذ 24 و 48 و 72 و 168 ساعة.
2. جرّب 1 و 2 و 4 و 8 رؤوس.
3. غيّر بعد التمثيل من 32 إلى 64.
4. أضف الحرارة والساعة كميزات.
5. قارن التجميع المتوسط باستخدام آخر خطوة.
6. قارن النتائج مباشرة مع LSTM في المخبر 09.

## 9. Mini Project

**Day-ahead forecasting:** Modify the model to output the next 24 hourly loads. The final fully connected layer must output 24 values, and each target must be a 24-element vector.

## 9. مشروع مصغر

حوّل النموذج من توقع ساعة واحدة إلى توقع اليوم التالي كاملاً، بحيث ينتج 24 قيمة حمل دفعة واحدة.

## 10. Laboratory Report

- Explain Q, K, V in the context of hourly load.
- Draw the network architecture.
- Report MAE, RMSE, and MAPE.
- Compare transformer and persistence.
- Compare transformer and LSTM.
- Discuss accuracy, training cost, and overfitting.

## 10. تقرير المخبر

يجب أن يتضمن تفسير Q و K و V، رسم البنية، مؤشرات الخطأ، مقارنة Transformer بخط الأساس و LSTM، ومناقشة الدقة والكلفة وفرط التخصيص.