

LAB 11 | المخبر 11

Graph Neural Network for State Estimation

شبكة عصبية بيانية لتقدير حالة شبكة كهربائية

A Transparent MATLAB Implementation on a Six-Bus System

تنفيذ واضح في MATLAB على شبكة من ستة قضبان

[Network](#)[Model](#)[Workflow](#)[MATLAB Code](#)[Results](#)[Tasks](#)

Prepared by | إعداد: Dr.-Ing. Aouss Gabash


Laboratory Objectives

- Represent a six-bus power network as a graph.
- Construct adjacency, degree, and normalized adjacency matrices.
- Generate synthetic operating points using DC power flow.
- Implement a two-layer GCN manually in MATLAB.
- Train the GCN to estimate voltage angles.
- Evaluate error by bus and discuss topology awareness.

أهداف المخبر

- تمثيل شبكة من ستة قضبان كرسم بياني.
- بناء مصفوفات المجاورة والدرجة والمجاورة المطبقة.
- إنشاء حالات تشغيل اصطناعية باستخدام تدفق القدرة المستمر.
- تنفيذ GCN من طبقتين يدويًا في MATLAB.
- تدريبها لتقدير زوايا الجهد.
- تقييم الخطأ لكل قضيب ومناقشة أثر الطوبولوجيا.

1. Six-Bus Graph



Bus 1 is the slack bus. Noisy active-power injections are node features, while true voltage angles are training targets.

1. الرسم البياني للشبكة

يستخدم القضيبي 1 كمرجع، وتمثل حقن القدرة المشوبة بالضجيج ميزات العقد، بينما تمثل زوايا الجهد الصحيحة أهداف التدريب.

2. Mathematical Model

$$P = B_{bus}\theta$$

$$\theta_{red} = B_{red} - 1P_{red}$$

$$S = D^{\sim} - 1/2(A + I)D^{\sim} - 1/2$$

$$H(1) = ReLU(SXW1 + b1)$$


$$\hat{Y} = SH(1)W2 + b2$$

The normalized adjacency matrix mixes each bus feature with neighboring buses before the learned feature transformation.

2. النموذج الرياضي

يولد نموذج DC زوايا الجهد الصحيحة، بينما تستخدم GCN مصفوفة المجاورة المطبقة لنقل المعلومات بين القضبان المتجاورة.

3. Engineering Workflow



1. Construct A , $\tilde{D}$, S , and B_{bus} .
2. Generate balanced active-power injections.
3. Compute exact DC angles.
4. Add measurement noise.
5. Train with Adam and validation monitoring.
6. Evaluate MAE, RMSE, and bus-wise errors.

3. سير العمل الهندسي

نبنى الرسم البياني ونولد البيانات ونطبعها، ثم ندرّب النموذج ونقيم الدقة والاتساق الفيزيائي.

4. Complete MATLAB Script

```

%% Lab 11: Manual GCN for Six-Bus State Estimation
clear; clc; close all; rng(11);

%% 1) Graph topology
N = 6;
edges = [1 2; 1 3; 2 4; 3 4; 3 5; 4 6; 5 6];
A = zeros(N);
for k = 1:size(edges,1)
    i = edges(k,1); j = edges(k,2);
    A(i,j) = 1; A(j,i) = 1;
end
Atilde = A + eye(N);
Dtilde = diag(sum(Atilde,2));
S = Dtilde^(-0.5)*Atilde*Dtilde^(-0.5);

%% 2) DC susceptance matrix
x = [0.18 0.22 0.20 0.25 0.30 0.17 0.21]';
b = 1./x;
Bbus = zeros(N);
for k = 1:size(edges,1)
    i = edges(k,1); j = edges(k,2);
    Bbus(i,i)=Bbus(i,i)+b(k); Bbus(j,j)=Bbus(j,j)+b(k);
    Bbus(i,j)=Bbus(i,j)-b(k); Bbus(j,i)=Bbus(j,i)-b(k);
end
slack = 1; nonSlack = 2:N;
Bred = Bbus(nonSlack,nonSlack);

%% 3) Generate samples
numSamples = 5000;
X = zeros(N,1,numSamples);
Y = zeros(N,1,numSamples);
for s = 1:numSamples
    P = zeros(N,1);
    P(nonSlack) = 0.35*randn(N-1,1);
    P(slack) = -sum(P(nonSlack));
    theta = zeros(N,1);
    theta(nonSlack) = Bred\P(nonSlack);
    X(:,:,s) = P + 0.02*randn(N,1);
    Y(:,:,s) = theta;
end

%% 4) Split and normalize
nTrain = 3500; nVal = 750;
iTrain = 1:nTrain;
iVal = nTrain+1:nTrain+nVal;

```

```

iTest = nTrain+nVal+1:numSamples;
XTrain=X(:,:,iTrain); YTrain=Y(:,:,iTrain);
XVal=X(:,:,iVal); YVal=Y(:,:,iVal);
XTest=X(:,:,iTest); YTest=Y(:,:,iTest);
muX=mean(XTrain,'all'); sigX=std(XTrain,0,'all');
muY=mean(YTrain,'all'); sigY=std(YTrain,0,'all');
XTrainN=(XTrain-muX)/sigX; XValN=(XVal-muX)/sigX;
XTestN=(XTest-muX)/sigX; YTrainN=(YTrain-muY)/sigY;
YValN=(YVal-muY)/sigY;

%% 5) Parameters
Fhidden = 16;
W1=dlarray(0.15*randn(1,Fhidden)); b1=dlarray(zeros(1,Fhidden));
W2=dlarray(0.15*randn(Fhidden,1)); b2=dlarray(0);
avgW1=[]; avgSqW1=[]; avgb1=[]; avgSqb1=[];
avgW2=[]; avgSqW2=[]; avgb2=[]; avgSqb2=[];
numEpochs=180; learnRate=2e-3; miniBatchSize=64; iteration=0;
trainLoss=zeros(numEpochs,1); valLoss=zeros(numEpochs,1);

%% 6) Training
for epoch=1:numEpochs
    order=randperm(nTrain); epochLoss=0; nBatches=0;
    for startIdx=1:miniBatchSize:nTrain
        iteration=iteration+1;
        idx=order(startIdx:min(startIdx+miniBatchSize-1,nTrain));
        xb=dlarray(XTrainN(:,:,idx),'SCB');
        yb=dlarray(YTrainN(:,:,idx),'SCB');
        [loss,g]=dlfeval(@modelGradients,xb,yb,S,W1,b1,W2,b2);

        [W1,avgW1,avgSqW1]=adamupdate(W1,g.W1,avgW1,avgSqW1,iteration,learnRate);

        [b1,avgb1,avgSqb1]=adamupdate(b1,g.b1,avgb1,avgSqb1,iteration,learnRate);

        [W2,avgW2,avgSqW2]=adamupdate(W2,g.W2,avgW2,avgSqW2,iteration,learnRate);

        [b2,avgb2,avgSqb2]=adamupdate(b2,g.b2,avgb2,avgSqb2,iteration,learnRate);
        epochLoss=epochLoss+double(gather(extractdata(loss)));
    nBatches=nBatches+1;
    end
    trainLoss(epoch)=epochLoss/nBatches;
    yv=gcnnForward(dlarray(XValN,'SCB'),S,W1,b1,W2,b2);
    valLoss(epoch)=mean((extractdata(yv)-YValN).^2,'all');
end

%% 7) Testing

```

```

YPredN=gcnForward(dlarray(XTestN,'SCB'),S,W1,b1,W2,b2);
YPred=extractdata(YPredN)*sigY+muY;
YPred(1,:,:)=0;
err=YPred-YTest;
MAE=mean(abs(err),'all');
RMSE=sqrt(mean(err.^2,'all'));
fprintf('Test MAE = %.6f rad\n',MAE);
fprintf('Test RMSE = %.6f rad\n',RMSE);

figure; semilogy(trainLoss,'LineWidth',1.3); hold on;
semilogy(valLoss,'LineWidth',1.3); grid on;
legend('Training','Validation'); xlabel('Epoch'); ylabel('MSE');

sample=25;
figure; stem(1:N,YTest(:,:,sample),'filled'); hold on;
stem(1:N,YPred(:,:,sample)); grid on;
legend('True','GCN Estimate'); xlabel('Bus'); ylabel('Angle (rad)');

busRMSE=squeeze(sqrt(mean(err.^2,3)));
figure; bar(1:N,busRMSE); grid on;
xlabel('Bus'); ylabel('RMSE (rad)');

%% Local functions
function Y=gcnForward(X,S,W1,b1,W2,b2)
    B=size(X,3);
    Sdl=dlarray(repmat(S,1,1,B),'SSB');
    H=relu(pagemtimes(pagemtimes(Sdl,X),W1)+reshape(b1,1,[],1));
    Y=pagemtimes(pagemtimes(Sdl,H),W2)+reshape(b2,1,1,1);
end

function [loss,g]=modelGradients(X,T,S,W1,b1,W2,b2)
    Y=gcnForward(X,S,W1,b1,W2,b2);
    loss=mean((Y-T).^2,'all');
    [g.W1,g.b1,g.W2,g.b2]=dlgradient(loss,W1,b1,W2,b2);
end

```

Requires Deep Learning Toolbox because the script uses `dlarray`, `dlfeval`, `dlgradient`, and `adamupdate`.

4. كود MATLAB الكامل

ينشئ الكود الشبكة والبيانات، ثم يدرب GCN يدويًا باستخدام الاشتقاق التلقائي وخوارزمية Adam.

5. Expected Results and Validation

Learning Curves

Training and validation losses should decrease without large divergence.

Angle Reconstruction

Estimated bus angles should follow the DC targets closely.

Bus-wise Error

Higher errors may appear at weakly connected or electrically remote buses.

Physical Check

Bus 1 angle must remain exactly zero.

$$MAE = \text{mean}(|\hat{\theta} - \theta|), RMSE = \sqrt{\text{mean}[(\hat{\theta} - \theta)^2]}$$

A low test error is insufficient if the model is evaluated only on the same topology and noise level used during training.

5. النتائج المتوقعة والتحقق

يجب انخفاض خسارتي التدريب والتحقق، وتقارب الزوايا المقدرة من القيم الصحيحة، مع تثبيت زاوية القضيبي المرجعي عند الصفر.

6. Student Tasks

1. Increase measurement noise from 0.02 to 0.05 and compare RMSE.
2. Remove line 3-4 and test the trained model without retraining.
3. Change the hidden width from 16 to 8 and 32.
4. Compare one and three graph-convolution layers.
5. Replace the GCN with a topology-blind MLP.
6. Report global and bus-wise errors.

6. مهام الطالب

1. زيادة ضجيج القياس ومقارنة الخطأ.
2. فصل الخط 3-4 واختبار النموذج دون إعادة تدريب.
3. تغيير عدد العصبونات المخفية.
4. مقارنة عدد طبقات الالتفاف البياني.
5. استبدال GCN بشبكة MLP لا تستخدم الطوبولوجيا.
6. عرض الخطأ الكلي والخطأ لكل قضيبي.



Research Extension

Possible extensions: AC state estimation, PMU and SCADA fusion, topology uncertainty, graph attention, bad-data detection, physics-informed losses, and transfer to unseen grids.

امتداد بحثي

يمكن توسيع المخبر إلى تقدير AC ودمج PMU وSCADA وعدم يقين الطوبولوجيا والانتباه البياني وكشف البيانات السيئة.



Review Questions

1. Why are self-loops added to the adjacency matrix?
2. Why is normalized adjacency used?
3. What information does one GCN layer collect?
4. Why must the slack angle be enforced?
5. What causes topology generalization failure?
6. How would AC state estimation change the targets?

أسئلة المراجعة

1. لماذا تضاف الوصلات الذاتية؟
2. لماذا نستخدم المجاورة المطبقة؟
3. ما المعلومات التي تجمعها طبقة GCN واحدة؟

4. لماذا يجب تثبيت زاوية المرجع؟

5. ما سبب فشل التعميم عند تغير الطوبولوجيا؟

6. كيف يتغير المخبر عند استخدام تقدير AC؟

المراجع | References

المراجع العامة المستخدمة في هذا المقرر

[1] A. Gabash, *Flexible Optimal Operations of Energy Supply Networks with Renewable Energy Generation and Battery Storage*. Saarbrücken, Germany: Südwestdeutscher Verlag für Hochschulschriften, 2014.

[2] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th Global ed. Harlow, U.K.: Pearson Education Limited, 2022.

[3] A. Gabash, “Energy Market Transition and Climate Change: A Review of TSOs-DSOs C+++ Framework from 1800 to Present,” *Energies*, vol. 16, no. 17, Art. no. 6139, 2023, doi: 10.3390/en16176139.

[4] A. Gabash, *AI Applications in Electrical Power Systems*, Version 1.0, 2026. [Online]. Available: <https://aoussgabash.com>

معلومات النشر | Publication Information

Document	Laboratory 11 · Graph Neural Network for State Estimation
Course	AI Applications in Electrical Power Systems
Author	Dr.-Ing. Aouss Gabash
Version	1.0
Publication year	2026
Official website	https://aoussgabash.com
Citation style	IEEE

Recommended citation:
Gabash, A. (2026). Graph Neural Network for State Estimation. AI Applications in Electrical Power Systems, Laboratory 11, Version 1.0. <https://aoussgabash.com>

المرجع المقترح:

أوس غباش، 2026، مخبر 11، تطبيقات الذكاء الاصطناعي في أنظمة الطاقة الكهربائية، الإصدار 1.0، <https://aoussgabash.com>

© 2026 Dr.-Ing. Aouss Gabash. Educational use with attribution to the author and official website.