

LAB 13 | المخبر 13

Explaining a Load-Forecasting Model

تفسير نموذج للتنبؤ بالحمل الكهربائي

MATLAB Laboratory Using Feature Importance, SHAP, LIME, and Partial Dependence

مخبر MATLAB باستخدام أهمية الميزات و SHAP و LIME والاعتماد الجزئي

Data

Model

Workflow

MATLAB Code

Interpretation

Tasks

Prepared by | إعداد: Dr.-Ing. Aouss Gabash

Laboratory Objectives

- Train a nonlinear ensemble for next-hour load prediction.
- Compute global feature importance.
- Explain one forecast using SHAP and LIME.
- Visualize partial dependence.
- Compare global and local explanations.
- Evaluate explanation stability and physical plausibility.

أهداف المخبر

- تدريب نموذج انحدار غير خطي لتوقع حمل الساعة التالية.
- حساب الأهمية العامة للميزات.
- تفسير توقع باستخدام SHAP و LIME.
- رسم الاعتماد الجزئي.
- مقارنة التفسير العام والمحلي.
- تقييم استقرار التفسير واتساقه الفيزيائي.

1. Requirements

- MATLAB
- Statistics and Machine Learning Toolbox

The optional `permutationImportance` section requires MATLAB R2024a or newer.

1. المتطلبات

يلزم MATLAB مع Statistics and Machine Learning Toolbox، وتتطلب دالة `permutationImportance` إصدار R2024a أو أحدث.

2. Predictors

LoadLag1

Previous-hour load.

LoadLag24

Load at the same hour yesterday.

Temperature

Weather influence.

Hour

Daily cycle.

Weekday

Working-day effect.

PV

Distributed generation effect.

$$\hat{y}_{t+1} = f(L_t, L_{t-23}, T_t, Hour_t, Weekday_t, PV_t)$$

2. الميزات

يستخدم النموذج الحمل السابق وحمل اليوم السابق والحرارة والساعة ويوم العمل والإنتاج الشمسي.

3. Model and Explanation Methods

Boosted Trees

Capture nonlinear interactions.

Global Importance

Ranks predictors over the dataset.

SHAP

Allocates one prediction among features.

LIME

Fits a local surrogate near one query.

PDP

Shows average model response.

Permutation


Measures loss increase after disruption.

Feature importance and attribution describe model behavior; they do not prove causality.

3. النموذج وطرق التفسير

تستخدم أشجار التعزيز للتنبؤ، ثم تطبق طرق عامة ومحلية لفهم سلوك النموذج دون ادعاء السببية.

4. Engineering Workflow



1. Create chronological hourly data.
2. Build lagged and contextual predictors.
3. Use a chronological train-test split.
4. Evaluate forecasting accuracy.
5. Generate global and local explanations.
6. Check stability, correlation effects, and engineering plausibility.

4. سير العمل الهندسي

ننشئ البيانات والميزات الزمنية، ثم ندرب النموذج ونفسر النتائج ونتحقق من استقرارها ومنطقها الهندسي.

5. Complete MATLAB Script

```

%% Lab 13: Explainable AI for Load Forecasting
clear; clc; close all; rng(13);

%% 1) Synthetic hourly data
nDays = 220; N = 24*nDays; t = (0:N-1)';
Hour = mod(t,24); Day = floor(t/24);
Weekday = double(mod(Day,7) < 5);
Temperature = 18 + 8*sin(2*pi*(Hour-14)/24) ...
    + 5*sin(2*pi*Day/nDays) + 1.2*randn(N,1);
PV = max(0,18*sin(pi*(Hour-6)/12));
PV = PV.*(0.75+0.20*rand(N,1));
BaseLoad = 110 + 24*sin(2*pi*(Hour-7)/24) ...
    + 8*sin(4*pi*(Hour-5)/24);
Load = BaseLoad + 9*Weekday ...
    + 0.9*max(Temperature-23,0) ...
    + 0.5*max(11-Temperature,0) ...
    - 0.30*PV + 2.5*randn(N,1);

%% 2) Lagged predictors
LoadLag1 = [NaN; Load(1:end-1)];
LoadLag24 = [NaN(24,1); Load(1:end-24)];
Target = [Load(2:end); NaN];
T = rmmissing(table(LoadLag1,LoadLag24,Temperature, ...
    Hour,Weekday,PV,Target));

%% 3) Chronological split
n = height(T); nTrain = floor(0.70*n);
TTrain = T(1:nTrain,:); TTest = T(nTrain+1:end,:);
predictorNames = ["LoadLag1","LoadLag24","Temperature", ...
    "Hour","Weekday","PV"];

%% 4) Train boosted-tree ensemble
Mdl = fitensemble(TTrain,"Target", ...
    Method="LSBoost",NumLearningCycles=250, ...
    Learners=templateTree(MaxNumSplits=20), ...
    PredictorNames=predictorNames);

%% 5) Accuracy
YPred = predict(Mdl,TTest); YTrue = TTest.Target;
MAE = mean(abs(YPred-YTrue));
RMSE = sqrt(mean((YPred-YTrue).^2));
MAPE = 100*mean(abs((YPred-YTrue)./YTrue));
fprintf("MAE = %.3f MW\n",MAE);
fprintf("RMSE = %.3f MW\n",RMSE);
fprintf("MAPE = %.3f %%\n",MAPE);

```

```

figure; plot(YTrue(1:240),"k",LineWidth=1.3); hold on;
plot(YPred(1:240),LineWidth=1.2); grid on;
legend("Actual","Predicted"); xlabel("Test Hour"); ylabel("Load (MW)");

%% 6) Global importance
impTree = predictorImportance(Mdl);
figure; bar(categorical(predictorNames),impTree); grid on;
ylabel("Predictor Importance"); title("Global Importance");

%% 7) Optional permutation importance
try
    impPerm = permutationImportance(Mdl,TTest,"Target", ...
        NumPermutations=20);
    figure; bar(categorical(impPerm.Predictor), ...
        impPerm.ImportanceMean); grid on;
    ylabel("Increase in Loss"); title("Permutation Importance");
catch ME
    warning("Permutation importance skipped: %s",ME.message);
end

%% 8) Local query
queryIndex = 80;
queryPoint = TTest(queryIndex,predictorNames);
queryPrediction = predict(Mdl,queryPoint);
fprintf("Query prediction = %.3f MW\n",queryPrediction);

%% 9) SHAP
explainerSHAP = shapley(Mdl,TTrain(:,predictorNames), ...
    QueryPoint=queryPoint);
figure; plot(explainerSHAP); title("SHAP Explanation");

%% 10) LIME
explainerLIME = lime(Mdl,queryPoint,6);
figure; plot(explainerLIME); title("LIME Explanation");

%% 11) Partial dependence
figure; plotPartialDependence(Mdl,"Temperature",TTrain);
grid on; title("Partial Dependence on Temperature");
figure; plotPartialDependence(Mdl,"Hour",TTrain);
grid on; title("Partial Dependence on Hour");

%% 12) Manual permutation importance
XTest = TTest(:,predictorNames);
baseLoss = mean((predict(Mdl,XTest)-YTrue).^2);

```

```

manualImp = zeros(numel(predictorNames),1);
for j = 1:numel(predictorNames)
    Xp = XTest;
    Xp.(predictorNames(j)) = ...
        Xp.(predictorNames(j))(randperm(height(Xp))));
    manualImp(j) = mean((predict(Mdl,Xp)-YTrue).^2)-baseLoss;
end
figure; bar(categorical(predictorNames),manualImp); grid on;
ylabel("Increase in MSE"); title("Manual Permutation Importance");

```

5. كود MATLAB الكامل

ينشئ الكود بيانات حمل اصطناعية، ويدرب نموذج أشجار معززة، ثم يطبق أهمية الميزات و SHAP و LIME و PDP وأهمية التبدل.

6. Interpreting the Results

Global View

LoadLag1 and LoadLag24 should usually dominate.

Local View

SHAP and LIME explain one operating hour.

Temperature

Importance rises at heating and cooling extremes.

Hour

Captures the daily demand cycle.

Weekday

Shifts baseline demand.

PV

Tends to reduce net load.

$$Prediction = Baseline + \sum FeatureContributions$$

Correlated features can split or redistribute importance, and PDP can evaluate unrealistic combinations.

6. تفسير النتائج

يفترض أن يهيمن الحمل السابق، بينما تكشف الطرق المحلية مساهمة كل ميزة في ساعة محددة، مع ضرورة الحذر من الترابط بين الميزات.

7. Validation Checklist

- Check MAE, RMSE, and MAPE on chronological test data.
- Repeat LIME and SHAP for several query points.
- Compare explanations for peak and off-peak hours.
- Test sensitivity to SHAP background data.
- Inspect correlated-feature effects.
- Compare explanation direction with engineering expectations.

An explanation should be quantitatively stable and physically plausible, not merely visually attractive.

7. قائمة التحقق

يجب فحص الدقة والاستقرار والحساسية لبيانات الخلفية والترابط، ثم مقارنة التفسير مع المعرفة الهندسية.

8. Student Tasks

1. Explain a low-load night and a high-load evening peak.
2. Compare SHAP and LIME stability across repeated runs.
3. Add a holiday feature.
4. Remove LoadLag1 and retrain.
5. Create a correlated copy of Temperature.
6. Change SHAP background data.
7. Compare tree importance with permutation importance.

8. مهام الطالب

1. تفسير حالة ليلية منخفضة وقمة مسائية.
2. مقارنة استقرار SHAP و LIME.
3. إضافة ميزة عطلة.

4. حذف LoadLag1 وإعادة التدريب.
5. إنشاء نسخة مترابطة من الحرارة.
6. تغيير بيانات خلفية SHAP.
7. مقارنة أهمية الأشجار مع أهمية التبديل.



Research Extension

Explainable peak-warning system: build a classifier for next-hour peak risk, compare SHAP and counterfactual explanations, and assess explanation drift under changing weather and load patterns.

امتداد بحثي

أنشئ نظام إنذار للقيمة القادمة، وقارن SHAP مع التفسيرات المضادة للواقع، وادرس انجراف التفسير مع تغير الطقس والحمل.



Review Questions

1. What is the difference between global and local explanations?
2. How does permutation importance work?
3. What does a positive SHAP value mean?
4. Why can LIME be unstable?
5. Why can correlated features distort attribution?
6. What is the main limitation of PDP?
7. Why is explanation not causality?

أسئلة المراجعة

1. ما الفرق بين التفسير العام والمحلي؟
2. كيف تعمل أهمية التبديل؟
3. ماذا تعني قيمة SHAP الموجبة؟
4. لماذا قد يكون LIME غير مستقر؟
5. كيف تشوه الميزات المترابطة توزيع المساهمات؟
6. ما القيد الرئيس لـ PDP؟
7. لماذا لا يعد التفسير سببية؟

References | المراجع

المراجع العامة المستخدمة في هذا المقرر

[1] A. Gabash, *Flexible Optimal Operations of Energy Supply Networks with Renewable Energy Generation and Battery Storage*. Saarbrücken, Germany: Südwestdeutscher Verlag für Hochschulschriften, 2014.

[2] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th Global ed. Harlow, U.K.: Pearson Education Limited, 2022.

[3] A. Gabash, "Energy Market Transition and Climate Change: A Review of TSOs-DSOs C+++ Framework from 1800 to Present," *Energies*, vol. 16, no. 17, Art. no. 6139, 2023, doi: 10.3390/en16176139.

[4] A. Gabash, *AI Applications in Electrical Power Systems*, Version 1.0, 2026. [Online]. Available: <https://aoussgabash.com>

Publication Information | معلومات النشر

Document	Laboratory 13 · Explaining a Load-Forecasting Model
Course	AI Applications in Electrical Power Systems
Author	Dr.-Ing. Aouss Gabash
Version	1.0
Publication year	2026
Official website	https://aoussgabash.com
Citation style	IEEE

Recommended citation:

Gabash, A. (2026). Explaining a Load-Forecasting Model. AI Applications in Electrical Power Systems, Laboratory 13, Version 1.0. <https://aoussgabash.com>

المرجع المقترح:

أوس غباش، 2026، مخبر 13، تطبيقات الذكاء الاصطناعي في أنظمة الطاقة الكهربائية، الإصدار 1.0، <https://aoussgabash.com>

© 2026 Dr.-Ing. Aouss Gabash. Educational use with attribution to the author and official website.