

LAB 13 | المخبر 13

Explaining a Load-Forecasting Model

تفسير نموذج للتنبؤ بالحمل الكهربائي

MATLAB laboratory using feature importance, SHAP, LIME, and partial dependence

مخبر MATLAB باستخدام أهمية الميزات و SHAP و LIME والاعتماد الجزئي

Laboratory Objectives

- Train a nonlinear regression ensemble for next-hour load prediction.
- Compute global predictor importance.
- Explain one forecast using SHAP.
- Explain the same forecast using LIME.
- Visualize partial dependence.
- Compare global and local explanations.

أهداف المخبر

- تدريب نموذج انحدار غير خطي لتوقع الحمل.
- حساب الأهمية العامة للميزات.
- تفسير توقع باستخدام SHAP.
- تفسيره باستخدام LIME.
- رسم الاعتماد الجزئي.
- مقارنة التفسير العام والمحلي.

1. Requirements

- MATLAB
- Statistics and Machine Learning Toolbox

The optional `permutationImportance` section requires MATLAB R2024a or newer. The remaining sections can use model-specific importance, SHAP, LIME, and partial dependence.

1. المتطلبات

يلزم MATLAB مع Statistics and Machine Learning Toolbox. تتطلب دالة permutationImportance إصدار R2024a أو أحدث.

2. Predictors

LoadLag1

Previous-hour load.

LoadLag24

Load at the same hour
yesterday.

Temperature

Weather influence.

Hour

Daily cycle.

Weekday

Working-day effect.

PV

Distributed generation
effect.

2. الميزات

يستخدم النموذج الحمل السابق وحمل اليوم السابق والحرارة والساعة ويوم العمل والإنتاج الشمسي.

3. Complete MATLAB Script

```

%% Lab 13: Explainable AI for Load Forecasting
clear; clc; close all;
rng(13);

%% 1) Generate synthetic hourly data
nDays = 220;
N = 24*nDays;
t = (0:N-1)';

Hour = mod(t,24);
Day = floor(t/24);
Weekday = double(mod(Day,7) < 5);

Temperature = 18 ...
    + 8*sin(2*pi*(Hour-14)/24) ...
    + 5*sin(2*pi*Day/nDays) ...
    + 1.2*randn(N,1);

PV = max(0,18*sin(pi*(Hour-6)/12));
PV = PV.*(0.75+0.20*rand(N,1));

BaseLoad = 110 ...
    + 24*sin(2*pi*(Hour-7)/24) ...
    + 8*sin(4*pi*(Hour-5)/24);

Load = BaseLoad ...
    + 9*Weekday ...
    + 0.9*max(Temperature-23,0) ...
    + 0.5*max(11-Temperature,0) ...
    - 0.30*PV ...
    + 2.5*randn(N,1);

%% 2) Build lagged predictors
LoadLag1 = [NaN; Load(1:end-1)];
LoadLag24 = [NaN(24,1); Load(1:end-24)];
Target = [Load(2:end); NaN];

T = table(LoadLag1,LoadLag24,Temperature,Hour, ...
    Weekday,PV,Target);

T = rmmissing(T);

%% 3) Chronological split
n = height(T);
nTrain = floor(0.70*n);

```

```

nTest = n-nTrain;

TTrain = T(1:nTrain,:);
TTest = T(nTrain+1:end,:);

predictorNames = ...
    ["LoadLag1","LoadLag24","Temperature", ...
    "Hour","Weekday","PV"];

%% 4) Train nonlinear regression ensemble
Mdl = fitrensemble(TTrain, ...
    "Target", ...
    Method="LSBoost", ...
    NumLearningCycles=250, ...
    Learners=templateTree(MaxNumSplits=20), ...
    PredictorNames=predictorNames);

%% 5) Test accuracy
YPred = predict(Mdl,TTest);
YTrue = TTest.Target;

MAE = mean(abs(YPred-YTrue));
RMSE = sqrt(mean((YPred-YTrue).^2));
MAPE = 100*mean(abs((YPred-YTrue)./YTrue));

fprintf("MAE = %.3f MW\n",MAE);
fprintf("RMSE = %.3f MW\n",RMSE);
fprintf("MAPE = %.3f %%\n",MAPE);

figure;
plot(YTrue(1:240),"k",LineWidth=1.3); hold on;
plot(YPred(1:240),LineWidth=1.2);
grid on;
xlabel("Test Hour");
ylabel("Load (MW)");
legend("Actual","Predicted");
title("Load Forecasting Model");

%% 6) Model-specific global importance
impTree = predictorImportance(Mdl);

figure;
bar(categorical(predictorNames),impTree);
grid on;
ylabel("Predictor Importance");

```

```

title("Global Tree-Ensemble Importance");

%% 7) Optional permutation importance (R2024a+)
try
    impPerm = permutationImportance( ...
        Mdl,TTest,"Target", ...
        NumPermutations=20);

    disp(impPerm);

    figure;
    bar(categorical(impPerm.Predictor), ...
        impPerm.ImportanceMean);
    grid on;
    ylabel("Increase in Loss");
    title("Permutation Importance");
catch ME
    warning("Permutation importance skipped: %s",ME.message);
end

%% 8) Select one query point
queryIndex = 80;
queryPoint = TTest(queryIndex,predictorNames);
queryPrediction = predict(Mdl,queryPoint);

fprintf("\nQuery prediction = %.3f MW\n",queryPrediction);
disp(queryPoint);

%% 9) SHAP explanation
explainerSHAP = shapley(Mdl,TTrain(:,predictorNames), ...
    QueryPoint=queryPoint);

figure;
plot(explainerSHAP);
title("SHAP Explanation for One Load Forecast");

disp(explainerSHAP.ShapleyValues);

%% 10) LIME explanation
explainerLIME = lime(Mdl,queryPoint,6);

figure;
plot(explainerLIME);
title("LIME Explanation for the Same Forecast");

```

```
%% 11) Partial dependence
figure;
plotPartialDependence(Mdl,"Temperature",TTrain);
grid on;
title("Partial Dependence on Temperature");

figure;
plotPartialDependence(Mdl,"Hour",TTrain);
grid on;
title("Partial Dependence on Hour");

%% 12) Manual permutation importance
XTest = TTest(:,predictorNames);
basePred = predict(Mdl,XTest);
baseLoss = mean((basePred-YTrue).^2);

manualImp = zeros(numel(predictorNames),1);

for j = 1:numel(predictorNames)
    Xp = XTest;
    Xp.(predictorNames(j)) = ...
        Xp.(predictorNames(j))(randperm(height(Xp))));

    predPerm = predict(Mdl,Xp);
    permLoss = mean((predPerm-YTrue).^2);
    manualImp(j) = permLoss-baseLoss;
end

figure;
bar(categorical(predictorNames),manualImp);
grid on;
ylabel("Increase in MSE");
title("Manual Permutation Importance");
```


3. الكود الكامل

ينشئ الكود بيانات حمل، ويدرب نموذج Boosted Trees، ثم يطبق الأهمية العامة و SHAP و LIME و PDP وأهمية التبديل اليدوية.

4. Why Use a Tree Ensemble?

A boosted-tree model captures nonlinear interactions while remaining compatible with several MATLAB explanation tools.

The aim is not to claim that trees are always the best forecasting model, but to create a transparent XAI laboratory.

4. لماذا نستخدم نموذج أشجار؟

يلتقط العلاقات اللاخطية ويتوافق مع عدة أدوات تفسير، لذلك يناسب الغرض التعليمي للمخبر.

5. Global Importance

Global importance answers: "Which predictors matter most across the test set?"

- Tree importance reflects the ensemble structure.
- Permutation importance reflects loss increase after feature disruption.

5. الأهمية العامة

تجيب عن سؤال: ما الميزات الأهم للنموذج عبر كامل البيانات؟ ويمكن أن تختلف طريقة الأشجار عن طريقة التبديل.

6. SHAP Interpretation

$$Prediction = Baseline + \sum FeatureContributions$$

For the selected hour, inspect which predictors increased or reduced the forecast relative to the baseline.

6. تفسير SHAP

يوضح الرسم كيف رفعت أو خفضت كل ميزة التنبؤ مقارنة بالقيمة الأساسية.

7. LIME Interpretation

LIME fits a simple local model around the query point. Compare the signs and rankings with SHAP.

Disagreement does not automatically mean one method is wrong; the methods make different approximations.

7. تفسير LIME

يبنى LIME نموذجًا بسيطًا قرب العينة المحددة. قارن اتجاهات وترتيب الميزات مع SHAP.

8. Partial Dependence

Temperature PDP should often show increased load under strong heating or cooling demand. Hour PDP should reveal the daily pattern.

PDP can evaluate feature combinations that are rare or unrealistic when predictors are correlated.

8. الاعتماد الجزئي

قد يظهر منحنى الحرارة زيادة الحمل عند التدفئة أو التبريد، بينما يكشف منحنى الساعة النمط اليومي. لكن الارتباط قد ينتج حالات غير واقعية.

9. Expected Findings

- LoadLag1 and LoadLag24 are usually dominant.
- Hour captures daily structure.
- Temperature matters more at extreme values.
- Weekday changes the baseline demand.
- PV tends to reduce net load.

9. النتائج المتوقعة

غالبًا يكون الحمل السابق وحمل اليوم السابق الأكثر أهمية، وتظهر الساعة النمط اليومي، وتزداد أهمية الحرارة عند القيم المتطرفة.

10. Student Experiments

1. Explain a low-load night and a high-load evening peak.
2. Compare SHAP and LIME stability across repeated runs.
3. Add a holiday feature.
4. Remove LoadLag1 and retrain.
5. Create correlated copies of Temperature and inspect attribution.
6. Change the background data used by SHAP.

10. تجارب الطالب

1. فسر حالة ليلية منخفضة وقمة مسائية.
2. قارن استقرار SHAP و LIME.
3. أضف ميزة عطلة.
4. احذف LoadLag1 وأعد التدريب.
5. أنشئ نسخة مترابطة من الحرارة.
6. غيّر بيانات الخلفية لـ SHAP.

11. Mini Project

Explainable peak-warning system: Build a classifier that predicts whether the next-hour load will exceed a threshold, then explain false alarms and missed peaks using SHAP and LIME.

11. مشروع مصغر

ابنِ مصنعاً لتحذير القمم، ثم فسّر الإنذارات الكاذبة والقمم الفائتة باستخدام SHAP و LIME.

12. Laboratory Report

- Report forecasting accuracy.
- Compare tree and permutation importance.
- Explain two contrasting query points.
- Compare SHAP and LIME.
- Discuss correlation and causality.
- Evaluate explanation stability.

12. تقرير المخبر

يتضمن دقة النموذج ومقارنة طرق الأهمية وتفسير حالتين ومقارنة SHAP و LIME وتحليل الارتباط والسببية والاستقرار.

المراجع | References

المراجع العامة المستخدمة في هذا المقرر

[1] A. Gabash, *Flexible Optimal Operations of Energy Supply Networks with Renewable Energy Generation and Battery Storage*. Saarbrücken, Germany: Südwestdeutscher Verlag für Hochschulschriften, 2014.

[2] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th Global ed. Harlow, U.K.: Pearson Education Limited, 2022.

[3] A. Gabash, "Energy Market Transition and Climate Change: A Review of TSOs-DSOs C+++ Framework from 1800 to Present," *Energies*, vol. 16, no. 17, Art. no. 6139, 2023, doi: 10.3390/en16176139.

[4] A. Gabash, *AI Applications in Electrical Power Systems*, Version 1.0, 2026. [Online]. Available: <https://aoussgabash.com>

معلومات النشر | Publication Information

Document	Laboratory 13 · Explaining a Load-Forecasting Model
Course	AI Applications in Electrical Power Systems
Author	Dr.-Ing. Aouss Gabash
Version	1.0
Publication year	2026
Official website	https://aoussgabash.com
Citation style	IEEE

Recommended citation:

Gabash, A. (2026). Explaining a Load-Forecasting Model. AI Applications in Electrical Power Systems, Laboratory 13, Version 1.0. <https://aoussgabash.com>

المرجع المقترح:

أوس غباش، 2026، مخبر 13، تطبيقات الذكاء الاصطناعي في أنظمة الطاقة الكهربائية، الإصدار 1.0، <https://aoussgabash.com>

© 2026 Dr.-Ing. Aouss Gabash. Educational use with attribution to the author and official website.