

LAB 18 | المخبر 18

Federated Learning Simulation

محاكاة التعلم الاتحادي

Local Training, FedAvg Aggregation, Non-IID Data, and Communication Analysis

التدريب المحلي ودمج FedAvg والبيانات غير المتجانسة وتحليل الاتصال

Scenario

Model

Workflow

MATLAB Code

Experiments

Validation

Prepared by | إعداد: Dr.-Ing. Aouss Gabash



Learning Outcomes

مخرجات التعلم

1. Implement a MATLAB workflow for ai-driven microgrid management.
تنفيذ سير عمل في MATLAB حول الإدارة الذكية للشبكات المصغرة.
2. Interpret numerical results, plots, and engineering implications.
تفسير النتائج العددية والرسوم والدلالات الهندسية.
3. Validate the implementation and discuss limitations.
التحقق من صحة التنفيذ ومناقشة حدوده.



Prerequisites

المتطلبات
السابقة

Economic dispatch,
storage models, and
microgrid
fundamentals.

التوزيع الاقتصادي ونماذج
التخزين وأساسيات
الشبكات المصغرة.

AI-Driven Microgrid
Management | الإدارة

الذكاء للشبكات المصغرة



Laboratory Objectives

- Create several smart-grid clients with private local data.
- Train local forecasting models without sharing raw measurements.
- Implement sample-weighted Federated Averaging.
- Track global and per-client loss across communication rounds.
- Compare IID and non-IID data.

- Study partial participation, communication cost, privacy noise, and malicious updates.

أهداف المخبر

- إنشاء عدة عملاء ببيانات محلية خاصة.
- تدريب نماذج محلية دون مشاركة القياسات الخام.
- تنفيذ FedAvg الموزون بعدد العينات.
- تتبع الخطأ العام وخطأ كل عميل.
- مقارنة البيانات المتجانسة وغير المتجانسة.
- دراسة المشاركة الجزئية وكلفة الاتصال وضوء الخصوصية والتحديثات الخبيثة.

1. Laboratory Scenario

Five distribution feeders collaboratively train a one-step load-forecasting model. Each client keeps load and temperature measurements locally and sends only model parameters to a central server.

$$\hat{P} = w_0 + w_1 P_{prev} + w_2 T$$

Federated learning coordinates model training while raw client data remain local.

1. سيناريو المخبر

تتعاون خمسة مغذيات لتدريب نموذج تنبؤ بالحمل، بينما تبقى بيانات الحمل والحرارة لدى كل عميل.

2. Federated Objective and FedAvg

$$F(w) = \sum_k = 1K(nk/N)Fk(w)$$

$$w_{kt} + 1 = LocalTrain(w_t, D_k)$$


$$w_t + 1 = \sum_k (nk / \sum_j nj) w_{kt} + 1$$

When client data are non-IID, many local epochs can increase client drift and bias the global model.

2. الهدف الاتحادي و FedAvg

يُدرَّب كل عميل نموذجًا محليًا، ثم يدمج الخادم النماذج بأوزان تتناسب مع عدد العينات.

3. Engineering Workflow



1. Generate private client datasets.
2. Initialize one global model.

3. Train local copies for several epochs.
4. Aggregate local parameters using FedAvg.
5. Measure global and client-specific performance.
6. Repeat under non-IID data, partial participation, and malicious updates.

3. سير العمل الهندسي

ننشئ العملاء وندريب النماذج محليًا ثم ندمجها ونقيم الأداء والمتانة والخصوصية.

4. Complete MATLAB Program

```

%% Lab 18: Federated Learning Simulation
clear; clc; close all; rng(18);

%% Federated settings
K = 5;
rounds = 40;
localEpochs = 4;
eta = 0.02;
nSamples = [180 220 260 320 420];

%% Private client data
Xclient = cell(K,1);
yclient = cell(K,1);
for k = 1:K
    n = nSamples(k);
    temperature = 10 + 20*rand(n,1);
    previousLoad = 40 + 12*randn(n,1) + 3*k;
    clientBias = 2.5*(k-3); % non-IID offset
    loadNow = 8 + 0.82*previousLoad + ...
        0.55*temperature + clientBias + 2*randn(n,1);
    Xclient{k} = [ones(n,1),previousLoad,temperature];
    yclient{k} = loadNow;
end

%% Global validation set
Xval = []; yval = [];
for k = 1:K
    Xval = [Xval;Xclient{k}];
    yval = [yval;yclient{k}];
end

%% Initialize global model
p = size(Xval,2);
wGlobal = zeros(p,1);
lossHistory = zeros(rounds,1);
clientLoss = zeros(rounds,K);

%% Federated training
for r = 1:rounds
    localModels = zeros(p,K);

    for k = 1:K
        Xk = Xclient{k}; yk = yclient{k};
        wk = wGlobal;
    end
end

```

```

        for e = 1:localEpochs
            prediction = Xk*wk;
            gradient = (2/size(Xk,1))*Xk'*(prediction-yk);
            wk = wk - eta*gradient;
        end

        localModels(:,k) = wk;
        clientLoss(r,k) = mean((Xk*wk-yk).^2);
    end

    weights = nSamples/sum(nSamples);
    wGlobal = localModels*weights';
    lossHistory(r) = mean((Xval*wGlobal-yval).^2);
end

%% Results
fprintf('Global model coefficients:\n');
disp(wGlobal);
fprintf('Final global MSE = %.4f\n',lossHistory(end));

figure;
semilogy(1:rounds,lossHistory,'LineWidth',1.8); grid on;
xlabel('Communication round'); ylabel('Global MSE');
title('Federated Learning Convergence');

figure;
plot(1:rounds,clientLoss,'LineWidth',1.2); grid on;
xlabel('Communication round'); ylabel('Local MSE');
legend('Client 1','Client 2','Client 3','Client 4','Client 5');

figure;
scatter(yval,Xval*wGlobal,18,'filled'); hold on;
minY = min(yval); maxY = max(yval);
plot([minY maxY],[minY maxY],'-','LineWidth',1.3); grid on;
xlabel('True load'); ylabel('Predicted load');
title('Global Federated Model');

%% Per-client evaluation
finalClientMSE = zeros(K,1);
for k = 1:K
    finalClientMSE(k) = mean((Xclient{k}*wGlobal-yclient{k}).^2);
end
disp(table((1:K)',nSamples',finalClientMSE, ...
    'VariableNames',{'Client','Samples','MSE'}));
fprintf('Worst-client MSE = %.4f\n',max(finalClientMSE));

```

4. برنامج MATLAB الكامل

ينشئ البرنامج بيانات خاصة لكل عميل، ويدرب نموذجًا محليًا، ثم يطبق FedAvg ويتابع الأداء العام والمحلي.

5. Experiments

Equal vs Weighted

Compare equal averaging with sample-weighted FedAvg.

IID vs Non-IID

Set all client biases to zero and compare convergence.

Partial Participation

Select only a fraction of clients per round.

Communication Cost

Estimate upload and download volume.

Client Drift

Compare 1, 4, 10, and 25 local epochs.

Malicious Client

Scale one update and compare mean with median aggregation.

```
% Partial participation example
participationRate = 0.6;
selectedCount = max(1,round(participationRate*K));
selected = randperm(K,selectedCount);
selectedWeights = nSamples(selected)/sum(nSamples(selected));
wGlobal = localModels(:,selected)*selectedWeights';

% Communication estimate
parametersPerModel = numel(wGlobal);
bytesPerParameter = 8;
totalMB = 2*rounds*K*parametersPerModel*bytesPerParameter/1024^2;

% Malicious update and robust aggregation
maliciousClient = 3;
localModels(:,maliciousClient) = 8*localModels(:,maliciousClient);
wMean = localModels*weights';
wMedian = median(localModels,2);
```

Robust aggregation can improve attack resistance but may reduce efficiency or penalize legitimate unusual clients.

5. التجارب

قارن طرق الدمج وتجانس البيانات والمشاركة الجزئية وكلفة الاتصال وانجراف العملاء والهجمات.

6. Expected Results and Validation

Global Convergence

Global MSE should decrease across rounds.

Client Fairness

Worst-client error should be reported.

Non-IID Effect

Heterogeneous clients may converge more slowly.

Attack Robustness

Median aggregation may resist extreme updates.

- Report global MSE and per-client MSE.
- Compare equal and sample-weighted aggregation.
- Repeat random participation experiments.
- Measure communication volume.
- Test model quality after adding update noise.

A good global average does not guarantee acceptable performance for every feeder.

6. النتائج المتوقعة والتحقق

يجب انخفاض الخطأ العام، مع فحص خطأ كل عميل والعدالة وكلفة الاتصال والمتانة أمام الهجمات.

7. Student Tasks

1. Compare equal and sample-weighted FedAvg.
2. Create IID and strongly non-IID client datasets.
3. Use participation rates of 0.4, 0.6, and 1.0.
4. Vary local epochs and quantify client drift.

5. Add Gaussian noise to local updates.
6. Compare mean, median, and trimmed-mean aggregation.
7. Report global, average-client, and worst-client errors.

7. مهام الطالب

1. مقارنة الدمج المتساوي والموزون.
2. إنشاء بيانات IID وغير IID بشدة.
3. اختبار نسب مشاركة مختلفة.
4. تغيير عدد العصور المحلية وقياس الانجراف.
5. إضافة ضوضاء إلى التحديثات.
6. مقارنة المتوسط والوسيط والمتوسط المشذب.
7. عرض الخطأ العام والمتوسط والأسوأ.



Research Extension

Secure smart-grid FL: add personalized models, differential privacy, secure aggregation, asynchronous clients, and adversarial update detection.

امتداد بحثي

وسّع المخبر إلى نماذج مخصصة وخصوصية تفاضلية وتجميع آمن وعملاء غير متزامنين وكشف التحديثات الخبيثة.



Review Questions

1. What is FedAvg?
2. Why are sample weights used?
3. What makes data non-IID?
4. How do local epochs affect client drift?
5. Why is per-client evaluation necessary?
6. How does partial participation affect convergence?
7. What is the difference between privacy and robustness?

أسئلة المراجعة

1. ما FedAvg؟
2. لماذا تستخدم أوزان العينات؟
3. ما الذي يجعل البيانات غير متجانسة؟
4. كيف تؤثر العصور المحلية في انجراف العملاء؟
5. لماذا نحتاج تقييم كل عميل؟
6. كيف تؤثر المشاركة الجزئية في التقارب؟
7. ما الفرق بين الخصوصية والمتانة؟

References | المراجع

المراجع العامة المستخدمة في هذا المقرر

- [1] A. Gabash, *Flexible Optimal Operations of Energy Supply Networks with Renewable Energy Generation and Battery Storage*. Saarbrücken, Germany: Südwestdeutscher Verlag für Hochschulschriften, 2014.
- [2] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th Global ed. Harlow, U.K.: Pearson Education Limited, 2022.
- [3] A. Gabash, "Energy Market Transition and Climate Change: A Review of TSOs-DSOs C+++ Framework from 1800 to Present," *Energies*, vol. 16, no. 17, Art. no. 6139, 2023, doi: 10.3390/en16176139.
- [4] A. Gabash, *AI Applications in Electrical Power Systems*, Version 1.0, 2026. [Online]. Available: <https://aoussgabash.com>

Recommended citation:

Gabash, A. (2026). Federated Learning Simulation. AI Applications in Electrical Power Systems, Laboratory 18, Version 1.0. <https://aoussgabash.com>

المرجع المقترح:

أوس غباش، 2026، مخبر 18، تطبيقات الذكاء الاصطناعي في أنظمة الطاقة الكهربائية، الإصدار 1.0، <https://aoussgabash.com>

© 2026 Dr.-Ing. Aouss Gabash. Educational use with attribution to the author and official website.