


LAB 19 | 19 المخبر

AI-Based Intrusion Detection

كشف الهجمات السيبرانية باستخدام الذكاء الاصطناعي

Synthetic PMU Data, False-Data Attacks, SVM Classification, and Robust Evaluation

بيانات PMU اصطناعية وهجمات بيانات كاذبة وتصنيف SVM وتقييم متين



Prepared by | إعداد | Dr.-Ing. Aouss Gabash

Laboratory Objectives

- Generate normal and attacked power-system measurements.
- Construct electrical and physics-inspired residual features.
- Split and standardize data without leakage.
- Train an RBF-SVM intrusion detector.
- Compute confusion matrix, precision, recall, F1, AUC, and false-alarm rate.
- Study noise, class imbalance, decision thresholds, and unseen attacks.
- Compare data-driven and physics-informed detection.

أهداف المخبر

- توليد قياسات طبيعية ومهاجمة لنظام قدرة.
- بناء ميزات كهربائية وبواقي مستوحاة من الفيزياء.
- تقسيم البيانات وتطبيقها دون تسرب معلومات.
- تدريب كاشف اختراق باستخدام RBF-SVM.
- حساب مصفوفة الالتباس و Precision و Recall و F1 و AUC والإنذار الكاذب.
- دراسة الضوضاء وعدم توازن الفئات والعتبات والهجمات غير المرئية.
- مقارنة الكشف البياني بالكشف المدعوم بالفيزياء.

1. Laboratory Scenario

We simulate PMU-like voltage magnitude, phase angle, frequency deviation, and active-power measurements. Attack samples contain coordinated false-data shifts and replay-like behavior.

$$z_{attack} = z + a + v$$

The classifier labels each sample as normal or attacked, while a residual feature checks whether measurements remain physically consistent.

1. سيناريو المخبر

نحاكي قياسات شبيهة بوحدات PMU، ثم نضيف هجمات منسقة وإعادة إرسال ونستخدم مصنعًا لتحديد الحالة.

2. Feature Engineering

$$rP = P - \hat{P}(V, \theta)$$

$$\hat{P} = 1.10 + c_1\theta + c_2(1 - V)$$

Voltage

Magnitude deviation from nominal.

Angle

Phase-angle shift.

Frequency

Frequency deviation.

Power

Active-power measurement.

Residual

Physics-consistency indicator.

Label


0 normal, 1 attack.

Residual features depend on model quality; a poor physical approximation can create false alarms.

2. هندسة الميزات

تجمع الميزات بين القياسات الخام ومَتَّبَقٍ يقيس اتساق القدرة مع الجهد والزاوية.

3. Engineering Workflow



1. Generate normal and attack datasets.
2. Construct raw and physics-informed features.
3. Split before normalization to avoid leakage.
4. Train and calibrate the classifier.
5. Evaluate standard metrics and ROC-AUC.
6. Test noise, imbalance, thresholds, and unseen attacks.

3. سير العمل الهندسي

نولد البيانات ونبنّي الميزات، ثم نقسمها ونطبعها وندرّب SVM ونختبر المتانة والتعميم.

4. Complete MATLAB Program

```

%% Lab 19: AI-Based Intrusion Detection
clear; clc; close all; rng(19);

%% Data size
Nnormal = 1800;
Nattack = 600;

%% Normal PMU-like measurements
Vn = 1.00 + 0.008*randn(Nnormal,1);
An = 0.00 + 0.020*randn(Nnormal,1);
Fn = 0.00 + 0.015*randn(Nnormal,1);
Pn = 1.10 + 0.12*randn(Nnormal,1);

%% Attack measurements
Va = 1.00 + 0.008*randn(Nattack,1);
Aa = 0.00 + 0.020*randn(Nattack,1);
Fa = 0.00 + 0.015*randn(Nattack,1);
Pa = 1.10 + 0.12*randn(Nattack,1);
Va = Va + 0.035 + 0.010*randn(Nattack,1);
Aa = Aa + 0.090 + 0.020*randn(Nattack,1);
Fa = Fa + 0.060 + 0.020*randn(Nattack,1);
Pa = Pa + 0.28 + 0.08*randn(Nattack,1);

%% Physics-inspired residual
c1 = 8.0; c2 = 3.0;
Rn = Pn - (1.10 + c1*An + c2*(1-Vn));
Ra = Pa - (1.10 + c1*Aa + c2*(1-Va));

%% Features and labels
Xnormal = [Vn An Fn Pn Rn];
Xattack = [Va Aa Fa Pa Ra];
X = [Xnormal;Xattack];
Y = [zeros(Nnormal,1);ones(Nattack,1)];

%% Train/test split
cv = cvpartition(Y,'HoldOut',0.30);
Xtrain = X(training(cv),:);
Ytrain = Y(training(cv));
Xtest = X(test(cv),:);
Ytest = Y(test(cv));

%% Standardization from training statistics only
mu = mean(Xtrain,1);
sigma = std(Xtrain,[],1);
sigma(sigma==0)=1;

```

```

XtrainZ = (Xtrain-mu)./sigma;
XtestZ = (Xtest-mu)./sigma;

%% RBF-SVM
mdl = fitcsvm(XtrainZ,Ytrain, ...
    'KernelFunction','rbf','KernelScale','auto', ...
    'Standardize',false,'ClassNames',[0 1]);
mdl = fitPosterior(mdl,XtrainZ,Ytrain);
[pred,score] = predict(mdl,XtestZ);

%% Metrics
cm = confusionmat(Ytest,pred,'Order',[0 1]);
TN=cm(1,1); FP=cm(1,2); FN=cm(2,1); TP=cm(2,2);
accuracy=(TP+TN)/sum(cm,'all');
precision=TP/max(TP+FP,1);
recall=TP/max(TP+FN,1);
F1=2*precision*recall/max(precision+recall,eps);
falseAlarmRate=FP/max(FP+TN,1);
[fpRate,tpRate,~,AUC]=perfcurve(Ytest,score(:,2),1);

fprintf('Accuracy          = %.3f\n',accuracy);
fprintf('Precision         = %.3f\n',precision);
fprintf('Recall             = %.3f\n',recall);
fprintf('F1 score           = %.3f\n',F1);
fprintf('False alarm rate = %.3f\n',falseAlarmRate);
fprintf('AUC                = %.3f\n',AUC);

figure;
confusionchart(Ytest,pred,'RowSummary','row-normalized', ...
    'ColumnSummary','column-normalized');
title('AI Intrusion Detector');

figure;
plot(fpRate,tpRate,'LineWidth',1.8); hold on;
plot([0 1],[0 1],'--'); grid on;
xlabel('False Positive Rate'); ylabel('True Positive Rate');
title(sprintf('ROC Curve, AUC = %.3f',AUC));

```

4. برنامج MATLAB الكامل

ينشئ البرنامج البيانات والميزات، ثم يدرب SVM ويحسب المقاييس الأساسية ومنحنى ROC.

5. Experiments

Remove Residual

Retrain using only raw features.

Class Imbalance

Reduce attack samples to 5%.

Noise Robustness

Add test-time Gaussian noise.

Threshold Selection

Trade recall against false alarms.

Unseen Attack

Test a different attack pattern.

Feature Ablation

Remove one feature at a time.

```
% Threshold experiment
probAttack = score(:,2);
thresholds = 0.10:0.05:0.90;
metricTable = zeros(numel(thresholds),3);
for q = 1:numel(thresholds)
    predT = probAttack >= thresholds(q);
    cmT = confusionmat(Ytest,predT,'Order',[0 1]);
    TN=cmT(1,1); FP=cmT(1,2); FN=cmT(2,1); TP=cmT(2,2);
    metricTable(q,1)=TP/max(TP+FN,1);
    metricTable(q,2)=FP/max(FP+TN,1);
    metricTable(q,3)=2*TP/max(2*TP+FP+FN,1);
end
```

Accuracy alone is misleading when attack samples are rare.

5. التجارب

اختبر حذف البواقي وعدم التوازن والضوضاء والعتبات والهجمات غير المرئية وحذف الميزات.

6. Expected Results and Validation

High Recall

Critical attacks should rarely be missed.

Controlled False Alarms

Normal operation should not trigger excessive alarms.

Residual Benefit

Physics features should improve unseen-attack detection.

Robustness

Performance should degrade gradually under noise.

- Report confusion matrix, precision, recall, F1, AUC, and false-alarm rate.
- Compare with and without the residual feature.
- Repeat the split using several random seeds.
- Test class imbalance explicitly.
- Evaluate at least one unseen attack type.

A useful security detector must be accurate, robust, physically plausible, and operationally acceptable.

6. النتائج المتوقعة والتحقق

يجب تحقيق استدعاء مرتفع مع إنذارات كاذبة مقبولة، وإظهار فائدة البواقي والمتانة أمام الضوضاء والهجمات الجديدة.

7. Student Tasks

1. Remove the residual and compare all metrics.
2. Create a 5% attack dataset.
3. Test four noise levels.
4. Select a threshold that maximizes F1.
5. Create a replay-like unseen attack.
6. Compare SVM with an ensemble classifier.
7. Report the most safety-critical failure case.

7. مهام الطالب

1. حذف البواقي ومقارنة المقاييس.
2. إنشاء مجموعة هجمات بنسبة 5%.
3. اختبار أربعة مستويات ضوضاء.
4. اختيار عتبة تعظم F1.
5. إنشاء هجوم إعادة إرسال غير مرئي.
6. مقارنة SVM مع نموذج تجميعي.
7. تحديد أخطر حالة فشل.



Research Extension

Cyber-physical detector: combine temporal models, graph topology, state-estimation residuals, adversarial testing, and online drift monitoring.

امتداد بحثي

ادمج النماذج الزمنية وطوبولوجيا الشبكة وبواقي تقدير الحالة والاختبارات الخصومية ومراقبة الانجراف.



Review Questions

1. Why is train-only standardization necessary?
2. What does the physics residual represent?
3. Why is recall important in intrusion detection?
4. How does class imbalance distort accuracy?
5. What does the ROC curve show?
6. Why test unseen attacks?
7. How can a detector be made physics-informed?

أسئلة المراجعة

1. لماذا يجب التطبيع باستخدام التدريب فقط؟
2. ماذا تمثل البواقي الفيزيائية؟

3. لماذا يعد Recall مهمًا؟
4. كيف يشوه عدم توازن الفئات الدقة؟
5. ماذا يبين منحنى ROC؟
6. لماذا نختبر هجمات غير مرئية؟
7. كيف نجعل الكاشف موجّهًا بالفيزياء؟

References | المراجع

المراجع العامة المستخدمة في هذا المقرر

[1] A. Gabash, *Flexible Optimal Operations of Energy Supply Networks with Renewable Energy Generation and Battery Storage*. Saarbrücken, Germany: Südwestdeutscher Verlag für Hochschulschriften, 2014.

[2] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th Global ed. Harlow, U.K.: Pearson Education Limited, 2022.

[3] A. Gabash, "Energy Market Transition and Climate Change: A Review of TSOs-DSOs C++ Framework from 1800 to Present," *Energies*, vol. 16, no. 17, Art. no. 6139, 2023, doi: 10.3390/en16176139.

[4] A. Gabash, *AI Applications in Electrical Power Systems*, Version 1.0, 2026. [Online]. Available: <https://aoussgabash.com>

Publication Information | معلومات النشر

Document	Laboratory 19 · AI-Based Intrusion Detection
Course	AI Applications in Electrical Power Systems
Author	Dr.-Ing. Aouss Gabash
Version	1.0
Publication year	2026
Official website	https://aoussgabash.com
Citation style	IEEE

Recommended citation:
Gabash, A. (2026). AI-Based Intrusion Detection. AI Applications in Electrical Power Systems, Laboratory 19, Version 1.0. <https://aoussgabash.com>

المرجع المقترح:

أوس غباش، 2026، مخبر 19، تطبيقات الذكاء الاصطناعي في أنظمة الطاقة الكهربائية، الإصدار 1.0، <https://aoussgabash.com>

© 2026 Dr.-Ing. Aouss Gabash. Educational use with attribution to the author and official website.