

## LECTURE 05 | المحاضرة 05

# Artificial Neural Networks

## الشبكات العصبية الاصطناعية

Neurons, Activation Functions, Loss, Gradients, and Backpropagation

العصبونات ودوال التنشيط ودالة الخطأ والتدرجات والانتشار الخلفي

Prepared by | إعداد | Dr.-Ing. Aouss Gabash



### Learning Outcomes

مخرجات التعلم

1. Apply clustering and dimensionality-reduction methods to engineering data.  
تطبيق التجميع وخفض الأبعاد على البيانات الهندسية.
2. Interpret the governing mathematical or algorithmic principles.  
تفسير المبادئ الرياضية أو الخوارزمية الحاكمة.
3. Connect the topic to practical electrical-power-engineering applications.  
ربط الموضوع بتطبيقات عملية في هندسة الطاقة الكهربائية.



### Prerequisite sites

المتطلبات السابقة

Lecture 04 and elementary linear algebra.

المحاضرة 04 والجبر الخطي الأولي.

Unsupervised Machine Learning |  
التعلم الآلي غير المراقب

### Learning Objectives


- Understand the mathematical model of an artificial neuron.
- Explain weights, bias, weighted sum, and activation functions.
- Understand and differentiate the Sigmoid function.
- Understand forward propagation, loss, gradient descent, and backpropagation.
- Use the chain rule to derive neural-network gradients.
- Apply neural networks to power-system problems.

## أهداف التعلم

- فهم النموذج الرياضي للعصبون الاصطناعي.
- فهم الأوزان والانزياح والمجموع الموزون ودوال التنشيط.
- فهم دالة Sigmoid واشتقاق مشتقتها.
- فهم الانتشار الأمامي ودالة الخطأ والانحدار المتدرج والانتشار الخلفي.
- استخدام قاعدة السلسلة لاشتقاق تدرجات الشبكة.
- تطبيق الشبكات العصبية على مسائل نظم الطاقة الكهربائية.

### 1. From Biological Neuron to Artificial Neuron

Artificial neural networks are inspired by the idea of biological neurons: receive signals, combine them, and generate an output.



An artificial neuron is fundamentally a mathematical function.

### 1. من العصبون الحيوي إلى العصبون الاصطناعي

تستلهم الشبكات العصبية الاصطناعية فكرتها بصورة مبسطة من العصبونات الحيوية: استقبال إشارات، دمجها، ثم إنتاج خرج.

العصبون الاصطناعي في جوهره عبارة عن دالة رياضية.

## 2. Mathematical Model of a Neuron

Suppose the neuron receives inputs  $x_1, x_2, \dots, x_n$  with weights  $w_1, w_2, \dots, w_n$ .

$$z = w_1x_1 + w_2x_2 + \dots + w_nx_n + b$$

$$z = \sum w_i x_i + b$$

$$y = \varphi(z)$$

## 2. النموذج الرياضي للعصبون

يحسب العصبون أولاً المجموع الموزون ثم يمرره عبر دالة التنشيط.

$$z = \sum w_i x_i + b$$

$$y = \varphi(z)$$

## 3. Weights and Bias

The weights determine how strongly each input influences the output.

$$z = w_1x_1 + w_2x_2$$

If  $|w_1| > |w_2|$ , input  $x_1$  has the stronger influence. The bias shifts the neuron response and allows useful outputs even when the inputs are zero.


Weights control input influence; bias controls the response shift.

### 3. الأوزان والانزياح

تحدد الأوزان مقدار تأثير كل مدخل على المخرج، بينما يسمح الانزياح بتحريك استجابة العصبون.

$$z = \sum w_i x_i + b$$

## 4. Structure of a Simple Neural Network



2 Inputs  $\rightarrow$  2 Hidden Neurons  $\rightarrow$  1 Output

## 4. بنية شبكة عصبية بسيطة

يوضح الشكل شبكة عصبية من النوع 1-2-2: مدخلان، عصبونان مخفيان، وخرج واحد.

$$2 \rightarrow 2 \rightarrow 1$$

## 5. Activation Functions

Activation functions allow neural networks to represent nonlinear relationships.

### Sigmoid

$$\sigma(z) = 1/(1 + e^{-z})$$

### Tanh

$$\tanh(z)$$

### ReLU

$$\text{ReLU}(z) = \max(0, z)$$

## 5. دوال التنشيط

تسمح دوال التنشيط للشبكة بتمثيل علاقات غير خطية ومعقدة، ومن أشهرها Sigmoid و Tanh و ReLU.

## 6. The Sigmoid Function and Its Derivative

$$\sigma(z) = 1/(1 + e^{-z})$$

$$0 < \sigma(z) < 1$$

Starting with  $\sigma(z) = (1 + e^{-z})^{-1}$  and applying the chain rule:

$$d\sigma/dz = e^{-z}/(1 + e^{-z})^2$$

Since  $1 - \sigma(z) = e^{-z}/(1 + e^{-z})$ , the derivative becomes:

$$\sigma'(z) = \sigma(z)[1 - \sigma(z)]$$

## 6. دالة Sigmoid ومشتقتها

$$\sigma(z) = 1/(1 + e^{-z})$$

باستخدام قاعدة السلسلة وإعادة الترتيب نحصل على:

$$\sigma'(z) = \sigma(z)[1 - \sigma(z)]$$

يمكن حساب المشتقة مباشرة باستخدام قيمة خرج Sigmoid.

## 7. Forward Propagation

### Hidden neurons

$$z_1 = w_1x_1 + w_2x_2 + b_1, h_1 = \sigma(z_1)$$

$$z_2 = w_3x_1 + w_4x_2 + b_2, h_2 = \sigma(z_2)$$

### Output neuron

$$z_3 = v_1h_1 + v_2h_2 + b_3$$

$$y = \sigma(z_3)$$

## 7. الانتشار الأمامي

يعني الانتشار الأمامي حساب خرج الشبكة بدءًا من المدخلات، مرورًا بالطبقات المخفية، وصولاً إلى الخرج النهائي.

Input → Hidden Layer → Output

## 8. Loss Function

The prediction  $y$  is compared with the desired target  $t$ .

$$E = 1/2(y - t)^2$$

The factor  $1/2$  simplifies the derivative:

$$\partial E / \partial y = y - t$$

### 8. دالة الخطأ

نقارن خرج الشبكة  $y$  مع القيمة المطلوبة  $t$ .

$$E = 1/2(y - t)^2$$

$$\partial E / \partial y = y - t$$

## 9. Backpropagation and the Chain Rule

Backpropagation determines how much each weight contributes to the final error.

$$\partial E / \partial w = \partial E / \partial y \times \partial y / \partial z \times \partial z / \partial w$$

Backpropagation is repeated application of the chain rule.



## 9. الانتشار الخلفي وقاعدة السلسلة

يحسب الانتشار الخلفي مقدار مساهمة كل وزن في الخطأ باستخدام المشتقات وقاعدة السلسلة.

$$\partial E / \partial w = \partial E / \partial y \times \partial y / \partial z \times \partial z / \partial w$$

## 10. Output-Layer Error Signal

$$y = \sigma(z_3)$$

$$\partial E / \partial y = y - t$$

$$\partial y / \partial z_3 = y(1 - y)$$

$$\delta_3 = \partial E / \partial z_3 = (y - t)y(1 - y)$$

MATLAB: dO = (y - t) \* y \* (1 - y)

## 10. إشارة الخطأ في طبقة الخرج

باستخدام قاعدة السلسلة:

$$\delta_3 = (y - t)y(1 - y)$$

ولهذا تظهر في كود MATLAB العلاقة:

$$dO = (y - t) * y * (1 - y)$$

## 11. Output-Weight Gradients

$$z_3 = v_1 h_1 + v_2 h_2 + b_3$$

$$\partial E / \partial v_1 = \delta_3 h_1$$

$$\partial E / \partial v_2 = \delta_3 h_2$$

$$\partial E / \partial b_3 = \delta_3$$

## 11. تدرجات أوزان طبقة الخرج

$$\partial E / \partial v_1 = \delta_3 h_1$$

$$\partial E / \partial v_2 = \delta_3 h_2$$

$$\partial E / \partial b_3 = \delta_3$$

## 12. Hidden-Layer Error Signals

$$\delta_1 = \delta_3 v_1 h_1 (1 - h_1)$$

$$\delta_2 = \delta_3 v_2 h_2 (1 - h_2)$$

The output error is propagated backward through the connection weights.

## 12. إشارات الخطأ في الطبقة المخفية

يصل تأثير الخطأ من طبقة الخرج إلى الطبقة المخفية عبر الأوزان.

$$\delta_1 = \delta_3 v_1 h_1 (1 - h_1)$$

$$\delta_2 = \delta_3 v_2 h_2 (1 - h_2)$$

### 13. Input-to-Hidden Gradients

If  $z_1 = w_1 x + b_1$ , then:

$$\partial E / \partial w_1 = \delta_1 x$$

$$\partial E / \partial b_1 = \delta_1$$

13. تدرجات الأوزان بين الدخل والطبقة المخفية

$$\partial E / \partial w_1 = \delta_1 x$$

$$\partial E / \partial b_1 = \delta_1$$

### 14. Gradient Descent

After calculating the gradients, every parameter is updated:

$$w(\text{new}) = w(\text{old}) - \eta \partial E / \partial w$$


$\eta$  is the learning rate. The gradient is subtracted because it points toward increasing error.

## 14. الانحدار المتدرج

$$w(new) = w(old) - \eta \partial E / \partial w$$

نطرح التدرج لأننا نريد التحرك باتجاه انخفاض الخطأ.

## 15. Complete Training Cycle



Repeat until the error becomes sufficiently small.

## 15. دورة التدريب الكاملة

المدخلات ← الانتشار الأمامي ← التنبؤ ← الخطأ ← الانتشار الخلفي ← تحديث الأوزان ← التكرار

## 16. Numerical Example

$$x = 1, w = 0.5, b = 0$$

$$z = wx + b = 0.5$$

$$y = \sigma(0.5) \approx 0.622$$

For target  $t=1$ :

$$E = 1/2(0.622 - 1)^2 \approx 0.0714$$

## 16. مثال عددي

$$x = 1, w = 0.5, b = 0$$

$$z = 0.5, y \approx 0.622$$

إذا كانت القيمة المطلوبة  $t=1$  فإن:

$$E \approx 0.0714$$

## 17. MATLAB Connection

$$z1 = W.w1 * x + W.b1$$

$$h1 = \text{sigma}(z1)$$

$$dO = (y - t) * y * (1 - y)$$

$$dV1 = dO * h1, dV2 = dO * h2$$

$$d1 = dO * W.v1 * h1 * (1 - h1)$$

$$dW1 = d1 * x$$

## 17. الربط مع MATLAB

كل قيمة d تمثل مشتقة جزئية أو إشارة خطأ مستخدمة لتحديد اتجاه تحديث الوزن.

## 18. Power-System Applications

A neural network can receive temperature, hour, previous load, and day type, then predict future electrical load.

$$x = [Temperature, Hour, PreviousLoad, DayType]$$

$$y = FutureElectricalLoad$$

### PV Forecasting

Predict photovoltaic generation.

### Wind Forecasting

Predict wind generation.

**Fault Classification**

Identify network faults.

**Voltage Estimation**

Estimate network voltage states.

**Battery Management**

Estimate SOC and support operation.

**Smart-Grid Monitoring**

Detect abnormal conditions.

## 18. تطبيقات نظم الطاقة

- التنبؤ بالحمل والطاقة الشمسية وطاقة الرياح.
- تصنيف الأعطال.
- تقدير الجهد والحالة التشغيلية.
- إدارة أنظمة تخزين الطاقة.
- مراقبة الشبكات الذكية.



## 19. Summary

- A neuron calculates a weighted sum and applies an activation function.
- The neuron equation is  $z = \sum w_i x_i + b$ .
- Sigmoid maps values to (0,1), with derivative  $\sigma'(z) = \sigma(z)[1 - \sigma(z)]$ .
- Forward propagation calculates predictions.
- Backpropagation calculates gradients using the chain rule.
- Gradient descent updates weights to reduce error.
- Neural networks have many power-system applications.

## 19. الخلاصة

- يحسب العصبون مجموعاً موزوناً ثم يطبق دالة تنشيط.
- المعادلة الأساسية هي  $z = \sum w_i x_i + b$ .
- مشتقة Sigmoid هي  $\sigma'(z) = \sigma(z)[1 - \sigma(z)]$ .
- يحسب الانتشار الأمامي التنبؤات.
- يحسب الانتشار الخلفي التدرجات باستخدام قاعدة السلسلة.
- يحدث الانحدار المتدرج الأوزان لتقليل الخطأ.
- للشبكات العصبية تطبيقات واسعة في نظم الطاقة.



## Review Questions

1. What is the equation of an artificial neuron?
2. What are the roles of weights and bias?
3. Why are activation functions required?
4. Derive the Sigmoid derivative.
5. What is forward propagation?
6. Explain the chain rule in backpropagation.
7. Derive  $dO = (y - t)y(1 - y)$ .
8. Why is the gradient subtracted?
9. Name four power-system applications.

## أسئلة المراجعة

1. ما معادلة العصبون الاصطناعي؟

2. ما وظيفة الأوزان والانزياح؟

3. لماذا نحتاج إلى دوال التنشيط؟

4. اشتق مشتقة Sigmoid.

5. ما المقصود بالانتشار الأمامي؟

6. اشرح قاعدة السلسلة في الانتشار الخلفي.

7. اشتق العلاقة  $dO = (y - t)y(1 - y)$ .

8. لماذا نطرح التدرج؟

9. اذكر أربعة تطبيقات في نظم الطاقة.

---

## References | المراجع

---

المراجع العامة المستخدمة في هذا المقرر

- [1] A. Gabash, *Flexible Optimal Operations of Energy Supply Networks with Renewable Energy Generation and Battery Storage*. Saarbrücken, Germany: Südwestdeutscher Verlag für Hochschulschriften, 2014.
- [2] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th Global ed. Harlow, U.K.: Pearson Education Limited, 2022.
- [3] A. Gabash, "Energy Market Transition and Climate Change: A Review of TSOs-DSOs C+++ Framework from 1800 to Present," *Energies*, vol. 16, no. 17, Art. no. 6139, 2023, doi: 10.3390/en16176139.
- [4] A. Gabash, *AI Applications in Electrical Power Systems*, Version 1.0, 2026. [Online]. Available: <https://aoussgabash.com>

---

### Recommended citation:

Gabash, A. (2026). Artificial Neural Networks. AI Applications in Electrical Power Systems, Lecture 05, Version 1.0. <https://aoussgabash.com>

---

المرجع المقترح:

أوس غباش، 2026، محاضرة 05، تطبيقات الذكاء الاصطناعي في أنظمة الطاقة الكهربائية، الإصدار 1.0، <https://aoussgabash.com>

---

© 2026 Dr.-Ing. Aouss Gabash. Educational use with attribution to the author and official website.