

LECTURE 06 | المحاضرة 06

Genetic Algorithms

الخوارزميات الجينية

Population, Fitness, Selection, Crossover, Mutation, and Optimization

المجتمع ودالة الملاءمة والاختيار والتزاوج والطفرة والتحسين

Prepared by | إعداد: Dr.-Ing. Aouss Gabash



Learning Outcomes

مخرجات التعلم

1. Explain forward propagation, backpropagation, and neural-network training.
شرح الانتشار الأمامي والخلفي وتدريب الشبكات العصبية.
2. Interpret the governing mathematical or algorithmic principles.
تفسير المبادئ الرياضية أو الخوارزمية الحاكمة.
3. Connect the topic to practical electrical-power-engineering applications.
ربط الموضوع بتطبيقات عملية في هندسة الطاقة الكهربائية.



Prerequisite sites

المتطلبات
السابقة

Lectures 04–05,
derivatives, and
matrix operations.

المحاضرتان 04–05
والمشتقات وعمليات
المصفوفات.

Artificial Neural
Networks | الشبكات

العصبية الاصطناعية

Learning Objectives

- Understand evolutionary optimization.
- Explain population, chromosome, gene, and fitness.
- Understand selection, crossover, mutation, and elitism.
- Formulate constrained optimization problems.
- Connect objective functions with fitness values.
- Apply Genetic Algorithms to power-system optimization.

أهداف التعلم

- فهم التحسين التطوري.
- فهم المجتمع والكروموسوم والجين ودالة الملاءمة.
- فهم الاختيار والتزاوج والطفرة والنخبوية.
- صياغة مسائل التحسين المقيدة.
- ربط دالة الهدف بدالة الملاءمة.
- تطبيق الخوارزميات الجينية على نظم الطاقة.

1. What is a Genetic Algorithm?

A Genetic Algorithm (GA) is an optimization method inspired by natural evolution.

Better candidate solutions are more likely to survive and produce new solutions.



1. ما هي الخوارزمية الجينية؟

الخوارزمية الجينية هي طريقة تحسين مستوحاة من مبادئ التطور الطبيعي.

الحلول الأفضل تحصل على فرصة أكبر للاستمرار والمشاركة في إنتاج حلول جديدة.

2. Optimization Problem

$$x^* = \arg \min J(x)$$

subject to:

$$g_i(x) \leq 0, h_j(x) = 0$$

- x : decision variables
- $J(x)$: objective function
- $g_i(x)$: inequality constraints
- $h_j(x)$: equality constraints

2. صياغة مسألة التحسين

$$x^* = \arg \min J(x)$$

مع القيود:

$$g_i(x) \leq 0, h_j(x) = 0$$

تمثل x متغيرات القرار وتمثل $J(x)$ دالة الهدف.

3. Population, Chromosome, Gene, and Generation

Population

A collection of candidate solutions.

Chromosome

One complete candidate solution.

Gene

One decision variable in a chromosome.

Generation

One iteration of the evolutionary process.

3. المجتمع والكروموسوم والجين والجيل

المجتمع

مجموعة من الحلول المرشحة.

الكروموسوم

حل كامل واحد.

الجين

متغير قرار واحد داخل الحل.

الجيل

دورة واحدة من العملية التطورية.

4. Chromosome Representation

For three decision variables:

$$x = [x_1, x_2, x_3]$$

A real-coded chromosome may be:

$$x = [0.25, 0.70, 0.40]$$

Binary coding is also possible, but real coding is often more natural for engineering variables.

4. تمثيل الكروموسوم

يمكن تمثيل الحل باستخدام متجه حقيقي:

$$x = [x_1, x_2, x_3]$$

$$x = [0.25, 0.70, 0.40]$$

ويكون الترميز الحقيقي مناسبًا غالبًا للمتغيرات الهندسية.

5. Objective Function and Fitness

For a minimization problem, smaller objective values should correspond to larger fitness values.

$$Fitness(x) = 1/[1 + J(x)]$$

Lower cost → higher fitness → greater probability of selection.

5. دالة الهدف ودالة الملاءمة

في مسألة التصغير يجب أن تقابل القيمة الأصغر لدالة الهدف قيمة أكبر للملاءمة.

$$Fitness(x) = 1/[1 + J(x)]$$

كلفة أصغر ← ملاءمة أكبر ← فرصة اختيار أعلى.

6. Constraint Handling

Constraints can be handled using penalty functions.

$$J_p(x) = J(x) + \lambda P(x)$$

$P(x)$ is zero for feasible solutions and positive when constraints are violated.

6. معالجة القيود

يمكن معالجة القيود باستخدام دوال العقوبة.

$$J_p(x) = J(x) + \lambda P(x)$$

تكون $P(x)$ صفرًا للحلول المقبولة وموجبة عند خرق القيود.

7. Initial Population

The initial population is usually generated randomly inside the allowed bounds.

$$x_i = x_{\min} + r_i(x_{\max} - x_{\min}), r_i \in [0, 1]$$

A diverse initial population improves exploration of the search space.

7. المجتمع الابتدائي

يتم عادة توليد المجتمع الابتدائي عشوائيًا ضمن الحدود المسموحة.

$$x_i = x_{\min} + r_i(x_{\max} - x_{\min})$$

يزيد التنوع في المجتمع الابتدائي من قدرة الخوارزمية على استكشاف فضاء البحث.

8. Selection

Selection chooses parent solutions according to fitness.

Roulette-Wheel Selection

Selection probability is proportional to fitness.

Tournament Selection

Several candidates compete and the best is selected.

$$p_i = F_i / \sum F_j$$

8. الاختيار

تختار عملية الانتقاء الحلول الأبوية اعتمادًا على قيم الملاءمة.

$$p_i = F_i / \sum F_j$$

من أشهر الطرائق عجلة الروليت واختيار البطولة.

9. Crossover

Crossover combines two parents to generate offspring.

$$Child_1 = \alpha Parent_1 + (1 - \alpha) Parent_2$$

$$Child_2 = (1 - \alpha) Parent_1 + \alpha Parent_2$$

where $\alpha \in [0,1]$.

9. التزاوج

تجمع عملية التزاوج معلومات من حلين أبويين لإنتاج حلول جديدة.

$$Child_1 = \alpha Parent_1 + (1 - \alpha) Parent_2$$

$$Child_2 = (1 - \alpha) Parent_1 + \alpha Parent_2$$

10. Mutation

Mutation introduces small random changes to preserve diversity.

$$x' = x + \sigma N(0, 1)$$

Too little mutation may cause premature convergence; too much mutation may destroy good solutions.

10. الطفرة

تضيف الطفرة تغييرات عشوائية صغيرة للمحافظة على تنوع المجتمع.

$$x' = x + \sigma N(0, 1)$$

الطفرة القليلة قد تسبب تقاربًا مبكرًا، والكثيرة قد تفسد الحلول الجيدة.

11. Elitism

Elitism copies one or more of the best solutions directly to the next generation.


Elitism prevents the algorithm from losing its best solution.

11. النخبوية

تنقل النخبوية أفضل حل أو عدة حلول مباشرة إلى الجيل التالي.

تمنع النخبوية فقدان أفضل حل تم الوصول إليه.

12. One Complete GA Generation



12. جيل كامل في الخوارزمية الجينية

تقييم ← اختيار الآباء ← تزاوج ← طفرة ← نخبوية ← تكوين المجتمع الجديد

13. Numerical Example

Minimize:

$$J(x) = x^2$$

For candidates $x = \{-2, -1, 0.5, 3\}$:

x	J(x)	Fitness=1/(1+J)
-2	4	0.20
-1	1	0.50
0.5	0.25	0.80
3	9	0.10

The candidate $x=0.5$ has the highest fitness.

13. مثال عددي

نريد تصغير:

$$J(x) = x^2$$

يملك الحل $x=0.5$ أصغر كلفة وأكبر قيمة ملائمة، لذلك تكون فرصة اختياره أعلى.

14. Power-System Application: Battery Scheduling

A chromosome can represent battery power over a scheduling horizon:

$$x = [P_\beta(1), P_\beta(2), \dots, P_\beta(T)]$$

The objective may combine energy cost, losses, and battery degradation:

$$J = C_{energy} + \lambda_1 P_{loss} + \lambda_2 C_{aging}$$

Constraints include SOC limits, power limits, and network operating limits.

14. تطبيق في نظم الطاقة: جدولة البطارية

يمكن أن يمثل الكروموسوم قدرة البطارية خلال أفق زمني:

$$x = [P_{\beta}(1), P_{\beta}(2), \dots, P_{\beta}(T)]$$

وقد تجمع دالة الهدف بين كلفة الطاقة والفواقد واهتراء البطارية، مع مراعاة حدود حالة الشحن والقدرة والشبكة.

15. Other Power-System Applications

Optimal Power Flow

Optimize generation and controllable resources.

Unit Commitment

Schedule generating units.

Network Reconfiguration

Choose switch states to reduce losses.

Controller Tuning

Optimize control parameters.

DG Placement

Select locations and sizes.

Renewable Scheduling

Coordinate uncertain resources.

15. تطبيقات أخرى في نظم الطاقة

- تدفق القدرة الأمثل.
- جدولة وحدات التوليد.
- إعادة تشكيل شبكات التوزيع.
- ضبط معاملات المتحكمات.
- تحديد مواقع وأحجام التوليد الموزع.
- جدولة مصادر الطاقة المتجددة.

16. Advantages and Limitations

Advantages

- No gradient required.
- Handles nonlinear and discrete problems.
- Explores many candidate solutions.

Limitations

- May require many evaluations.
- Parameter tuning is important.
- No guarantee of the global optimum.

16. المزايا والقيود

المزايا

- لا تحتاج إلى مشتقات.
- تتعامل مع المسائل غير الخطية والمتقطعة.
- تستكشف حلولاً متعددة.

القيود

- قد تحتاج إلى عدد كبير من التقييمات.
- تحتاج إلى ضبط المعاملات.
- لا تضمن دائماً الوصول إلى الحل الأمثل العالمي.

17. MATLAB Concept

```
for generation = 1:maxGenerations
    fitness = evaluatePopulation(population);
    parents = selectParents(population, fitness);
    children = crossover(parents);
    children = mutate(children);
    population = applyElitism(population, children, fitness);
end
```

17. الفكرة البرمجية في MATLAB

تتكرر خطوات التقييم والاختيار والتزاوج والطفرة والنخوبة حتى يتحقق شرط التوقف.

18. Summary

- GA is a population-based evolutionary optimizer.

- Chromosomes represent candidate solutions.
- Fitness measures solution quality.
- Selection, crossover, and mutation generate new solutions.
- Elitism preserves the best candidates.
- Penalty functions help enforce constraints.
- GA is useful for many complex power-system problems.

18. الخلاصة

- الخوارزمية الجينية طريقة تحسين تطورية تعتمد على مجتمع من الحلول.
- يمثل الكروموسوم حلاً مرشحاً.
- تقيس دالة الملاءمة جودة الحل.
- ينتج الاختيار والتزاوج والطفرة حلولاً جديدة.
- تحافظ النخبوية على أفضل الحلول.
- تساعد دوال العقوبة على تطبيق القيود.
- تصلح الخوارزمية الجينية لمسائل نظم الطاقة المعقدة.



Review Questions

1. What is a Genetic Algorithm?
2. What are population, chromosome, and gene?
3. How is fitness related to the objective function?
4. What is selection?
5. What is crossover?
6. Why is mutation required?
7. What is elitism?
8. How can constraints be handled?
9. How can GA be applied to battery scheduling?

أسئلة المراجعة

1. ما هي الخوارزمية الجينية؟
2. ما المقصود بالمجتمع والكروموسوم والجين؟
3. ما العلاقة بين دالة الهدف ودالة الملاءمة؟
4. ما المقصود بالاختيار؟

5. ما المقصود بالتزاج؟
6. لماذا نحتاج إلى الطفرة؟
7. ما المقصود بالنخبوية؟
8. كيف يمكن معالجة القيود؟
9. كيف تطبق الخوارزمية الجينية على جدولة البطارية؟

References | المراجع

المراجع العامة المستخدمة في هذا المقرر

- [1] A. Gabash, *Flexible Optimal Operations of Energy Supply Networks with Renewable Energy Generation and Battery Storage*. Saarbrücken, Germany: Südwestdeutscher Verlag für Hochschulschriften, 2014.
- [2] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th Global ed. Harlow, U.K.: Pearson Education Limited, 2022.
- [3] A. Gabash, "Energy Market Transition and Climate Change: A Review of TSOs-DSOs C+++ Framework from 1800 to Present," *Energies*, vol. 16, no. 17, Art. no. 6139, 2023, doi: 10.3390/en16176139.
- [4] A. Gabash, *AI Applications in Electrical Power Systems*, Version 1.0, 2026. [Online]. Available: <https://aoussgabash.com>

Recommended citation:

Gabash, A. (2026). Genetic Algorithms. AI Applications in Electrical Power Systems, Lecture 06, Version 1.0. <https://aoussgabash.com>

المرجع المقترح:

أوس غباش، 2026، محاضرة 06، تطبيقات الذكاء الاصطناعي في أنظمة الطاقة الكهربائية، الإصدار 1.0، <https://aoussgabash.com>

© 2026 Dr.-Ing. Aouss Gabash. Educational use with attribution to the author and official website.