

LECTURE 09 | 09 المحاضرة

Deep Learning for Power Systems

التعلم العميق في أنظمة الطاقة الكهربائية

From Multilayer Networks to Recurrent Models and LSTM Forecasting

من الشبكات متعددة الطبقات إلى النماذج المتكررة والتنبؤ باستخدام LSTM

Prepared by | إعداد: Dr.-Ing. Aouss Gabash


Learning Objectives

- Distinguish shallow and deep learning.
- Formulate forward propagation through multiple layers.
- Explain activation, loss, and gradient-based training.
- Understand CNN, RNN, and LSTM architectures.
- Select a suitable deep model for a power-system problem.
- Recognize overfitting, leakage, and distribution shift.

أهداف التعلم

- التمييز بين التعلم السطحي والعميق.
- صياغة الانتشار الأمامي عبر عدة طبقات.
- فهم دوال التفعيل والخسارة والتدريب.
- فهم CNN و RNN و LSTM.
- اختيار النموذج المناسب لمسألة نظام قدرة.
- التعرف على فرط التخصيص وتسرب البيانات وتغير توزيعها.

1. Deep Neural Networks



$$h^{(l)} = \varphi^{(l)}(W^{(l)}h^{(l-1)} + b^{(l)}), h^{(0)} = x$$

Depth enables hierarchical feature learning from raw measurements to engineering predictions.

1. الشبكات العصبية العميقة

تتعلم كل طبقة تمثيلاً أكثر تجريدًا للبيانات، وتبني الميزات المعقدة من ميزات أبسط.

2. Forward Propagation

$$z^1 = W^1x + b^1, h^1 = ReLU(z^1)$$

$$z^2 = W^2h^1 + b^2, h^2 = ReLU(z^2)$$

$$\hat{y} = W^3h^2 + b^3$$

2. الانتشار الأمامي

تمر بيانات الحمل والطقس والزمن عبر الطبقات بالتتابع حتى إنتاج قيمة الحمل المتنبأ بها.

3. Loss and Training

$$MSE = (1/N) \sum (\hat{y}_i - y_i)^2$$

$$\theta \leftarrow \theta - \eta \nabla_{\theta} J(\theta)$$

Learning Rate

Controls update size.

Batch Size

Samples per gradient estimate.

Epoch

One full pass through training data.

Validation Loss

Monitors generalization.

3. الخسارة والتدريب

يتم تحديث الأوزان بعكس اتجاه التدرج لتقليل الفرق بين التنبؤ والقيمة الحقيقية.

4. Activation Functions

Function	Expression	Typical Use
ReLU	$\max(0, z)$	Hidden layers
Sigmoid	$1/(1+e^{-z})$	Gates and probabilities
Tanh	$\tanh(z)$	Recurrent states
Linear	z	Regression output

4. دوال التفعيل

تمنح دوال التفعيل اللاخطية الشبكة القدرة على تمثيل العلاقات المعقدة.

5. Convolutional Neural Networks

$$y[k] = \sum_m w[m]x[k - m] + b$$

Waveforms

Fault and disturbance classification.

Spectrograms

Power-quality recognition.

Spatial Maps

Thermal and inspection images.

5. الشبكات الالتفافية CNN

تتعلم CNN مرشحات محلية تناسب أشكال الموجة والأطياف وصور المعدات.

6. Recurrent Neural Networks

$$h_t = \tanh(W_x x_t + W_h h_{t-1} + b)$$

$$\hat{y}_t = W_y h_t + b_y$$

Basic RNNs may suffer from vanishing or exploding gradients.

6. الشبكات المتكررة RNN

تحمل الشبكة حالة مخفية بين الخطوات الزمنية، لكنها قد تواجه صعوبة في تعلم الاعتماديات الطويلة.

7. Long Short-Term Memory

$$f_t = \sigma(Wf[x_t, h_{t-1}] + bf)$$

$$i_t = \sigma(Wi[x_t, h_{t-1}] + bi), g_t = \tanh(Wg[x_t, h_{t-1}] + bg)$$

$$c_t = f_t \odot c_{t-1} + i_t \odot g_t$$

$$o_t = \sigma(Wo[x_t, h_{t-1}] + bo), h_t = o_t \odot \tanh(c_t)$$

LSTM is useful for load, renewable generation, and price forecasting.

7. الذاكرة طويلة وقصيرة الأمد LSTM

تستخدم LSTM بوابات للتحكم بالمعلومات التي يتم نسيانها أو تخزينها أو إخراجها.

8. Sequence Construction

$$X_t = [P_{t-23}, \dots, P_t], target = P_{t+1}$$

Additional features may include temperature, hour, weekday, holidays, and renewable generation.

Split time-series data chronologically to avoid future-information leakage.

8. بناء المتتاليات

يمكن استخدام آخر 24 قيمة ساعية ومدخلات إضافية للتنبؤ بالساعة التالية، مع الحفاظ على التقسيم الزمني.

9. Power-System Applications

Load Forecasting

Short- and medium-term demand.

Renewable Forecasting

PV and wind estimation.

Fault Diagnosis

Classification from voltage and current.

Predictive Maintenance

Asset health and remaining life.

State Estimation

Measurement-to-state mappings.

Power Quality

Detection of disturbances.

9. تطبيقات نظم القدرة

تشمل التنبؤ بالحمل والمتجددة وتشخيص الأعطال والصيانة التنبؤية وتقدير الحالة وجودة القدرة.

10. Overfitting and Regularization

$$J_{regularized} = J_{data} + \lambda \sum w^2$$

- Dropout
- L2 regularization
- Early stopping
- Representative data

10. فرط التخصيص والتنظيم

تساعد Dropout و L2 والإيقاف المبكر والبيانات الممثلة على تحسين التعميم.

11. Model Evaluation

$$MAE = (1/N) \sum |\hat{y}_i - y_i|$$

Missing argument for \sqrt


$$MAPE = (100/N) \sum |(\hat{y}_i - y_i)/y_i|$$

Compare the deep model with a simple baseline such as persistence or linear regression.

11. تقييم النموذج

يجب تقييم الأخطاء ومقارنتها بخط أساس بسيط، وليس الاعتماد على مؤشر واحد فقط.

12. Engineering Workflow



12. سير العمل الهندسي

ابدأ بتحديد الهدف وتحضير البيانات وخط الأساس، ثم درب النموذج واختبره قبل النشر.



Review Questions

1. Why are nonlinear activations necessary?
2. What causes vanishing gradients?
3. How does LSTM preserve information?
4. Why must time-series data be split chronologically?
5. When might CNN be preferable to LSTM?

أسئلة المراجعة

1. لماذا نحتاج إلى دوال تفعيل لخطية؟
2. ما سبب تلاشي التدرج؟
3. كيف تحفظ LSTM المعلومات؟
4. لماذا يجب تقسيم السلاسل زمنيًا؟
5. متى تكون CNN أنسب من LSTM؟

References | المراجع

المراجع العامة المستخدمة في هذا المقرر

[1] A. Gabash, *Flexible Optimal Operations of Energy Supply Networks with Renewable Energy Generation and Battery Storage*. Saarbrücken, Germany: Südwestdeutscher Verlag für Hochschulschriften, 2014.

[2] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th Global ed. Harlow, U.K.: Pearson Education Limited, 2022.

[3] A. Gabash, "Energy Market Transition and Climate Change: A Review of TSOs-DSOs C++ Framework from 1800 to Present," *Energies*, vol. 16, no. 17, Art. no. 6139, 2023, doi: 10.3390/en16176139.

[4] A. Gabash, *AI Applications in Electrical Power Systems*, Version 1.0, 2026. [Online]. Available: <https://aoussgabash.com>

Publication Information | معلومات النشر

Document	Lecture 09 · Deep Learning for Power Systems
Course	AI Applications in Electrical Power Systems
Author	Dr.-Ing. Aouss Gabash
Version	1.0
Publication year	2026
Official website	https://aoussgabash.com
Citation style	IEEE

Recommended citation:

Gabash, A. (2026). Deep Learning for Power Systems. AI Applications in Electrical Power Systems, Lecture 09, Version 1.0. <https://aoussgabash.com>

المرجع المقترح:

أوس غباش، 2026، محاضرة 09، تطبيقات الذكاء الاصطناعي في أنظمة الطاقة الكهربائية، الإصدار 1.0، <https://aoussgabash.com>

© 2026 Dr.-Ing. Aouss Gabash. Educational use with attribution to the author and official website.



Interactive Quiz — Lecture 09

اختبار تفاعلي — المحاضرة 09

1. Why is an LSTM useful for load forecasting?

1. لماذا يفيد LSTM في التنبؤ بالحمل؟

- ☐ It ignores time order
يتجاهل ترتيب الزمن
- ☐ It models temporal dependencies
ينمذج الاعتماديات الزمنية
- ☐ It only clusters data
يجمع البيانات فقط
- ☐ It requires no training
لا يحتاج تدريباً

2. A CNN is especially effective at learning:

2. تكون CNN فعالة خصوصاً في تعلم:

- ☐ Only exact equations
المعادلات الدقيقة فقط

- Random labels

التسميات العشوائية

- Local patterns through convolution

الأنماط المحلية عبر الالتفاف

- No features

عدم وجود ميزات

3. What is an epoch?

3. ما هو العصر التدريبي Epoch؟

- One full pass through the training data

مرور كامل على بيانات التدريب

- One input feature

ميزة دخل واحدة

- One physical hour always

ساعة فيزيائية دائمًا

- One cluster center

مركز عنقود واحد

4. Dropout is commonly used to:

4. يستخدم Dropout عادة من أجل:

- Increase all weights

زيادة جميع الأوزان

- Remove the target

حذف الهدف

- Guarantee exact forecasts

ضمان تنبؤات دقيقة تمامًا

- Reduce overfitting

تقليل فرط التوافق

5. For time-series validation, data should usually be split:

5. في التحقق من السلاسل الزمنية، تقسم البيانات عادة:

- Randomly without regard to time

عشوائيًا دون اعتبار الزمن

- Chronologically

زمنيًا

- By color

حسب اللون

- By filename length

حسب طول اسم الملف

تُحفظ نتيجتك في هذا المتصفح فقط | Your result is stored only in this browser.