

## LECTURE 09 | 09 المحاضرة

# Deep Learning for Power Systems

## التعلم العميق في أنظمة الطاقة الكهربائية

From Multilayer Networks to Recurrent Models and LSTM Forecasting

من الشبكات متعددة الطبقات إلى النماذج المتكررة والتنبؤ باستخدام LSTM

Prepared by | إعداد: Dr.-Ing. Aouss Gabash



### Learning Outcomes

مخرجات التعلم

1. Select suitable deep-learning architectures for power-system data.  
اختيار بنى التعلم العميق المناسبة لبيانات أنظمة الطاقة.
2. Interpret the governing mathematical or algorithmic principles.  
تفسير المبادئ الرياضية أو الخوارزمية الحاكمة.
3. Connect the topic to practical electrical-power-engineering applications.  
ربط الموضوع بتطبيقات عملية في هندسة الطاقة الكهربائية.



### Prerequisite sites

المتطلبات  
السابقة

Lecture 06 and time-series fundamentals.

المحاضرة 06 وأساسيات  
السلاسل الزمنية.

#### Deep Learning for Power Systems |

التعلم العميق في أنظمة  
الطاقة




### Learning Objectives

- Distinguish shallow and deep learning.
- Formulate forward propagation through multiple layers.
- Explain activation, loss, and gradient-based training.
- Understand CNN, RNN, and LSTM architectures.
- Select a suitable deep model for a power-system problem.
- Recognize overfitting, leakage, and distribution shift.

## أهداف التعلم

- التمييز بين التعلم السطحي والعميق.
- صياغة الانتشار الأمامي عبر عدة طبقات.
- فهم دوال التفعيل والخسارة والتدريب.
- فهم CNN و RNN و LSTM.
- اختيار النموذج المناسب لمسألة نظام قدرة.
- التعرف على فرط التخصيص وتسرب البيانات وتغيير توزيعها.

## 1. Deep Neural Networks



$$h^{(l)} = \varphi^{(l)}(W^{(l)}h^{(l-1)} + b^{(l)}), h^{(0)} = x$$

Depth enables hierarchical feature learning from raw measurements to engineering predictions.

### 1. الشبكات العصبية العميقة

تتعلم كل طبقة تمثيلًا أكثر تجريدًا للبيانات، وتبني الميزات المعقدة من ميزات أبسط.

## 2. Forward Propagation

$$z^1 = W^1x + b^1, h^1 = \text{ReLU}(z^1)$$

$$z^2 = W^2 h^1 + b^2, h^2 = \text{ReLU}(z^2)$$

$$\hat{y} = W^3 h^2 + b^3$$

## 2. الانتشار الأمامي

تمر بيانات الحمل والطقس والزمن عبر الطبقات بالتتابع حتى إنتاج قيمة الحمل المتنبأ بها.

## 3. Loss and Training

$$MSE = (1/N) \sum (\hat{y}_i - y_i)^2$$

$$\theta \leftarrow \theta - \eta \nabla_{\theta} J(\theta)$$

### Learning Rate

Controls update size.

### Batch Size

Samples per gradient estimate.

### Epoch

One full pass through training data.

### Validation Loss

Monitors generalization.

### 3. الخسارة والتدريب

يتم تحديث الأوزان بعكس اتجاه التدرج لتقليل الفرق بين التنبؤ والقيمة الحقيقية.

### 4. Activation Functions

| Function | Expression     | Typical Use             |
|----------|----------------|-------------------------|
| ReLU     | $\max(0,z)$    | Hidden layers           |
| Sigmoid  | $1/(1+e^{-z})$ | Gates and probabilities |
| Tanh     | $\tanh(z)$     | Recurrent states        |
| Linear   | $z$            | Regression output       |

### 4. دوال التفعيل

تمنح دوال التفعيل اللاخطية الشبكة القدرة على تمثيل العلاقات المعقدة.

### 5. Convolutional Neural Networks

$$y[k] = \sum_m w[m]x[k - m] + b$$

**Waveforms**

Fault and disturbance classification.

**Spectrograms**

Power-quality recognition.

**Spatial Maps**

Thermal and inspection images.

## 5. الشبكات الالتفافية CNN

تتعلم CNN مرشحات محلية تناسب أشكال الموجة والأطياف وصور المعدات.

## 6. Recurrent Neural Networks

$$h_t = \tanh(W_x x_t + W_h h_{t-1} + b)$$

$$\hat{y}_t = W_y h_t + b_y$$

Basic RNNs may suffer from vanishing or exploding gradients.

## 6. الشبكات المتكررة RNN

تحمل الشبكة حالة مخفية بين الخطوات الزمنية، لكنها قد تواجه صعوبة في تعلم الاعتماديات الطويلة.

## 7. Long Short-Term Memory

$$f_t = \sigma(W_f[x_t, h_{t-1}] + b_f)$$

$$i_t = \sigma(W_i[x_t, h_{t-1}] + b_i), g_t = \tanh(W_g[x_t, h_{t-1}] + b_g)$$

$$c_t = f_t \odot c_{t-1} + i_t \odot g_t$$

$$o_t = \sigma(Wo[x_t, h_{t-1}] + bo), h_t = o_t \odot \tanh(c_t)$$

LSTM is useful for load, renewable generation, and price forecasting.

## 7. الذاكرة طويلة وقصيرة الأمد LSTM

تستخدم LSTM بوابات للتحكم بالمعلومات التي يتم نسيانها أو تخزينها أو إخراجها.

## 8. Sequence Construction

$$X_t = [P_{t-23}, \dots, P_t], target = P_{t+1}$$

Additional features may include temperature, hour, weekday, holidays, and renewable generation.

Split time-series data chronologically to avoid future-information leakage.

## 8. بناء المتتاليات

يمكن استخدام آخر 24 قيمة ساعية ومدخلات إضافية للتنبؤ بالساعة التالية، مع الحفاظ على التقسيم الزمني.

## 9. Power-System Applications

### Load Forecasting

Short- and medium-term demand.

### Renewable Forecasting

PV and wind estimation.

### Fault Diagnosis

Classification from voltage and current.

### Predictive Maintenance

Asset health and remaining life.

**State Estimation**

Measurement-to-state mappings.

**Power Quality**

Detection of disturbances.

## 9. تطبيقات نظم القدرة

تشمل التنبؤ بالحمل والمتجددة وتشخيص الأعطال والصيانة التنبؤية وتقدير الحالة وجودة القدرة.

## 10. Overfitting and Regularization

$$J_{regularized} = J_{data} + \lambda \sum w^2$$

- Dropout
- L2 regularization
- Early stopping
- Representative data

## 10. فرط التخصيص والتنظيم

تساعد Dropout و L2 والإيقاف المبكر والبيانات الممثلة على تحسين التعميم.

## 11. Model Evaluation

$$MAE = (1/N) \sum |\hat{y}_i - y_i|$$

Missing argument for sqrt


$$MAPE = (100/N) \sum |(\hat{y}_i - y_i)/y_i|$$

Compare the deep model with a simple baseline such as persistence or linear regression.

## 11. تقييم النموذج

يجب تقييم الأخطاء ومقارنتها بخط أساس بسيط، وليس الاعتماد على مؤشر واحد فقط.

## 12. Engineering Workflow



## 12. سير العمل الهندسي

ابدأ بتحديد الهدف وتحضير البيانات وخط الأساس، ثم درب النموذج واختبره قبل النشر.



## Review Questions

1. Why are nonlinear activations necessary?
2. What causes vanishing gradients?
3. How does LSTM preserve information?
4. Why must time-series data be split chronologically?
5. When might CNN be preferable to LSTM?

## أسئلة المراجعة

1. لماذا نحتاج إلى دوال تفعيل لاخطية؟



2. ما سبب تلاشي التدرج؟
3. كيف تحفظ LSTM المعلومات؟
4. لماذا يجب تقسيم السلاسل زمنيًا؟
5. متى تكون CNN أنسب من LSTM؟

---

## References | المراجع

---

المراجع العامة المستخدمة في هذا المقرر

- [1] A. Gabash, *Flexible Optimal Operations of Energy Supply Networks with Renewable Energy Generation and Battery Storage*. Saarbrücken, Germany: Südwestdeutscher Verlag für Hochschulschriften, 2014.
- [2] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th Global ed. Harlow, U.K.: Pearson Education Limited, 2022.
- [3] A. Gabash, "Energy Market Transition and Climate Change: A Review of TSOs-DSOs C+++ Framework from 1800 to Present," *Energies*, vol. 16, no. 17, Art. no. 6139, 2023, doi: 10.3390/en16176139.
- [4] A. Gabash, *AI Applications in Electrical Power Systems*, Version 1.0, 2026. [Online]. Available: <https://aoussgabash.com>

---

### Recommended citation:

Gabash, A. (2026). Deep Learning for Power Systems. AI Applications in Electrical Power Systems, Lecture 09, Version 1.0. <https://aoussgabash.com>

---

المرجع المقترح:

أوس غباش، 2026، محاضرة 09، تطبيقات الذكاء الاصطناعي في أنظمة الطاقة الكهربائية، الإصدار 1.0، <https://aoussgabash.com>

---

© 2026 Dr.-Ing. Aouss Gabash. Educational use with attribution to the author and official website.