

Deep Learning for Power Systems

التعلم العميق في أنظمة الطاقة الكهربائية

From multilayer networks to recurrent models and LSTM-based forecasting

LSTM من الشبكات متعددة الطبقات إلى النماذج المتكررة والتنبؤ باستخدام

Objectives

Deep Networks

Training

CNN

RNN

LSTM

Applications

Prepared by | إعداد: Dr.-Ing. Aouss Gabash

Learning Objectives


- Distinguish shallow learning from deep learning.
- Formulate forward propagation through multiple hidden layers.
- Explain activation functions, loss functions, and gradient-based training.
- Understand CNN, RNN, and LSTM architectures.
- Select a suitable deep model for a power-system problem.
- Recognize overfitting, data leakage, and distribution shift.

أهداف التعلم

- التمييز بين التعلم السطحي والتعلم العميق.
- صياغة الانتشار الأمامي عبر عدة طبقات مخفية.
- فهم دوال التفعيل والخسارة والتدريب المعتمد على التدرج.
- فهم بنى CNN و RNN و LSTM.
- اختيار البنية المناسبة لمسألة في نظام القدرة.
- التعرف على فرط التخصيص وتسرب البيانات وتغير توزيعها.

1. What Makes a Network “Deep”?

A deep neural network contains several trainable representation layers between input and output.



$$h^{(l)} = \varphi^{(l)}(W^{(l)}h^{(l-1)} + b^{(l)}), h^{(0)} = x$$

Depth enables the model to build hierarchical features: raw measurements → local patterns → operating states → engineering prediction.

1. متى تُسمّى الشبكة عميقة؟

تحتوي الشبكة العميقة على عدة طبقات قابلة للتدريب بين الدخل والخرج، وتتعلم كل طبقة تمثيلًا أكثر تجريدًا للبيانات.

$$h^{(l)} = \varphi^{(l)}(W^{(l)}h^{(l-1)} + b^{(l)})$$

يمكن للطبقات الأولى تعلم الأنماط المحلية، بينما تجمع الطبقات الأعمق هذه الأنماط لتتعرف على حالات تشغيل معقدة.

2. Forward Propagation Example

For a two-hidden-layer model:

$$z^1 = W^1x + b^1, h^1 = \text{ReLU}(z^1), z^2 = W^2h^1 + b^2, h^2 = \text{ReLU}(z^2), \hat{y} = W^3h^2 + b^3$$

For load forecasting, the output can be a real-valued active-power estimate in MW.

2. مثال على الانتشار الأمامي

تمر بيانات الحمل والطقس والزمن عبر الطبقات بالتتابع. في مسائل الانحدار يكون الخرج رقمًا حقيقيًا، مثل الحمل المتوقع بالميجاواط.

3. Loss Function and Training

For a dataset of N samples, a common regression loss is mean squared error:

$$MSE = (1/N) \sum_{i=1}^N (\hat{y}_i - y_i)^2$$

Parameters are updated using gradient descent or an adaptive optimizer such as Adam:

$$\theta \leftarrow \theta - \eta \nabla_{\theta} J(\theta)$$

 η : Learning rate

Controls update size.

Batch size

Number of samples per gradient estimate.

Epoch

One complete pass through training data.

Validation loss

Monitors generalization during training.

3. دالة الخسارة والتدريب

يهدف التدريب إلى تقليل الفرق بين الخرج المتوقع والقيمة الحقيقية. يتم تحديث جميع الأوزان والانزياحات بعكس اتجاه تدرج الخسارة.

$$\theta \leftarrow \theta - \eta \nabla_{\theta} J(\theta)$$

4. Activation Functions

Function	Expression	Typical use	Remark
ReLU	$\max(0, z)$	Hidden layers	Fast and widely used
Sigmoid	$1/(1+e^{-z})$	Gates / probabilities	Can saturate
Tanh	$\tanh(z)$	Recurrent states	Zero-centered
Linear	z	Regression output	Unbounded output

4. دوال التفعيل

تضيف دالة التفعيل اللاخطية القدرة على تمثيل العلاقات المعقدة. دونها تصبح عدة طبقات خطية مكافئة لطبقة خطية واحدة.

5. Convolutional Neural Networks (CNN)

CNNs learn local filters shared across a signal or image. In power engineering they can process:

Waveforms

Fault and disturbance classification.

Spectrograms

Power-quality event recognition.

Spatial maps

Thermal or asset inspection images.

$$y[k] = \sum_m w[m]x[k - m] + b$$

5. الشبكات الالتفافية CNN

تتعلم CNN مرشحات محلية تُطبَّق على كامل الإشارة. لذلك تناسب تحليل أشكال الموجة والأطياف وصور المعدات الكهربائية.

6. Recurrent Neural Networks (RNN)

Time-series problems require memory. An RNN carries a hidden state from one time step to the next:

$$h_t = \tanh(W_x x_t + W_h h_{t-1} + b)$$

$$\hat{y}_t = W_y h_t + b_y$$

Basic RNNs may suffer from vanishing or exploding gradients when learning long-term dependencies.

6. الشبكات العصبية المتكررة RNN

تحمل الشبكة حالة مخفية من لحظة إلى اللحظة التالية، ولهذا تستطيع استخدام التاريخ الزمني. لكن الشبكة التقليدية قد تواجه صعوبة في الاحتفاظ بالمعلومات البعيدة.

7. Long Short-Term Memory (LSTM)

LSTM introduces gates that regulate what is forgotten, written, and exposed.

$$f_t = \sigma(W_f[x_t, h_{t-1}] + b_f) \text{ Forgetgate } i_t = \sigma(W_i[x_t, h_{t-1}] + b_i) \text{ Inputgate}$$

The cell state c_t provides a controlled path for long-term information, making LSTM useful for electrical load, renewable generation, and price forecasting.

7. الذاكرة طويلة وقصيرة الأمد LSTM

تستخدم LSTM بوابات نسيان وإدخال وإخراج للتحكم بالمعلومة التي تبقى في ذاكرة الخلية، ولذلك تستطيع التقاط الأنماط اليومية والأسبوعية والموسمية.

لا تعني الذاكرة أن النموذج "يفهم" الزمن؛ بل يتعلم رياضياً أي معلومات سابقة تساعد على تقليل خطأ التنبؤ.

8. Sequence Construction for Load Forecasting

A supervised sample can use the previous 24 hourly values to predict the next hour:

$$X_t = [P_{t-23}, \dots, P_t], \text{target} = P_{t+1}$$

Additional features may include temperature, hour of day, weekday, holiday indicator, and renewable generation.

Split data chronologically. Random shuffling before train/test separation can leak future information into the training set.

8. بناء المتتاليات للتنبؤ بالحمل

يمكن استخدام آخر 24 قيمة ساعية كدخل لتوقع الساعة التالية، مع إضافة درجة الحرارة والساعة واليوم والعطل الرسمية.

يجب تقسيم بيانات السلاسل الزمنية زمنياً، لأن الخلط العشوائي قد يسمح للنموذج برؤية معلومات من المستقبل.

9. Applications in Electrical Power Systems

Load forecasting

Short- and medium-term demand prediction.

Renewable forecasting

PV and wind power estimation.

Fault diagnosis

Classification from current and voltage signals.

Predictive maintenance

Asset health and remaining useful life.

State estimation

Learning nonlinear measurement-to-state mappings.

Power quality

Detection of sags, swells, harmonics, and transients.

9. التطبيقات في أنظمة القدرة الكهربائية

تشمل التطبيقات التنبؤ بالحمل والطاقة المتجددة، تشخيص الأعطال، الصيانة التنبؤية، تقدير الحالة، وتصنيف اضطرابات جودة القدرة.

10. Overfitting and Regularization

Dropout

Randomly disables units during training.

L2 regularization

Penalizes large weights.

Early stopping

Stops when validation performance no longer improves.

More representative data

Covers seasons and operating conditions.

$$J_{regularized} = J_{data} + \lambda \sum w^2$$

10. فرط التخصيص والتنظيم

يحدث فرط التخصيص عندما يحفظ النموذج بيانات التدريب ولا يعمم جيدًا. من وسائل الحد منه: الإسقاط، تنظيم L2، الإيقاف المبكر، وبيانات أكثر تمثيلًا.

11. Model Evaluation

$$MAE = (1/N) \sum |\hat{y}_i - y_i|$$

Missing argument for \sqrt


$$MAPE = (100/N) \sum |(\hat{y}_i - y_i)/y_i|$$

Always compare the deep model with a simple baseline such as persistence, moving average, or linear regression.

11. تقييم النموذج

تُستخدم MAE و RMSE و MAPE، لكن لا تكفي قيمة واحدة للحكم. يجب فحص الأخطاء حسب الساعة واليوم والموسم ومقارنتها بخط أساس بسيط.

12. Engineering Workflow



12. سير العمل الهندسي

ابدأ بتعريف الهدف ومقياس النجاح، ثم حصّر البيانات وابن خط أساس، وبعدها درّب النموذج العميق واختبره خارج بيانات التدريب قبل النشر.

Review Questions

1. Why are nonlinear activation functions necessary?
2. What causes vanishing gradients in recurrent networks?
3. How does the LSTM cell state help preserve information?
4. Why must time-series data be split chronologically?
5. When might a CNN be preferable to an LSTM?

أسئلة المراجعة

1. لماذا نحتاج إلى دوال تفعيل لاقطية؟
2. ما مشكلة تلاشي التدرج في الشبكات المتكررة؟
3. كيف تساعد حالة خلية LSTM على حفظ المعلومات؟
4. لماذا يجب تقسيم السلاسل الزمنية زمنيًا؟
5. متى تكون CNN أنسب من LSTM؟