

# Transformer Models and Attention

نماذج المحوّل وآلية الانتباه

Modern sequence modeling for load, renewable-energy, and grid-event forecasting

نمذجة حديثة للسلاسل الزمنية في الأحمال والطاقة المتجددة وأحداث الشبكة

Objectives

Attention

Self-Attention

Multi-Head

Position

Power Applications

Prepared by | إعداد: Dr.-Ing. Aouss Gabash | د. م. أوس غباش

## Learning Objectives


- Explain why recurrence is not required in transformer models.
- Derive scaled dot-product attention from queries, keys, and values.
- Understand self-attention, multi-head attention, and positional encoding.
- Describe an encoder block and residual connections.
- Compare transformers with RNN and LSTM for power-system time series.
- Recognize data, computation, and interpretability limitations.

## أهداف التعلم

- فهم سبب عدم حاجة Transformer إلى التكرار الزمني التقليدي.
- اشتقاق الانتباه النقطي المُقاس من Q و K و V.
- فهم الانتباه الذاتي ومتعدد الرؤوس والترميز الموضعي.
- شرح كتلة Encoder والوصلات المتبقية.
- مقارنة Transformer مع RNN و LSTM في بيانات الطاقة.
- معرفة القيود الحسابية والبيانية والتفسيرية.

# 1. Why Transformers?

RNNs process a sequence step by step. Transformers instead compare time steps directly through attention.



A transformer can learn that the load at 18:00 today is strongly related to 18:00 yesterday, even when many time steps separate them.

## 1. لماذا نستخدم Transformer؟

تعالج RNN البيانات خطوة بعد خطوة، بينما تسمح آلية الانتباه لكل خطوة زمنية بالنظر مباشرة إلى الخطوات الأخرى وتحديد أهميتها.

# 2. Query, Key, and Value

For each input representation  $x_t$ , three learned projections are created:

$$q_t = WQx_t, k_t = WKx_t, v_t = WVx_t$$

### Query Q

What information is this time step looking for?

### Key K

What information does each time step offer?

### Value V

What content is transferred if a step is relevant?

## 2. الاستعلام والمفتاح والقيمة

يُحوّل كل متجه دخل إلى ثلاثة متجهات متعلمة: الاستعلام Q، المفتاح K، والقيمة V. يحدد التشابه بين Q و K مقدار الاستفادة من V.

## 3. Scaled Dot-Product Attention

$$S = QK^T$$

Large dot products can make softmax too sharp. Therefore, scale by the square root of key dimension  $d_k$ :

$$A = \text{softmax}(QK^T/\sqrt{dk})$$

$$\text{Attention}(Q, K, V) = AV$$

Each row of A sums to one and represents how one time step distributes attention over the full sequence.

### 3. الانتباه النقطي المُقاس

تُحسب درجات التشابه بين الاستعلامات والمفاتيح، ثم تُقسم على  $d_k\sqrt{}$  وتُمرر عبر Softmax. بعد ذلك تُستخدم الأوزان لجمع متجهات القيمة.

## 4. Numerical Example

Suppose one query has similarities [2, 1, 0] with three keys.

$$\text{softmax}([2, 1, 0]) \approx [0.665, 0.245, 0.090]$$

The first time step contributes about 66.5% of the context, the second 24.5%, and the third 9%.

### 4. مثال عددي

إذا كانت درجات التشابه  $[2, 1, 0]$ ، فإن Softmax تحولها إلى أوزان موجبة مجموعها واحد، ويصبح العنصر الأول الأكثر تأثيرًا.

## 5. Multi-Head Attention

One attention head may focus on short-term variation, another on daily periodicity, and another on weather-related dependencies.

$$head_i = Attention(QW_iQ, KW_iK, VW_iV)$$

$$MultiHead = Concat(head_1, \dots, head_h)WO$$

### 5. الانتباه متعدد الرؤوس

يتيح تعدد الرؤوس تعلم أنواع مختلفة من العلاقات في الوقت نفسه، مثل العلاقة مع الساعة السابقة، واليوم السابق، ونمط نهاية الأسبوع.

## 6. Positional Information

Attention alone does not know sequence order. A position representation is added to each time step.

$$z_t = x_t + p_t$$


Positions can be learned or generated using sinusoidal functions.

$$PE(pos, 2i) = \sin(pos/10000^{2i/d}) \quad PE(pos, 2i + 1) = \cos(pos/10000^{2i/d})$$

## 6. المعلومات الموضعية

آلية الانتباه لا تعرف تلقائيًا ترتيب الزمن، لذلك نضيف تمثيلًا لموضع كل خطوة. يمكن تعلم هذا التمثيل أو حسابه بدوال جيبيّة.

## 7. Transformer Encoder Block



$$FFN(x) = W_2 \varphi(W_1 x + b_1) + b_2$$

Residual connections preserve information and improve gradient flow through deep stacks.

## 7. كتلة Encoder

تتكون من انتباه متعدد الرؤوس، وصلة متبقية مع تطبيع، ثم شبكة أمامية صغيرة لكل خطوة، ثم وصلة متبقية أخرى.

## 8. Causal and Non-Causal Attention

### Non-causal

Every position can see all positions. Useful for classification or complete-window regression.

### Causal

A position can only attend to present and past steps. Necessary for autoregressive forecasting.

Using future samples inside the attention window during training creates information leakage and unrealistically optimistic accuracy.

## 8. الانتباه السببي وغير السببي

في التنبؤ الذاتي يجب منع النموذج من رؤية المستقبل باستخدام قناع سببي. أما عند تلخيص نافذة تاريخية مكتملة لتوقع قيمة واحدة، فيمكن استخدام النافذة كلها.

## 9. Transformer vs. LSTM

| Aspect              | LSTM                  | Transformer                  |
|---------------------|-----------------------|------------------------------|
| Sequence processing | Step-by-step          | Parallel within a window     |
| Long dependencies   | Controlled memory     | Direct attention paths       |
| Data requirement    | Often moderate        | Often larger                 |
| Computational cost  | Linear recurrence     | Attention often $O(T^2)$     |
| Interpretability    | Hidden-state analysis | Attention maps, with caution |

### 9. مقارنة Transformer و LSTM

يمتاز Transformer بالتوازي والوصول المباشر للعلاقات البعيدة، لكنه قد يحتاج بيانات وحوسبة أكبر، خصوصًا عندما تطول المتتالية.

## 10. Applications in Electrical Power Systems

### Load forecasting

Hourly and day-ahead demand prediction.



### **PV forecasting**

Combining historical output and weather variables.

### **Wind forecasting**

Learning delayed weather-power dependencies.

### **Electricity prices**

Capturing market and calendar interactions.

### **Event detection**

Classifying disturbances from multichannel sequences.

### **Asset monitoring**

Long-window condition and degradation analysis.

## **10. التطبيقات في أنظمة الطاقة**

تشمل التنبؤ بالأحمال والطاقة الشمسية والرياح والأسعار، وتحليل أحداث الشبكة ومراقبة حالة المعدات.

## **11. Practical Design Choices**

- Sequence length and forecast horizon

- Number of attention heads
- Embedding dimension
- Number of encoder blocks
- Dropout and regularization
- Feature engineering and normalization

The embedding dimension should be compatible with the number of heads so each head receives a meaningful channel subspace.

## 11. خيارات التصميم العملية

من أهم الخيارات طول النافذة، عدد الرؤوس، بعد التمثيل، عدد الكتل، نسبة الإسقاط، وطريقة تجهيز الميزات.

## 12. Limitations and Common Mistakes

### Small datasets

A large transformer may overfit.

### Long windows

Attention matrices grow quadratically.

### Leakage

Future features may accidentally enter training inputs.

### Attention $\neq$ explanation

High attention weight is not always a causal explanation.

## 12. القيود والأخطاء الشائعة

أكثر المشكلات شيوعًا هي قلة البيانات، تضخم الكلفة مع النوافذ الطويلة، تسرب المستقبل، واعتبار خريطة الانتباه تفسيرًا سببيًا كاملاً.



### Research Corner

**Emerging directions:** Temporal Fusion Transformers, sparse attention, probabilistic forecasting, multimodal weather-grid models, and physics-guided transformer architectures.

## زاوية البحث العلمي

من الاتجاهات الحديثة: Temporal Fusion Transformer، الانتباه المتناثر، التنبؤ الاحتمالي، دمج بيانات الطقس والشبكة، ودمج القيود الفيزيائية ضمن النموذج.



### Review Questions

1. Why is the factor  $\sqrt{d_k}$  used?
2. What do Q, K, and V represent?

3. Why is positional encoding required?
4. What is the difference between causal and non-causal attention?
5. Why can attention cost grow quadratically?

## أسئلة المراجعة 🧠

1. لماذا نقسم على  $d_k$ ؟
2. ما معنى  $Q$  و  $K$  و  $V$ ؟
3. لماذا نحتاج الترميز الموضعي؟
4. ما الفرق بين الانتباه السببي وغير السببي؟
5. لماذا تنمو كلفة الانتباه تربيعيًا؟