

Transformer Models and Attention

نماذج المحوّل وآلية الانتباه

Modern sequence modeling for load, renewable-energy, and grid-event forecasting

نمذجة حديثة للسلاسل الزمنية في الأحمال والطاقة المتجددة وأحداث الشبكة

Objectives

Attention

Self-Attention

Multi-Head

Position

Power Applications

Learning Objectives


- Explain why recurrence is not required in transformer models.
- Derive scaled dot-product attention from queries, keys, and values.
- Understand self-attention, multi-head attention, and positional encoding.
- Describe an encoder block and residual connections.
- Compare transformers with RNN and LSTM for power-system time series.
- Recognize data, computation, and interpretability limitations.

أهداف التعلم

- فهم سبب عدم حاجة Transformer إلى التكرار الزمني التقليدي.
- اشتقاق الانتباه النقطي المُقاس من Q و K و V.
- فهم الانتباه الذاتي ومتعدد الرؤوس والترميز الموضعي.
- شرح كتلة Encoder والوصلات المتبقية.
- مقارنة Transformer مع RNN و LSTM في بيانات الطاقة.
- معرفة القيود الحسابية والبيانية والتفسيرية.

1. Why Transformers?

RNNs process a sequence step by step. Transformers instead compare time steps directly through attention.



A transformer can learn that the load at 18:00 today is strongly related to 18:00 yesterday, even when many time steps separate them.

1. لماذا نستخدم Transformer؟

تعالج RNN البيانات خطوة بعد خطوة، بينما تسمح آلية الانتباه لكل خطوة زمنية بالنظر مباشرة إلى الخطوات الأخرى وتحديد أهميتها.

2. Query, Key, and Value

For each input representation x_t , three learned projections are created:

$$q_t = W_Q x_t, \quad k_t = W_K x_t, \quad v_t = W_V x_t$$

Query Q

What information is this time step looking for?

Key K

What information does each time step offer?

Value V

What content is transferred if a step is relevant?

2. الاستعلام والمفتاح والقيمة

يُحوّل كل متجه دخل إلى ثلاثة متجهات متعلمة: الاستعلام Q، المفتاح K، والقيمة V. يحدد التشابه بين Q و K مقدار الاستفادة من V.

3. Scaled Dot-Product Attention

$$S = QK^T$$

Large dot products can make softmax too sharp. Therefore, scale by the square root of key dimension d_k :

$$A = \text{softmax}(QK^T / \sqrt{d_k})$$

$$\text{Attention}(Q, K, V) = AV$$

Each row of A sums to one and represents how one time step distributes attention over the full sequence.

3. الانتباه النقطي المُقاس

تُحسب درجات التشابه بين الاستعلامات والمفاتيح، ثم تُقسم على d_k وتُمرر عبر Softmax. بعد ذلك تُستخدم الأوزان لجمع متجهات القيمة.

4. Numerical Example

Suppose one query has similarities [2, 1, 0] with three keys.

$$\text{softmax}([2,1,0]) \approx [0.665, 0.245, 0.090]$$

The first time step contributes about 66.5% of the context, the second 24.5%, and the third 9%.

4. مثال عددي

إذا كانت درجات التشابه [2,1,0]، فإن Softmax تحولها إلى أوزان موجبة مجموعها واحد، ويصبح العنصر الأول الأكثر تأثيرًا.

5. Multi-Head Attention

One attention head may focus on short-term variation, another on daily periodicity, and another on weather-related dependencies.

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$

$$\text{MultiHead} = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O$$

5. الانتباه متعدد الرؤوس

يتيح تعدد الرؤوس تعلم أنواع مختلفة من العلاقات في الوقت نفسه، مثل العلاقة مع الساعة السابقة، واليوم السابق، ونمط نهاية الأسبوع.

6. Positional Information

Attention alone does not know sequence order. A position representation is added to each time step.

$$z_t = x_t + p_t$$


Positions can be learned or generated using sinusoidal functions.

$$\begin{aligned} PE(pos, 2i) &= \sin(pos/10000^{2i/d}) \\ PE(pos, 2i+1) &= \cos(pos/10000^{2i/d}) \end{aligned}$$

6. المعلومات الموضعية

آلية الانتباه لا تعرف تلقائيًا ترتيب الزمن، لذلك نضيف تمثيلًا لموضع كل خطوة. يمكن تعلم هذا التمثيل أو حسابه بدوال جيبية.

7. Transformer Encoder Block



Feed-Forward Network



Add & Normalize

$$\text{FFN}(x) = W_2 \phi(W_1 x + b_1) + b_2$$

Residual connections preserve information and improve gradient flow through deep stacks.

7. كتلة Encoder

تتكون من انتباه متعدد الرؤوس، وصلة متبقية مع تطبيع، ثم شبكة أمامية صغيرة لكل خطوة، ثم وصلة متبقية أخرى.

8. Causal and Non-Causal Attention

Non-causal

Every position can see all positions.
Useful for classification or complete-window regression.

Causal

A position can only attend to present and past steps. Necessary for autoregressive forecasting.

Using future samples inside the attention window during training creates information leakage and unrealistically optimistic accuracy.

8. الانتباه السببي وغير السببي

في التنبؤ الذاتي يجب منع النموذج من رؤية المستقبل باستخدام قناع سببي. أما عند تلخيص نافذة تاريخية مكتملة لتوقع قيمة واحدة، فيمكن استخدام النافذة كلها.

9. Transformer vs. LSTM

Aspect	LSTM	Transformer
Sequence processing	Step-by-step	Parallel within a window
Long dependencies	Controlled memory	Direct attention paths
Data requirement	Often moderate	Often larger
Computational cost	Linear recurrence	Attention often $O(T^2)$
Interpretability	Hidden-state analysis	Attention maps, with caution

9. مقارنة LSTM و Transformer

يمتاز Transformer بالتوازي والوصول المباشر للعلاقات البعيدة، لكنه قد يحتاج بيانات وحوسبة أكبر، خصوصًا عندما تطول المتتالية.

10. Applications in Electrical Power Systems

Load forecasting

Hourly and day-ahead demand prediction.

PV forecasting

Combining historical output and weather variables.

Wind forecasting

Learning delayed weather-power dependencies.

Electricity prices

Capturing market and calendar interactions.

Event detection

Classifying disturbances from multichannel sequences.

Asset monitoring

Long-window condition and degradation analysis.

10. التطبيقات في أنظمة الطاقة

تشمل التنبؤ بالأحمال والطاقة الشمسية والرياح والأسعار، وتحليل أحداث الشبكة ومراقبة حالة المعدات.

11. Practical Design Choices

- Sequence length and forecast horizon
- Number of attention heads
- Embedding dimension
- Number of encoder blocks
- Dropout and regularization
- Feature engineering and normalization

The embedding dimension should be compatible with the number of heads so each head receives a meaningful channel subspace.

11. خيارات التصميم العملية

من أهم الخيارات طول النافذة، عدد الرؤوس، بعد التمثيل، عدد الكتل، نسبة الإسقاط، وطريقة تجهيز الميزات.

12. Limitations and Common Mistakes

Small datasets

A large transformer may overfit.

Long windows

Attention matrices grow quadratically.

Leakage

Future features may accidentally enter training inputs.

Attention $\neq$ explanation

High attention weight is not always a causal explanation.

12. القيود والأخطاء الشائعة

أكثر المشكلات شيوعًا هي قلة البيانات، تضخم الكلفة مع النوافذ الطويلة، تسرب المستقبل، واعتبار خريطة الانتباه تفسيرًا سببيًا كاملاً.



Research Corner

Emerging directions: Temporal Fusion Transformers, sparse attention, probabilistic forecasting, multimodal weather-grid models, and physics-guided transformer architectures.

من الاتجاهات الحديثة: Temporal Fusion Transformer، الانتباه المتناثر، التنبؤ الاحتمالي، دمج بيانات الطقس والشبكة، ودمج القيود الفيزيائية ضمن النموذج.

Review Questions

1. Why is the factor $\sqrt{d_k}$ used?
2. What do Q, K, and V represent?
3. Why is positional encoding required?
4. What is the difference between causal and non-causal attention?
5. Why can attention cost grow quadratically?

أسئلة المراجعة

1. لماذا نقسم على $\sqrt{d_k}$ ؟
2. ما معنى Q و K و V؟
3. لماذا نحتاج الترميز الموضعي؟
4. ما الفرق بين الانتباه السببي وغير السببي؟
5. لماذا تنمو كلفة الانتباه تربيعيًا؟