

## LECTURE 10 | المحاضرة 10

# Transformer Models and Attention

## نماذج المحوّل وآلية الانتباه

Modern Sequence Modeling for Load, Renewable-Energy, and Grid-Event Forecasting

نمذجة حديثة للسلاسل الزمنية في الأحمال والطاقة المتجددة وأحداث الشبكة

Prepared by | إعداد: Dr.-Ing. Aouss Gabash


### Learning Objectives

- Explain why recurrence is not required in Transformer models.
- Derive scaled dot-product attention from queries, keys, and values.
- Understand self-attention, multi-head attention, and positional encoding.
- Describe an encoder block and residual connections.
- Compare Transformers with RNN and LSTM for power-system time series.
- Recognize computational and interpretability limitations.

### أهداف التعلم

- فهم سبب عدم حاجة Transformer إلى التكرار الزمني التقليدي.
- اشتقاق الانتباه النقطي المقاس من Q و K و V.
- فهم الانتباه الذاتي ومتعدد الرؤوس والترميز الموضعي.
- شرح كتلة Encoder والوصلات المتبقية.
- مقارنة Transformer مع RNN و LSTM.
- معرفة القيود الحسابية والتفسيرية.

# 1. Why Transformers?



Attention allows distant time steps to interact directly instead of passing information sequentially through every intermediate step.

## 1. لماذا نستخدم Transformer؟

تسمح آلية الانتباه لكل خطوة زمنية بالنظر مباشرة إلى الخطوات الأخرى وتحديد أهميتها.

# 2. Query, Key, and Value

$$q_t = WQx_t, k_t = WKx_t, v_t = WVx_t$$

### Query Q

What information is this step seeking?

### Key K

What information does each step offer?

### Value V

What content is transferred?

## 2. الاستعلام والمفتاح والقيمة

يحدد التشابه بين Q و K مقدار الاستفادة من V في بناء السياق.

### 3. Scaled Dot-Product Attention

$$S = QK^T$$

$$A = \text{softmax}(QK^T/\sqrt{dk})$$

$$\text{Attention}(Q, K, V) = AV$$

Each row of A sums to one and represents the attention distribution of one time step.

## 3. الانتباه النقطي المقاس

تُحسب درجات التشابه ثم تُقسم على  $\sqrt{dk}$  وتُمرر عبر Softmax للحصول على أوزان الانتباه.

### 4. Numerical Example

$$\text{softmax}([2, 1, 0]) \approx [0.665, 0.245, 0.090]$$

The first item contributes most strongly to the resulting context.

## 4. مثال عددي

تحويل Softmax الدرجات إلى أوزان موجبة مجموعها واحد، ويكون العنصر الأول الأكثر تأثيرًا.

## 5. Multi-Head Attention

$$head_i = Attention(QW_iQ, KW_iK, VW_iV)$$

$$MultiHead = Concat(head_1, \dots, head_h)WO$$

Different heads can learn short-term variation, daily periodicity, and weather-related dependencies simultaneously.

## 5. الانتباه متعدد الرؤوس

يتيح تعدد الرؤوس تعلم أنواع مختلفة من العلاقات الزمنية في الوقت نفسه.

## 6. Positional Information

$$z_t = x_t + p_t$$

$$PE(pos, 2i) = \sin(pos/100002i/d)$$


$$PE(pos, 2i + 1) = \cos(pos/100002i/d)$$

Attention alone does not know sequence order, so positional information must be added.

## 6. المعلومات الموضعية

يُضاف تمثيل لموضع كل خطوة لأن الانتباه وحده لا يعرف ترتيب الزمن.

## 7. Transformer Encoder Block



$$FFN(x) = W_2 \varphi(W_1 x + b_1) + b_2$$

Residual connections preserve information and improve gradient flow.

## 7. كتلة Encoder

تتكون من الانتباه متعدد الرؤوس والوصلات المتبقية والتطبيع وشبكة تغذية أمامية.

## 8. Causal and Non-Causal Attention

### Causal Attention

Prevents access to future time steps.

### Non-Causal Attention

Allows access to the full input window.

Forecasting systems must prevent future-information leakage.

## 8. الانتباه السببي وغير السببي

يمنع الانتباه السببي الوصول إلى المستقبل، وهو ضروري في التنبؤ الزمني الحقيقي.

## 9. Transformer vs RNN and LSTM

| Property                | RNN/LSTM            | Transformer            |
|-------------------------|---------------------|------------------------|
| Processing              | Sequential          | Parallel over sequence |
| Long-range dependencies | Possible but harder | Direct attention links |
| Memory cost             | Moderate            | Can grow quadratically |
| Small datasets          | Often competitive   | May overfit            |

## 9. مقارنة Transformer مع RNN و LSTM

يمتاز Transformer بالمعالجة المتوازية والروابط المباشرة، لكنه قد يحتاج إلى بيانات وحوسبة أكبر.

## 10. Applications in Power Systems

**Load Forecasting**  
Short- and long-horizon demand.

**Renewable Forecasting**  
PV and wind time series.

**Event Detection**  
Disturbances and anomalies.

**Price Forecasting**  
Market time-series modeling.

**State Estimation**  
Temporal measurement relationships.

**Asset Monitoring**  
Long-term sensor patterns.

## 10. التطبيقات في نظم القدرة

تشمل التنبؤ بالحمل والمتجددة والأسعار وكشف الأحداث ومراقبة الأصول وتقدير الحالة.


## 11. Limitations

- Attention cost can scale quadratically with sequence length.
- Large models may require substantial data and computation.
- Attention weights are not always complete explanations.
- Distribution shift can reduce performance after deployment.

## 11. القيود

قد تكون الكلفة الحسابية مرتفعة، كما أن أوزان الانتباه لا تعد دائمًا تفسيرًا كاملاً للقرار.

## 12. Engineering Workflow



## 12. سير العمل الهندسي

يجب بناء خط أساس، والحفاظ على التقسيم الزمني، ثم تقييم النموذج ومراقبته بعد التشغيل.



## Review Questions

1. What are queries, keys, and values?
2. Why is attention scaled by  $\sqrt{d_k}$ ?
3. Why is positional information necessary?
4. What is the purpose of multiple heads?
5. What is causal masking?
6. When might LSTM be preferable to Transformer?

## أسئلة المراجعة

1. ما هي  $Q$  و  $K$  و  $V$ ؟
2. لماذا نقسم على  $dV_k$ ؟
3. لماذا نحتاج إلى معلومات الموضع؟
4. ما فائدة تعدد الرؤوس؟
5. ما المقصود بالقناع السببي؟
6. متى قد تكون LSTM أنسب من Transformer؟



# References | المراجع

المراجع العامة المستخدمة في هذا المقرر

[1] A. Gabash, *Flexible Optimal Operations of Energy Supply Networks with Renewable Energy Generation and Battery Storage*. Saarbrücken, Germany: Südwestdeutscher Verlag für Hochschulschriften, 2014.

[2] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th Global ed. Harlow, U.K.: Pearson Education Limited, 2022.

[3] A. Gabash, "Energy Market Transition and Climate Change: A Review of TSOs-DSOs C++ Framework from 1800 to Present," *Energies*, vol. 16, no. 17, Art. no. 6139, 2023, doi: 10.3390/en16176139.

[4] A. Gabash, *AI Applications in Electrical Power Systems*, Version 1.0, 2026. [Online]. Available: <https://aoussgabash.com>

# Publication Information | معلومات النشر

|                  |                                                               |
|------------------|---------------------------------------------------------------|
| Document         | Lecture 10 · Transformer Models and Attention                 |
| Course           | AI Applications in Electrical Power Systems                   |
| Author           | Dr.-Ing. Aouss Gabash                                         |
| Version          | 1.0                                                           |
| Publication year | 2026                                                          |
| Official website | <a href="https://aoussgabash.com">https://aoussgabash.com</a> |
| Citation style   | IEEE                                                          |

**Recommended citation:**  
Gabash, A. (2026). Transformer Models and Attention. AI Applications in Electrical Power Systems, Lecture 10, Version 1.0. <https://aoussgabash.com>

المرجع المقترح:

أوس غباش، 2026، محاضرة 10، تطبيقات الذكاء الاصطناعي في أنظمة الطاقة الكهربائية، الإصدار 1.0، <https://aoussgabash.com>

© 2026 Dr.-Ing. Aouss Gabash. Educational use with attribution to the author and official website.



## Interactive Quiz — Lecture 10

اختبار تفاعلي — المحاضرة 10

1. The attention mechanism computes relevance between:

1. تحسب آلية الانتباه الصلة بين:

- ☐ Queries and keys  
الاستعلامات والمفاتيح
- ☐ Only labels and filenames  
التسميات وأسماء الملفات فقط
- ☐ Transformers and circuit breakers  
المحولات والقواطع
- ☐ Clusters and voltmeters  
العناقيد والفولتميترات

2. What does self-attention allow each time step to do?

2. ماذا يتيح الانتباه الذاتي لكل خطوة زمنية؟

- ☐ Ignore all other steps  
تجاهل جميع الخطوات الأخرى

- Use only the previous step

استخدام الخطوة السابقة فقط

- Attend to other relevant positions

الانتباه إلى المواضع الأخرى ذات الصلة

- Delete the input sequence

حذف سلسلة الدخل

### 3. Why are positional encodings needed?

3. لماذا نحتاج الترميز الموضعي؟

- To increase voltage

لزيادة الجهد

- To represent sequence order

لتمثيل ترتيب السلسلة

- To choose cluster count

لاختيار عدد العناقيد

- To encrypt files

لتشفير الملفات

### 4. Multi-head attention enables the model to:

4. يتيح الانتباه متعدد الرؤوس للنموذج:

- Use no parameters

عدم استخدام معاملات

- Process only one feature

معالجة ميزة واحدة فقط

- Always output a constant

إخراج ثابت دائماً

- Learn different relationships in parallel

تعلم علاقات مختلفة بالتوازي

5. A transformer advantage over a basic RNN is:

5. من مزايا Transformer على RNN الأساسي:

- Greater parallelism during training

توازن أكبر أثناء التدريب

- No need for data

عدم الحاجة للبيانات

- Guaranteed zero error

ضمان خطأ صفري

- No computation

عدم وجود حسابات

تُحفظ نتيجتك في هذا المتصفح فقط | Your result is stored only in this browser.