

LECTURE 11 | المحاضرة 11

Graph Neural Networks for Power Systems

الشبكات العصبية البيانية في أنظمة القدرة الكهربائية

Topology-Aware Learning for State Estimation, Fault Detection, Stability, and Smart Grids

تعلم واع بالطوبولوجيا لتقدير الحالة وكشف الأعطال والاستقرار والشبكات الذكية

Grid as Graph

Graph Matrices

Message Passing

GCN

GAT

Applications

Prepared by | إعداد | Dr.-Ing. Aouss Gabash

Learning Objectives

- Represent a power network as a graph.
- Explain adjacency, degree, incidence, and Laplacian matrices.
- Understand graph signals and message passing.
- Derive the normalized GCN update.
- Compare GCN, GraphSAGE, and GAT.
- Apply GNNs to state estimation, faults, stability, and OPF surrogates.
- Recognize topology, data-quality, and over-smoothing limitations.


أهداف التعلم

- تمثيل شبكة القدرة كرسم بياني.
- فهم مصفوفات المجاورة والدرجة والاتصال واللابلاسيان.
- فهم الإشارات البيانية وتمرير الرسائل.
- اشتقاق تحديث GCN المطيع.
- مقارنة GCN و GraphSAGE و GAT.
- تطبيق GNN في تقدير الحالة والأعطال والاستقرار وبدائل OPF.
- معرفة قيود الطوبولوجيا وجودة البيانات وفراط التنعيم.

1. The Power Grid as a Graph

$$G = (V, E), |V| = N, |E| = M$$

Buses are nodes and lines or transformers are edges. Node features may include voltage, angle, injections, demand, generation, and PMU measurements. Edge features may include resistance, reactance, susceptance, rating, tap ratio, status, and power flow.



A GNN preserves the physical neighborhood structure instead of flattening the grid into an unrelated vector.

1. شبكة القدرة كرسم بياني

تمثل القضاة عقدًا، والخطوط والمحولات حوافًا، وتحمل العقد والحواف القياسات والمعاملات الكهربائية.

2. Graph Matrices

$$A_{ij} = 1 \text{ if } (i, j) \in E$$

$$D_{ii} = \sum_j A_{ij}$$

$$L = D - A$$

$$L_{sym} = I - D - 1/2AD - 1/2$$

A weighted adjacency matrix can use $|b_{ij}|$, $1/x_{ij}$, or another physically meaningful coupling. With an oriented incidence matrix B , the unweighted Laplacian satisfies $L=BB^T$.

$$x^T L x = 1/2 \sum_{i,j} A_{ij} (x_i - x_j)^2$$

2. مصفوفات الرسم البياني

تصف A الاتصال، و D درجة كل عقدة، و B علاقة العقد بالحواف، بينما يقيس L اختلاف الإشارات بين العقد المجاورة.

3. Graph Signals

$$X = [x_1^T; x_2^T; \dots; x_N^T] \in \mathbb{R}^N \times F$$

Voltage Signal

$|V|$ and θ at every bus.

Injection Signal

Active and reactive powers P and Q .

Measurement Signal

SCADA, PMU, smart-meter, or pseudo-measurements.

Edge Signal

Flows, loading, status, and electrical parameters.

3. الإشارات البيانية

تُسند قيمة أو متجه ميزات لكل قضيبي، ويمكن أيضًا إسناد ميزات لكل خط.

4. Why Conventional Models Are Limited

Model	Native Structure	Grid Limitation
ANN	Fixed vector	Ignores locality and topology
CNN	Regular grid	Power networks are irregular
RNN/LSTM	Sequence	Models time, not topology
Transformer	Set or sequence	Topology must be injected
GNN	Graph	Directly uses buses and lines


4. حدود النماذج التقليدية

بُنيت GNN أصلاً للتعامل مع علاقات الجوار غير المنتظمة التي تميز شبكات القدرة.

5. Message Passing

$$mi(l) = AGGREGATE(\psi(hi(l), hj(l), eij) : j \in N(i))$$

$$hi(l + 1) = UPDATE(hi(l), mi(l))$$



Each layer expands the receptive field by one graph hop.

5. تمرير الرسائل

ترسل العقد المجاورة معلوماتها، ثم تُجمع الرسائل ويُحدَّث تمثيل العقدة.

6. Graph Convolutional Network

$$\tilde{A} = A + I, D^{-1/2} \tilde{A} D^{-1/2}$$

$$H(l+1) = \sigma(D^{-1/2} \tilde{A} D^{-1/2} H(l) W(l))$$

1. Transform node features using W.
2. Mix neighboring information using normalized adjacency.
3. Apply a nonlinear activation.
4. Repeat to include more distant buses.

Too many layers may cause over-smoothing, making node embeddings nearly indistinguishable.

6. شبكة GCN

تُضاف وصلات ذاتية ثم تُطبع المجاورة لتجنب هيمنة العقد عالية الدرجة، وبعدها تُجمع ميزات الجيران وتُطبق اللاخطية.

7. Spectral and Spatial Views

$$L = U \Lambda U^T, \hat{x} = U^T x$$

$$g\theta * Gx = Ug\theta(\Lambda)U^Tx$$

$$h'i = \sigma(Wselfhi + \sum_{j \in N(i)} Wnbrhj)$$

The spectral view interprets convolution as graph-frequency filtering, while the spatial view focuses directly on neighborhood aggregation.

7. المنظوران الطيفي والمكاني

يفسر المنظور الطيفي العملية كمرشح بياني، بينما يركز المنظور المكاني على تبادل الرسائل بين الجيران.

8. GraphSAGE

$$hN(i)(l) = AGGREGATE(hj(l-1) : j \in N(i))$$

$$hi(l) = \sigma(W(l)[hi(l-1) || hN(i)(l)])$$

GraphSAGE learns an inductive aggregation rule that can generalize to unseen nodes or changed networks.

GraphSAGE .8

تتعلم قاعدة تجميع قابلة للتعميم على عقد أو شبكات لم تظهر أثناء التدريب.

9. Graph Attention Networks

$$e_{ij} = \text{LeakyReLU}(a^T[Wh_i || Wh_j])$$

$$\alpha_{ij} = \text{softmax}_j(e_{ij})$$

$$h'_i = \sigma(\sum_{j \in N(i)} \alpha_{ij} Wh_j)$$

Attention may emphasize electrically influential neighbors, but learned weights should not automatically be interpreted as physical causality.

9. شبكات الانتباه البياني

تتعلم وزنًا مختلفًا لكل جار بدل إعطاء جميع الجيران الأهمية نفسها.

10. Edge Features and Physics

$$m_{ij} = \psi(h_i, h_j, x_{ij}, r_{ij}, t_{ap_{ij}}, s_{ij})$$

Using physical line data is usually more meaningful than binary adjacency alone. Physics-informed losses can also penalize power-flow mismatch and operating-limit violations.

$$J_{total} = J_{data} + \lambda p f J_{power} - flow + \lambda reg \|\theta\|^2$$

10. ميزات الحواف والفيزياء

يمكن للرسائل أن تعتمد على المفاعلة والمقاومة ونسبة المحول وحالة الخط، ويمكن إضافة قيود فيزيائية إلى دالة التدريب.

11. Output Levels

Node-Level

Estimate voltage or classify a bus condition.

Edge-Level

Predict flow, congestion, or a faulted branch.

Graph-Level

Classify overall stability or security.

Spatio-Temporal

Combine topology with measurements over time.

11. مستويات الخرج

قد يكون الخرج لكل عقدة أو حافة أو للشبكة كاملة، أو مكانياً وزمناً معاً.

12. Applications in Power Systems

State Estimation

Infer states from incomplete noisy measurements.

Topology Identification

Detect switching and line-status changes.

Fault Localization

Locate disturbances from spatial patterns.

Voltage Stability

Classify secure and insecure states.

OPF Surrogates

Approximate optimization mappings rapidly.

Renewable Integration

Model spatial dependencies among DERs.

12. التطبيقات في نظم القدرة

تشمل تقدير الحالة وتحديد الطوبولوجيا والأعطال والاستقرار وبدائل OPF وتحليل الموارد الموزعة.

13. Classical and Learned State Estimation

$$z = h(x) + e$$

$$\hat{x}_{WLS} = \operatorname{argmin}_x (z - h(x))^T R^{-1} (z - h(x))$$

$$\hat{X} = f_{GNN}(G, Z)$$

A learned estimator does not eliminate observability analysis, bad-data processing, uncertainty assessment, or physical validation.

13. تقدير الحالة التقليدي والمتعلم

يتعلم GNN علاقة بين القياسات والحالات، لكنه لا يلغي متطلبات الرصد والتحقق الفيزيائي ومعالجة البيانات السيئة.

14. Generalization and Limitations


- Test line outages and switching actions.
- Include different loading and renewable patterns.
- Evaluate missing sensors and topology errors.
- Avoid training on only one fixed topology.

- Control over-smoothing and computational cost.
- Validate simulated data against realistic operating conditions.

14. التعميم والقيود

يجب اختبار تغير الطوبولوجيا وفقد القياسات وتبدل الأحمال والمتجددة، مع الانتباه إلى فرط التنعيم وقابلية التوسع.

15. Engineering Workflow



Research directions: spatio-temporal GNNs, physics-informed GNNs, graph Transformers, topology-robust learning, uncertainty-aware estimation, and distributed inference.

15. سير العمل الهندسي

نبدأ بنموذج الشبكة وبناء الرسم البياني والميزات، ثم ندرب النموذج ونختبره تحت تغيرات واقعية ونقارن نتائجه بالفيزياء.

Review Questions

1. Why is a power grid naturally a graph?
2. What is the difference between A, D, B, and L?
3. Explain message passing.
4. Derive one GCN layer.
5. How does GAT differ from GCN?
6. What causes over-smoothing?
7. How are line parameters incorporated?
8. Why must topology changes be tested?

أسئلة المراجعة

1. لماذا تمثل شبكة القدرة كرسم بياني؟
2. ما الفرق بين A و D و B و L؟
3. اشرح تمرير الرسائل.
4. اشتق طبقة GCN.
5. كيف تختلف GAT عن GCN؟
6. ما سبب فرط التنعيم؟
7. كيف نضيف معاملات الخطوط؟
8. لماذا نختبر تغيير الطوبولوجيا؟

References | المراجع

المراجع العامة المستخدمة في هذا المقرر

[1] A. Gabash, *Flexible Optimal Operations of Energy Supply Networks with Renewable Energy Generation and Battery Storage*. Saarbrücken, Germany: Südwestdeutscher Verlag für Hochschulschriften, 2014.

[2] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th Global ed. Harlow, U.K.: Pearson Education Limited, 2022.

[3] A. Gabash, "Energy Market Transition and Climate Change: A Review of TSOs-DSOs C+++ Framework from 1800 to Present," *Energies*, vol. 16, no. 17, Art. no. 6139, 2023, doi: 10.3390/en16176139.

[4] A. Gabash, *AI Applications in Electrical Power Systems*, Version 1.0, 2026. [Online]. Available: <https://aoussgabash.com>

Publication Information | معلومات النشر

Document	Lecture 11 · Graph Neural Networks for Power Systems
Course	AI Applications in Electrical Power Systems
Author	Dr.-Ing. Aouss Gabash
Version	1.0
Publication year	2026
Official website	https://aoussgabash.com
Citation style	IEEE

Recommended citation:
Gabash, A. (2026). Graph Neural Networks for Power Systems. AI Applications in Electrical Power Systems, Lecture 11, Version 1.0. <https://aoussgabash.com>

المرجع المقترح:

أوس غباش، 2026، محاضرة 11، تطبيقات الذكاء الاصطناعي في أنظمة الطاقة الكهربائية، الإصدار 1.0، <https://aoussgabash.com>

© 2026 Dr.-Ing. Aouss Gabash. Educational use with attribution to the author and official website.