

LECTURE 11 | المحاضرة 11

Graph Neural Networks for Power Systems

الشبكات العصبية البيانية في أنظمة القدرة الكهربائية

Topology-aware learning for state estimation, fault detection, stability, and smart grids

تعلم واع بالطوبولوجيا لتقدير الحالة وكشف الأعطال والاستقرار والشبكات الذكية

Grid as Graph

Graph Matrices

Graph Signals

Message Passing

GCN


GAT

Applications

Prepared by | إعداد: Dr.-Ing. Aouss Gabash | د.م. أوس غباش

1. Why Is a Power Grid a Graph?

An electrical power system is naturally represented as a graph $G=(V,E)$, where buses form the node set V and transmission or distribution lines form the edge set E .



Node features

Voltage magnitude, angle, injections, demand, generation, PMU measurements.

Edge features

Resistance, reactance, susceptance, rating, status, power flow.

Unlike a standard ANN, a GNN preserves the physical neighborhood structure of the grid.

1. لماذا تُعد الشبكة الكهربائية رسمًا بيانيًا؟

يمكن تمثيل شبكة القدرة كرسم بياني تكون فيه القضبان عقدًا، والخطوط والمحولات حوافًا. وتحمل العقد والحواف معلومات كهربائية قابلة للتعليم.

الميزة الأساسية لـ GNN أنها لا تتجاهل طوبولوجيا الشبكة، بل تستخدمها جزءًا من عملية التعلم.

2. Formal Graph Definition

$$G = (V, E), |V| = N, |E| = M$$

For an undirected grid model, edge (i,j) means that buses i and j are electrically connected. For directional flows, a directed representation can also be used.

2. التعريف الرياضي للرسم البياني

يتكون الرسم البياني من مجموعة عقد V ومجموعة حواف E . ويمكن استخدام تمثيل غير موجه للطوبولوجيا، أو موجه عند الحاجة إلى اتجاه التدفق.

3. Adjacency Matrix

$$A_{ij} = 1 \text{ if } (i, j) \in E, \text{ otherwise } A_{ij} = 0$$

A weighted adjacency matrix may store electrical coupling instead of binary connectivity:

$$A_{ij} = |b_{ij}|, 1/x_{ij}, \text{ or another physically meaningful edge weight}$$

3. مصفوفة المجاورة

تحدد مصفوفة المجاورة أي عقد مرتبطة. ويمكن جعلها موزونة باستخدام ممانعة الخط أو القابلية أو معامل اقتران كهربائي مناسب.

4. Degree Matrix

$$D_{ii} = \sum_j A_{ij}$$

The diagonal entry D_{ii} measures the total connectivity of node i .

4. مصفوفة الدرجات

تحتوي D على مجموع أوزان الحواف المتصلة بكل عقدة. وهي مصفوفة قطرية أساسية في التطبيق وبناء لابلاسيان.

5. Incidence Matrix

Choose an orientation for each line. The incidence matrix $B \in \mathbb{R}^{N \times M}$ contains +1 at the sending node, -1 at the receiving node, and 0 elsewhere.

$$L = BB^T \text{ for an unweighted graph}$$

In DC power-flow models, incidence and weighted Laplacian structures appear naturally in the nodal equations.

5. مصفوفة الاتصال

تربط مصفوفة الاتصال العقد بالحواف. وتظهر بنيتها مباشرة في نماذج تدفق القدرة المستمر DC وفي تشكيل مصفوفات الشبكة.

6. Graph Laplacian

$$L = D - A$$

$$L_{sym} = I - D - 1/2AD - 1/2$$

The Laplacian measures differences between neighboring node signals and is central to graph signal processing.

$$x^T L x = 1/2 \sum_{i,j} A_{ij} (x_i - x_j)^2$$

6. لابلاسيان الرسم البياني

يقيس لابلاسيان مقدار اختلاف الإشارة بين العقد المجاورة. فإذا كانت قيم الجهد متقاربة على الحواف، تكون طاقة الإشارة البيانية منخفضة.

7. Graph Signals in Power Systems

A graph signal assigns a value or vector to every bus:

$$X = [x_1^T; x_2^T; \dots; x_N^T] \in \mathbb{R}^N \times F$$

Voltage signal
|V| and angle θ at every bus.

Injection signal
Active and reactive powers P and Q.

Measurement signal
SCADA, PMU, smart-meter, or pseudo-measurements.

7. الإشارات على الرسم البياني

يمكن إسناد متجه ميزات لكل قضيبي، مثل مقدار الجهد والزاوية والحقن الفعال والردي والقياسات المحلية.


8. Why Ordinary Neural Networks Are Not Enough

Model	Native structure	Grid limitation
ANN	Fixed vector	Ignores locality and topology
CNN	Regular grid	Power networks are irregular
RNN/LSTM	Sequence	Models time, not topology
Transformer	Set/sequence attention	Topology must be injected explicitly
GNN	Graph	Directly exploits buses and lines

8. لماذا لا تكفي الشبكات التقليدية؟

تتعامل ANN مع متجه ثابت، و CNN مع شبكة منتظمة، و RNN مع تسلسل زمني. أما GNN فمبنية أصلاً لتمثيل علاقات الجوار غير المنتظمة.

9. Message Passing



$$m_i(l) = \text{AGGREGATE}(\psi(h_i(l), h_j(l), e_{ij}) : j \in N(i))$$

$$h_i(l+1) = \text{UPDATE}(h_i(l), m_i(l))$$

Each layer expands the receptive field by one graph hop.

9. تمرير الرسائل

تستقبل كل عقدة رسائل من جيرانها، ثم تجمعها وتحديث تمثيلها. وبعد طبقتين يمكنها الاستفادة من معلومات الجيران حتى مسافتين بيانيتين.

10. Graph Convolutional Network (GCN)

Add self-loops so each node keeps its own information:

$$\tilde{A} = A + I, D_{ii} = \sum_j \tilde{A}_{ij}$$

The normalized GCN update is:

$$H(l+1) = \sigma(D^{-1/2} \tilde{A} D^{-1/2} - 1/2 H(l) W(l))$$

Normalization prevents high-degree buses from dominating the aggregation.

10. شبكة الالتفاف البياني GCN

نضيف وصلات ذاتية ثم نطبع مصفوفة المجاورة. تجمع كل عقدة تمثيلات جيرانها بعد وزنها، ثم تطبق تحويلًا خطيًا ودالة تفعيل.

11. Step-by-Step Interpretation

1. Multiply H by W to transform node features.
2. Multiply by normalized adjacency to mix neighboring information.
3. Apply nonlinear activation.
4. Repeat to include more distant buses.

Too many GCN layers may cause over-smoothing: node embeddings become nearly indistinguishable.

11. تفسير الخطوات

تحول الأوزان الميزات، ثم تمزج المجاورة معلومات العقد المتصلة، وتضيف اللاخطية القدرة على تمثيل العلاقات المعقدة. لكن كثرة الطبقات قد تسبب تساوي التمثيلات.

12. Spectral View

The Laplacian eigendecomposition defines graph-frequency components:

$$L = U\Lambda U^T, \hat{x} = U^T x$$

$$g\theta * Gx = U g\theta(\Lambda) U^T x$$

Practical GCNs approximate spectral filtering without explicitly computing all eigenvectors.

12. المنظور الطيفي

تمثل متجهات لابلاسيان الذاتية ترددات بيانية. ويمكن تفسير الالتفاف البياني كمرشح في هذا المجال، ثم تقريب العملية بطريقة محلية قابلة للتعلم.

13. Spatial View

The spatial interpretation focuses directly on neighborhood aggregation rather than graph Fourier modes.

$$h'_i = \sigma(W_{self}h_i + \sum_{j \in N(i)} W_{nbr}h_j)$$

13. المنظور المكاني

يركز المنظور المكاني على الرسائل بين العقد المجاورة مباشرة، وهو أسهل للربط مع البنية الفيزيائية للشبكة.

14. GraphSAGE

$$h_{N(i)}(l) = \text{AGGREGATE}(h_j(l-1), j \in N(i))$$

$$h_i(l) = \sigma(W(l)[h_i(l-1) || h_{N(i)}(l)])$$

GraphSAGE can learn an aggregation rule that generalizes to unseen nodes or changed networks.

14. خوارزمية GraphSAGE

تجمع GraphSAGE معلومات الجيران ثم تدمجها مع تمثيل العقدة نفسها، وهي مناسبة للتعليم الاستقرائي عند ظهور عقد أو شبكات جديدة.

15. Graph Attention Networks (GAT)

GAT learns different importance coefficients for different neighbors:

$$e_{ij} = \text{LeakyReLU}(a^T[W h_i || W h_j])$$

$$\alpha_{ij} = \text{softmax}_j(e_{ij})$$

$$h'_i = \sigma(\sum_{j \in N(i)} \alpha_{ij} W h_j)$$

Attention can assign more weight to electrically influential neighbors, but the learned weight should not automatically be interpreted as physical causality.

15. شبكات الانتباه البياني GAT

تتعلم GAT وزنًا مختلفًا لكل جار، بدل إعطاء جميع الجيران وزنًا موحدًا. وقد تساعد في التركيز على العقد الأكثر تأثيرًا في حالة تشغيل معينة.

16. Edge Features and Physics

Electrical lines are not identical. Edge-aware message functions may use reactance, resistance, tap ratio, or line status:

$$m_{ij} = \psi(h_i, h_j, x_{ij}, r_{ij}, s_{ij})$$

Using physical edge data is often more meaningful than using a binary adjacency matrix alone.

16. ميزات الحواف والفيزياء

ينبغي ألا تعامل جميع الخطوط بالطريقة نفسها. يمكن للرسالة أن تعتمد على المفاعلة والمقاومة ونسبة المحول وحالة الخط.

17. Node-Level, Edge-Level, and Graph-Level Tasks

Node-level

Estimate voltage magnitude or classify a bus condition.

Edge-level

Predict line flow, congestion, or faulted branch.

Graph-level

Classify overall stability or operating security.

17. مستويات المهام

يمكن أن يكون الخرج لكل عقدة، أو لكل حافة، أو للشبكة كاملة. ويحدد ذلك شكل طبقة الخرج ودالة الخسارة.

18. Applications in Electrical Power Systems

State estimation

Infer voltage states from incomplete and noisy measurements.

Topology identification

Detect switching or line-status changes.

Fault localization

Locate disturbances using spatial measurement patterns.

Voltage stability

Classify secure and insecure operating states.

Optimal power flow surrogates

Approximate optimization mappings quickly.

Renewable integration

Model spatial dependencies among distributed resources.

18. التطبيقات في أنظمة القدرة

تشمل تقدير الحالة، كشف تغير الطوبولوجيا، تحديد الأعطال، تقييم الاستقرار، تقريب مسائل تدفق القدرة الأمثل، وتحليل الموارد الموزعة.

19. From Classical State Estimation to GNN

$$z = h(x) + e$$

$$\hat{x}^{WLS} = \operatorname{argmin}_x (z - h(x))^T R^{-1} (z - h(x))$$

A GNN instead learns a mapping from graph-structured measurements to states:

$$\hat{X} = f_{GNN}(G, Z)$$

A learned estimator does not eliminate the need for observability analysis, bad-data handling, uncertainty assessment, and physical validation.

19. من تقدير الحالة التقليدي إلى GNN

يحل WLS مسألة تحسين قائمة على نموذج القياس. أما GNN فتعلم علاقة بين القياسات البيانية والحالات. ويجب عدم اعتبارها بديلاً مطلقاً للتحليل الفيزيائي.

20. Training Objective

$$J(\theta) = 1/N \sum_s \| \hat{X}(s) - X(s) \|^2$$

Additional physics penalties can be included:

$$J_{total} = J_{data} + \lambda_{pf} J_{power - flow} + \lambda_{reg} \|\theta\|^2$$

20. دالة التدريب

يمكن تدريب النموذج بخطأ الحالة، ثم إضافة عقوبات فيزيائية لعدم اتزان القدرة أو مخالفة حدود التشغيل.

21. Generalization to Topology Changes

A topology-aware model should be tested under:

- Line outages
- Switching actions
- Different loading levels
- Missing sensors
- Unseen renewable patterns

Training on only one fixed topology may lead to excellent test accuracy but poor real-world robustness.

21. التعميم عند تغير الطوبولوجيا

يجب اختبار النموذج عند خروج خطوط وتغير المفاتيح وفقد القياسات وتبدل مستويات الحمل، وليس فقط على نفس الشبكة المستخدمة في التدريب.

22. Limitations

Data quality

Biased simulations create biased models.

Topology mismatch

Wrong connectivity corrupts message passing.

Over-smoothing

Deep layers may erase local distinctions.


Scalability

Large dynamic grids require efficient sampling and batching.

22. القيود

تتأثر GNN بجودة البيانات وصحة الطوبولوجيا وعمق الشبكة وكلفة التدريب على الأنظمة الكبيرة.

23. From Theory to Grid



23. من النظرية إلى الشبكة

نبدأ بنموذج الشبكة، ثم نبني الرسم البياني والميزات والتسميات، وبعد التدريب نقارن النتائج بقيود ومعادلات النظام الفيزيائية.



Research Corner

Emerging directions: spatio-temporal GNNs, physics-informed GNNs, graph transformers, topology-robust learning, uncertainty-aware state estimation, and distributed GNN inference at substations.

زاوية البحث العلمي

من الاتجاهات الحديثة: GNN مكانية-زمنية، دمج الفيزياء في التدريب، Graph Transformers، التعميم على تغير الطوبولوجيا، تقدير عدم اليقين، والتنفيذ الموزع في المحطات.



Review Questions

1. Why is a power grid naturally modeled as a graph?
2. What is the difference between adjacency, degree, incidence, and Laplacian matrices?

3. Explain one GCN layer mathematically.
4. What is message passing?
5. How does GAT differ from GCN?
6. What causes over-smoothing?
7. How can line parameters be incorporated?
8. Why must topology changes be included in testing?

أسئلة المراجعة

1. لماذا تمثل الشبكة الكهربائية كرسم بياني طبيعيًا؟
2. ما الفرق بين مصفوفات المجاورة والدرجة والاتصال واللابلاسيان؟
3. اشرح طبقة GCN رياضيًا.
4. ما المقصود بتمرير الرسائل؟
5. كيف تختلف GAT عن GCN؟
6. ما سبب فرط التنعيم؟
7. كيف نضيف معاملات الخطوط؟
8. لماذا يجب اختبار تغير الطوبولوجيا؟

Publication Information

معلومات النشر والمرجع

Document	Lecture 11 · Graph Neural Networks for Power Systems
Course	AI Applications in Electrical Power Systems
Author	Dr.-Ing. Aouss Gabash
Version	1.0
Publication year	2026
Official website	https://aoussgabash.com

Recommended citation:
Gabash, A. (2026). Graph Neural Networks for Power Systems. AI Applications in Electrical Power Systems, Lecture 11, Version 1.0. <https://aoussgabash.com>

المرجع المقترح:

أوس غباش، 2026، محاضرة 11، تطبيقات الذكاء الاصطناعي في أنظمة الطاقة الكهربائية، الإصدار 1.0، <https://aoussgabash.com>

© 2026 Dr.-Ing. Aouss Gabash. Educational use with attribution to the author and official website.