

Reinforcement Learning in Energy Management

التعلم المعزز في إدارة الطاقة

Sequential decision-making for batteries, microgrids, demand response, and grid control
اتخاذ القرار المتتابع للبطاريات والشبكات المصغرة والاستجابة للطلب والتحكم بالشبكة

د. م. أوس غباش | إعداد: Dr.-Ing. Aouss Gabash


Learning Objectives

- Formulate energy management as a Markov decision process.
- Define state, action, reward, policy, and return.
- Derive Bellman equations and Q-learning updates.
- Explain DQN, actor-critic, PPO, DDPG, and SAC.
- Design a reward for battery scheduling.
- Recognize safety and generalization challenges.

أهداف التعلم

- صياغة إدارة الطاقة كعملية قرار ماركوفية.
- تعريف الحالة والفعل والمكافأة والسياسة والعائد.
- اشتقاق معادلات بيلمان و Q-learning.
- فهم DQN و Actor-Critic و PPO و DDPG و SAC.
- تصميم مكافأة لجدولة البطارية.
- فهم الأمان والتعميم.

1. Reinforcement Learning Loop



The agent is not given the correct action for every state. It discovers a policy through interaction.

1. حلقة التعلم المعزز

يراقب الوكيل الحالة ويختار فعلاً، ثم تنتقل البيئة إلى حالة جديدة وتعيد مكافأة. ومن تكرار هذه العملية يتعلم الوكيل سياسة القرار.

2. Markov Decision Process

$$\text{MDP} = (\mathcal{S}, \mathcal{A}, P, R, \gamma)$$

State

Information for decision-making.

Action

Available control decision.

Transition

Evolution after the action.

Reward

Immediate decision quality.

Discount

Importance of future reward.

Policy

State-to-action mapping.

2. عملية قرار ماركوفية

تتكون من الحالات والأفعال وديناميكا الانتقال والمكافأة ومعامل الخصم والسياسة.

3. Markov Property

$$P(s_{t+1} \mid s_0, a_0, \dots, s_t, a_t) = P(s_{t+1} \mid s_t, a_t)$$

For battery control, SOC alone may be insufficient; time, load, price, renewable output, and forecasts may also be needed.

3. خاصية ماركوف

يجب أن تحتوي الحالة على المعلومات المهمة للمستقبل، ولذلك نضيف إلى SOC الزمن والسعر والحمل والتوقعات.

4. Return and Discount

$$G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots$$

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$$

A small γ emphasizes immediate savings; γ near one emphasizes long-term operation.

4. العائد والخصم

العائد هو مجموع المكافآت الحالية والمستقبلية بعد خصمها، ويحدد γ مقدار اهتمام الوكيل بالمستقبل.

5. Value Functions

$$V^{\pi}(s) = \mathbb{E}_{\pi}[G_t \mid s_t = s]$$

$$Q^{\pi}(s, a) = \mathbb{E}_{\pi}[G_t \mid s_t = s, a_t = a]$$

V evaluates a state; Q evaluates a particular action in that state.

5. دوال القيمة

تقيس V جودة الحالة، بينما تقيس Q جودة اختيار فعل معين ضمن تلك الحالة.

6. Bellman Optimality

$$Q^*(s, a) = \mathbb{E} \left[r + \gamma \max_{a'} Q^*(s', a') \right]$$

A long-horizon problem becomes an immediate reward plus the best value of the next state.

6. أمثلية بيلمان

تربط قيمة القرار الحالي بالمكافأة الفورية وأفضل قيمة مستقبلية، وهي الأساس الرياضي لخوارزميات القيمة.

7. Q-Learning

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_{t+1} + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t) \right]$$

$$\delta_t = r_{t+1} + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t)$$

7. خوارزمية Q-Learning

تُحدَّث قيمة الفعل باستخدام خطأ الفرق الزمني بين القيمة الحالية والهدف الجديد.

8. Exploration and Exploitation

$$\begin{cases} \text{choose a random action,} & \text{with probability } \varepsilon, \\ \arg \max_a Q(s, a), & \text{otherwise.} \end{cases}$$

Too little exploration can trap the agent in a poor policy. Excessive exploration wastes experience and may violate limits.

8. الاستكشاف والاستغلال

توازن سياسة ϵ -greedy بين تجربة أفعال جديدة واستخدام أفضل فعل معروف.

9. Deep Q-Network

DQN approximates $Q(s,a)$ using a neural network and is suited to discrete actions.

$$L(\theta) = \mathbb{E} \left[\left(r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta) \right)^2 \right]$$

Experience replay

Random mini-batches reduce correlation.

Target network

Stabilizes the learning target.

9. شبكة DQN

تستخدم DQN شبكة عصبية لتقريب Q ، وتناسب الأفعال المنفصلة مثل الشحن أو التوقف أو التفريغ.

10. Actor-Critic Methods

$$\nabla_{\theta} J(\theta) = \mathbb{E}[\nabla_{\theta} \log \pi_{\theta}(a | s) \cdot A(s, a)]$$

Actor

Produces an action or probability distribution.

Critic

Estimates value and guides the actor.

10. أساليب Actor-Critic

يتعلم Actor السياسة مباشرة، بينما يقيم Critic جودة الأفعال ويوجه تحديث السياسة.

11. Algorithm Selection

Algorithm	Action space	Typical energy use
DQN	Discrete	Charge / idle / discharge
DDPG / TD3	Continuous	Continuous storage or inverter power
PPO	Discrete or continuous	General robust control policy
SAC	Continuous	Exploratory storage and microgrid control

11. اختيار الخوارزمية

تناسب DQN الأفعال المنفصلة، بينما تناسب DDPG و TD3 و SAC التحكم المستمر، ويمكن استخدام PPO في الحالتين.

12. Battery Scheduling as an MDP

State

SOC, load, price, PV, hour, forecasts.

Action

Charge or discharge power.

Transition

SOC dynamics and next-hour data.

Reward

Negative cost, degradation, and violations.

12. جدولة البطارية كـ MDP

تتكون الحالة من SOC والحمل والسعر والزمن، والفعل من قدرة البطارية، والمكافأة من الكلفة والتآكل والعقوبات.

13. Battery Dynamics

$$\text{SOC}_{t+1} = \text{SOC}_t + \frac{\eta_c P_{c,t} \Delta t}{E_{\max}} - \frac{P_{d,t} \Delta t}{\eta_d E_{\max}}$$

$$\text{SOC}_{\min} \leq \text{SOC}_t \leq \text{SOC}_{\max}$$

13. ديناميكا البطارية

تزداد SOC عند الشحن وتنخفض عند التفريغ مع مراعاة الكفاءة والسعة وحدود التشغيل.

14. Reward Design

$$r_t = -c_t P_{\text{grid},t} \Delta t - \lambda_{\text{deg}} |P_{b,t}| - \lambda_{\text{viol}} \text{Violation}_t$$

Reward scaling strongly changes the learned behavior. Weak penalties may be ignored; excessive penalties can make the policy too conservative.

14. تصميم المكافأة

تجمع المكافأة كلفة الطاقة وتآكل البطارية وعقوبات تجاوز القيود، ويجب موازنة معاملات هذه الحدود بعناية.

15. RL versus Optimization

Aspect	Optimization	Reinforcement learning
Model	Usually explicit	Can learn from interaction
Online use	Solve repeatedly	Fast policy inference
Guarantees	Possible under assumptions	Usually limited
Best use	Well-modeled constrained problems	Complex sequential uncertainty

15. مقارنة RL والتحسين

يوفر التحسين ضمانات أقوى عند توفر نموذج واضح، بينما قد يوفر RL قرارًا سريعًا بعد التدريب. ولا ينبغي اعتباره بديلًا تلقائيًا للتحسين.

16. Safe Reinforcement Learning

- Action clipping
- Safety filters
- Constrained MDPs
- Lagrangian penalties

- MPC safety layers
- Offline validation

In a critical grid, learned actions should pass deterministic feasibility and protection checks.

16. التعلم المعزز الآمن

يمكن استخدام قص الأفعال ومرشحات الأمان والقيود وطبقات MPC، ويجب التحقق من القرار قبل تطبيقه.

17. Power-System Applications

Microgrids

Storage, generation, and grid exchange.

Demand response

Shift flexible loads.

Voltage control

Coordinate inverter reactive power.

Electric vehicles

Charging and vehicle-to-grid.

Restoration

Sequential switching after faults.

Market bidding

Storage participation under uncertainty.

17. التطبيقات

تشمل الشبكات المصغرة والاستجابة للطلب والتحكم بالجهد والمركبات واستعادة الشبكة والأسواق.



Research Corner

Emerging directions: offline RL, safe RL, multi-agent systems, model-based RL, distributional RL, and hybrid optimization-RL controllers.

زاوية البحث العلمي

من الاتجاهات الحديثة التعلم دون اتصال، التعلم الآمن، الأنظمة متعددة الوكلاء، التعلم القائم على نموذج، والدمج مع التحسين.



Review Questions

1. Define an MDP for battery scheduling.
2. Derive the Q-learning update.
3. Why does DQN need replay memory?
4. When is DQN unsuitable?
5. How does reward design affect degradation?
6. Why are safety filters needed?

أسئلة المراجعة 🧠

1. عرّف MDP لجدولة البطارية.
2. اشتق تحديث Q-learning.
3. لماذا تحتاج DQN إلى ذاكرة خبرة؟
4. متى لا تناسب DQN المسألة؟
5. كيف تؤثر المكافأة في التآكل؟
6. لماذا نحتاج مرشحات الأمان؟