

## LECTURE 12 | المحاضرة 12

# Reinforcement Learning in Energy Management

## التعلم المعزز في إدارة الطاقة

Sequential decision-making for batteries, microgrids, demand response, and grid control

اتخاذ القرار المتتابع للبطاريات والشبكات المصغرة والاستجابة للطلب والتحكم بالشبكة

Prepared by | إعداد | Dr.-Ing. Aouss Gabash


### Learning Objectives

- Formulate energy management as a Markov decision process.
- Define state, action, reward, policy, and return.
- Derive Bellman equations and Q-learning updates.
- Explain DQN, actor-critic, PPO, DDPG, and SAC.
- Design a reward for battery scheduling.
- Recognize safety and generalization challenges.

### أهداف التعلم

- صياغة إدارة الطاقة كعملية قرار ماركوفية.
- تعريف الحالة والفعل والمكافأة والسياسة والعائد.
- اشتقاق معادلات بيلمان و Q-learning.
- فهم DQN و Actor-Critic و PPO و DDPG و SAC.
- تصميم مكافأة لجدولة البطارية.
- فهم الأمان والتعميم.

## 1. Reinforcement Learning Loop



The agent is not given the correct action for every state. It discovers a policy through interaction.

### 1. حلقة التعلم المعزز

يراقب الوكيل الحالة ويختار فعلاً، ثم تنتقل البيئة إلى حالة جديدة وتعيد مكافأة. ومن تكرار هذه العملية يتعلم الوكيل سياسة القرار.

## 2. Markov Decision Process

$$\text{MDP} = (\mathcal{S}, \mathcal{A}, P, R, \gamma)$$

### State

Information for decision-making.

### Action

Available control decision.

### Transition

Evolution after the action.

### Reward

Immediate decision quality.

### Discount

Importance of future reward.

### Policy

State-to-action mapping.

## 2. عملية قرار ماركوفية

تتكون من الحالات والأفعال وديناميكا الانتقال والمكافأة ومعامل الخصم والسياسة.

### 3. Markov Property

$$P(s_{t+1} \mid s_0, a_0, \dots, s_t, a_t) = P(s_{t+1} \mid s_t, a_t)$$

For battery control, SOC alone may be insufficient; time, load, price, renewable output, and forecasts may also be needed.

## 3. خاصية ماركوف

يجب أن تحتوي الحالة على المعلومات المهمة للمستقبل، ولذلك نضيف إلى SOC الزمن والسعر والحمل والتوقعات.

### 4. Return and Discount

$$G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots$$

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$$

A small  $\gamma$  emphasizes immediate savings;  $\gamma$  near one emphasizes long-term operation.

## 4. العائد والخصم

العائد هو مجموع المكافآت الحالية والمستقبلية بعد خصمها، ويحدد  $\gamma$  مقدار اهتمام الوكيل بالمستقبل.

## 5. Value Functions

$$V^{\pi}(s) = \mathbb{E}_{\pi}[G_t \mid s_t = s]$$

$$Q^{\pi}(s, a) = \mathbb{E}_{\pi}[G_t \mid s_t = s, a_t = a]$$

V evaluates a state; Q evaluates a particular action in that state.

## 5. دوال القيمة

تقيس V جودة الحالة، بينما تقيس Q جودة اختيار فعل معين ضمن تلك الحالة.

## 6. Bellman Optimality

$$Q^*(s, a) = \mathbb{E} \left[ r + \gamma \max_{a'} Q^*(s', a') \right]$$

A long-horizon problem becomes an immediate reward plus the best value of the next state.

## 6. أمثلة بيلمان

ترتبط قيمة القرار الحالي بالمكافأة الفورية وأفضل قيمة مستقبلية، وهي الأساس الرياضي لخوارزميات القيمة.

## 7. Q-Learning

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[ r_{t+1} + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t) \right]$$

$$\delta_t = r_{t+1} + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t)$$

## 7. خوارزمية Q-Learning

تُحدَّث قيمة الفعل باستخدام خطأ الفرق الزمني بين القيمة الحالية والهدف الجديد.

## 8. Exploration and Exploitation

$$\begin{cases} \text{choose a random action,} & \text{with probability } \varepsilon, \\ \arg \max_a Q(s, a), & \text{otherwise.} \end{cases}$$

Too little exploration can trap the agent in a poor policy. Excessive exploration wastes experience and may violate limits.

## 8. الاستكشاف والاستغلال

توازن سياسة  $\epsilon$ -greedy بين تجربة أفعال جديدة واستخدام أفضل فعل معروف.

## 9. Deep Q-Network

DQN approximates  $Q(s,a)$  using a neural network and is suited to discrete actions.

$$L(\theta) = \mathbb{E} \left[ \left( r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta) \right)^2 \right]$$

### Experience replay

Random mini-batches reduce correlation.

### Target network

Stabilizes the learning target.

## 9. شبكة DQN

تستخدم DQN شبكة عصبية لتقريب  $Q$ ، وتناسب الأفعال المنفصلة مثل الشحن أو التوقف أو التفريغ.

## 10. Actor-Critic Methods

$$\nabla_{\theta} J(\theta) = \mathbb{E} [\nabla_{\theta} \log \pi_{\theta}(a | s) \cdot A(s, a)]$$

### Actor

Produces an action or probability distribution.

### Critic

Estimates value and guides the actor.

## 10. أساليب Actor-Critic

يتعلم Actor السياسة مباشرة، بينما يقيم Critic جودة الأفعال ويوجه تحديث السياسة.

## 11. Algorithm Selection

| Algorithm  | Action space           | Typical energy use                        |
|------------|------------------------|-------------------------------------------|
| DQN        | Discrete               | Charge / idle / discharge                 |
| DDPG / TD3 | Continuous             | Continuous storage or inverter power      |
| PPO        | Discrete or continuous | General robust control policy             |
| SAC        | Continuous             | Exploratory storage and microgrid control |

## 11. اختيار الخوارزمية

تناسب DQN الأفعال المنفصلة، بينما تناسب DDPG و TD3 و SAC التحكم المستمر، ويمكن استخدام PPO في الحالتين.

## 12. Battery Scheduling as an MDP

### State

SOC, load, price, PV, hour, forecasts.

### Action

Charge or discharge power.

### Transition

SOC dynamics and next-hour data.

### Reward

Negative cost, degradation, and violations.

## 12. جدولة البطارية كـ MDP

تتكون الحالة من SOC والحمل والسعر والزمن، والفعل من قدرة البطارية، والمكافأة من الكلفة والتآكل والعقوبات.

## 13. Battery Dynamics

$$\text{SOC}_{t+1} = \text{SOC}_t + \frac{\eta_c P_{c,t} \Delta t}{E_{\max}} - \frac{P_{d,t} \Delta t}{\eta_d E_{\max}}$$

$$\text{SOC}_{\min} \leq \text{SOC}_t \leq \text{SOC}_{\max}$$

## 13. ديناميكا البطارية

تزداد SOC عند الشحن وتنخفض عند التفريغ مع مراعاة الكفاءة والسعة وحدود التشغيل.

## 14. Reward Design

$$r_t = -c_t P_{\text{grid},t} \Delta t - \lambda_{\text{deg}} |P_{b,t}| - \lambda_{\text{viol}} \text{Violation}_t$$

Reward scaling strongly changes the learned behavior. Weak penalties may be ignored; excessive penalties can make the policy too conservative.

## 14. تصميم المكافأة

تجمع المكافأة كلفة الطاقة وتآكل البطارية وعقوبات تجاوز القيود، ويجب موازنة معاملات هذه الحدود بعناية.

## 15. RL versus Optimization

| Aspect     | Optimization                      | Reinforcement learning         |
|------------|-----------------------------------|--------------------------------|
| Model      | Usually explicit                  | Can learn from interaction     |
| Online use | Solve repeatedly                  | Fast policy inference          |
| Guarantees | Possible under assumptions        | Usually limited                |
| Best use   | Well-modeled constrained problems | Complex sequential uncertainty |

## 15. مقارنة RL والتحسين

يوفر التحسين ضمانات أقوى عند توفر نموذج واضح، بينما قد يوفر RL قرارًا سريعًا بعد التدريب. ولا ينبغي اعتباره بديلًا تلقائيًا للتحسين.

## 16. Safe Reinforcement Learning

- Action clipping
- Safety filters
- Constrained MDPs
- Lagrangian penalties
- MPC safety layers
- Offline validation

In a critical grid, learned actions should pass deterministic feasibility and protection checks.

## 16. التعلم المعزز الآمن

يمكن استخدام قص الأفعال ومرشحات الأمان والقيود وطبقات MPC، ويجب التحقق من القرار قبل تطبيقه.

## 17. Power-System Applications

### Microgrids

Storage, generation, and grid exchange.

### Demand response

Shift flexible loads.

### Voltage control

Coordinate inverter reactive power.

### Electric vehicles

Charging and vehicle-to-grid.

### Restoration

Sequential switching after faults.

### Market bidding

Storage participation under uncertainty.

## 17. التطبيقات

تشمل الشبكات المصغرة والاستجابة للطلب والتحكم بالجهد والمركبات واستعادة الشبكة والأسواق.



## Research Corner

**Emerging directions:** offline RL, safe RL, multi-agent systems, model-based RL, distributional RL, and hybrid optimization-RL controllers.

## زاوية البحث العلمي

من الاتجاهات الحديثة التعلم دون اتصال، التعلم الآمن، الأنظمة متعددة الوكلاء، التعلم القائم على نموذج، والدمج مع التحسين.



## Review Questions

1. Define an MDP for battery scheduling.

2. Derive the Q-learning update.
3. Why does DQN need replay memory?
4. When is DQN unsuitable?
5. How does reward design affect degradation?
6. Why are safety filters needed?

## أسئلة المراجعة 🧠

1. عرّف MDP لجدولة البطارية.
2. اشتق تحديث Q-learning.
3. لماذا تحتاج DQN إلى ذاكرة خبرة؟
4. متى لا تناسب DQN المسألة؟
5. كيف تؤثر المكافأة في التآكل؟
6. لماذا نحتاج مرشحات الأمان؟

# المراجع | References

المراجع العامة المستخدمة في هذا المقرر

[1] A. Gabash, *Flexible Optimal Operations of Energy Supply Networks with Renewable Energy Generation and Battery Storage*. Saarbrücken, Germany: Südwestdeutscher Verlag für Hochschulschriften, 2014.

[2] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th Global ed. Harlow, U.K.: Pearson Education Limited, 2022.

[3] A. Gabash, "Energy Market Transition and Climate Change: A Review of TSOs-DSOs C+++ Framework from 1800 to Present," *Energies*, vol. 16, no. 17, Art. no. 6139, 2023, doi: 10.3390/en16176139.

[4] A. Gabash, *AI Applications in Electrical Power Systems*, Version 1.0, 2026. [Online]. Available: <https://aoussgabash.com>

# معلومات النشر | Publication Information

|                  |                                                               |
|------------------|---------------------------------------------------------------|
| Document         | Lecture 12 · Reinforcement Learning in Energy Management      |
| Course           | AI Applications in Electrical Power Systems                   |
| Author           | Dr.-Ing. Aouss Gabash                                         |
| Version          | 1.0                                                           |
| Publication year | 2026                                                          |
| Official website | <a href="https://aoussgabash.com">https://aoussgabash.com</a> |
| Citation style   | IEEE                                                          |

**Recommended citation:**  
Gabash, A. (2026). Reinforcement Learning in Energy Management. AI Applications in Electrical Power Systems, Lecture 12, Version 1.0. <https://aoussgabash.com>

المرجع المقترح:

أوس غباش، 2026، محاضرة 12، تطبيقات الذكاء الاصطناعي في أنظمة الطاقة الكهربائية، الإصدار 1.0، <https://aoussgabash.com>

© 2026 Dr.-Ing. Aouss Gabash. Educational use with attribution to the author and official website.



## Interactive Quiz — Lecture 12

اختبار تفاعلي — المحاضرة 12

1. In reinforcement learning, the agent learns through:

1. في التعلم المعزز، يتعلم الوكيل من خلال:

☐ Only labeled tables

جداول موسومة فقط

☐ Interaction and rewards

التفاعل والمكافآت

☐ No feedback

دون تغذية راجعة

☐ Static clustering

تجميع ثابت

2. A policy maps:

2. تربط السياسة:

☐ States to actions

الحالات بالأفعال

- Files to colors

الملفات بالألوان

- Voltages to passwords

الجهود بكلمات المرور

- Clusters to labels only

العناقيد بالتسميات فقط

### 3. The discount factor controls:

3. يتحكم معامل الخصم في:

- Number of sensors

عدد الحساسات

- Battery voltage units

وحدات جهد البطارية

- Importance of future rewards

أهمية المكافآت المستقبلية

- Graph edge count

عدد حواف البيان

### 4. Exploration means:

4. يعني الاستكشاف:

- Always choosing the current best action

اختيار أفضل فعل حالي دائمًا

- Stopping training

إيقاف التدريب

- Ignoring rewards

تجاهل المكافآت

- Trying actions to gain information

تجربة أفعال لاكتساب معلومات

5. A useful reward for battery scheduling may include:

5. قد تتضمن مكافأة مفيدة لجدولة البطارية:

- Negative energy cost and constraint penalties

سالب تكلفة الطاقة وعقوبات القيود

- Only battery color

لون البطارية فقط

- Page loading speed

سرعة تحميل الصفحة

- Random text length

طول نص عشوائي

تُحفظ نتيجتك في هذا المتصفح فقط | Your result is stored only in this browser.