


## LECTURE 13 | المحاضرة 13

# Explainable Artificial Intelligence

## الذكاء الاصطناعي القابل للتفسير

Understanding, Validating, and Communicating AI Decisions in Power Systems

فهم قرارات الذكاء الاصطناعي والتحقق منها وشرحها في أنظمة القدرة



Prepared by | إعداد: Dr.-Ing. Aouss Gabash

### Learning Objectives

- Distinguish interpretability, explainability, transparency, and causality.
- Differentiate global and local explanations.
- Understand permutation importance, PDP, ICE, LIME, and SHAP.
- Explain Shapley values mathematically.
- Recognize explanation pitfalls with correlated power-system data.
- Apply XAI to forecasting, fault detection, and state estimation.
- Evaluate explanation fidelity, stability, and physical consistency.

### أهداف التعلم

- التمييز بين قابلية الفهم والتفسير والشفافية والسببية.
- التمييز بين التفسير العام والمحلي.
- فهم أهمية التبديل و PDP و ICE و LIME و SHAP.
- شرح قيم شابلي رياضياً.
- معرفة أخطاء التفسير مع البيانات المترابطة.
- تطبيق XAI في التنبؤ والأعطال وتقدير الحالة.
- تقييم دقة واستقرار واتساق التفسير مع الفيزياء.

# 1. Why Explainability Matters

Power systems are safety-critical. Engineers need to understand why an AI model recommends an action when the result affects protection, dispatch, voltage control, reliability, or market operation.

High predictive accuracy does not automatically imply physical validity, robustness, fairness, or operational safety.

## 1. لماذا نحتاج إلى التفسير؟

يجب معرفة سبب القرار قبل استخدامه في تطبيقات حرجية مثل الحماية والتشغيل والتحكم بالجهد.

# 2. Core Concepts

### Interpretability

How directly a human can understand the model itself.

### Explainability

Methods used to explain a prediction or behavior.

### Transparency

Visibility of data, training, assumptions, and implementation.

### Causality

Whether changing a variable physically changes the outcome.

A predictive explanation is not automatically a causal explanation.

## 2. المفاهيم الأساسية

قد يكون النموذج مفهومًا بذاته، أو يحتاج إلى أدوات تفسير، بينما تشمل الشفافية البيانات وطريقة التدريب والافتراضات.

### 3. Global, Local, Intrinsic, and Post-Hoc

| Type      | Purpose                  | Example                  | Limitation                 |
|-----------|--------------------------|--------------------------|----------------------------|
| Global    | Explain overall behavior | Feature importance, PDP  | May hide local variation   |
| Local     | Explain one prediction   | LIME, local SHAP         | May be unstable            |
| Intrinsic | Model is understandable  | Linear model, small tree | May reduce flexibility     |
| Post-hoc  | Explain a complex model  | SHAP, LIME, PDP          | Explanation is approximate |

A feature can be globally important but locally unimportant for one operating point, and vice versa.

## 3. أنواع التفسير

يشرح التفسير العام سلوك النموذج ككل، بينما يشرح التفسير المحلي حالة تشغيل محددة.

### 4. Feature Importance

Feature importance ranks predictors according to their influence on model performance or internal structure.

$$Imp(j) = Loss(X \text{ with feature } j \text{ permuted}) - Loss(X)$$

Importance does not show the direction of influence and does not prove causality. Correlated predictors may replace one another and underestimate individual importance.

## 4. أهمية الميزات

نقيس مقدار ازدياد الخطأ بعد تبديل ميزة، لكن النتيجة لا تثبت السببية وقد تتأثر بترابط الميزات.

## 5. Partial Dependence and ICE

$$PD_j(z) = EX - j[f(z, X - j)]$$

### PDP

Shows the average model response when one feature is varied.

### ICE

Shows one response curve per observation.

ICE can reveal heterogeneous operating behavior that an average PDP may hide.

## 5. الاعتماد الجزئي و ICE

يعرض PDP التأثير المتوسط، بينما تكشف ICE اختلاف استجابة الحالات الفردية.

## 6. LIME

LIME perturbs samples around a query point, obtains black-box predictions, and fits a weighted simple surrogate.

$$g^* = \operatorname{argmin}_g [L(f, g, \pi x) + \Omega(g)]$$

### L

Local fidelity to the black-box model.

### $\Omega$

Penalty that keeps the surrogate simple.

Results depend on the neighborhood definition, random perturbations, surrogate fidelity, and whether perturbed samples are physically feasible.

## 6. طريقة LIME

تنشئ عينات قريبة من الحالة وتدريب نموذجًا بسيطًا ليقلد النموذج المعقد محليًا، لكن النتيجة قد تتغير مع تعريف الجوار.

## 7. Shapley Values and SHAP

SHAP is based on cooperative game theory. Features are players and the model prediction is the payout.

Extra close brace or missing open brace

$$f(x) = \varphi_0 + \sum_j \varphi_j$$

Positive values increase the prediction relative to the baseline; negative values decrease it.

## 7. قيم شابلي و SHAP

توزع SHAP التنبؤ على الميزات وفق مساهمة كل ميزة عبر جميع المجموعات الممكنة.

## 8. SHAP Properties

### Local Accuracy

Contributions sum to the prediction.

### Missingness

Absent features receive zero contribution.

### Consistency

Greater model influence should not reduce attribution.

### Baseline Dependence

Results depend on background data and conditional assumptions.

## 8. خصائص SHAP

تتميز بالدقة المحلية والاتساق، لكنها تتأثر ببيانات الخلفية والافتراضات الشرطية.

## 9. Correlated Features and Causality

Load, temperature, hour, renewable output, and lagged measurements are often strongly correlated.

Attributions may be split among correlated predictors or assigned differently depending on the background distribution.

*Predictive association  $\neq$  Causal effect*

A high SHAP value means the model used a feature strongly. It does not prove that changing that feature will physically cause the predicted change.

## 9. الميزات المترابطة والسببية

يجب تفسير المساهمات بحذر، لأن التفسير يصف استخدام النموذج للميزة ولا يثبت التأثير الفيزيائي السببي.

## 10. Explanation Fidelity and Stability

- Local surrogate  $R^2$  or approximation error.
- Stability under small input perturbations.
- Consistency across similar operating points.
- Agreement with physical knowledge.
- Sensitivity to background or reference data.
- Robustness under distribution shift.

An explanation should be evaluated, not merely visualized.

## 10. جودة واستقرار التفسير

يجب قياس دقة الشرح واستقراره واتساقه مع المعرفة الفيزيائية ومع تغير البيانات المرجعية.

## 11. XAI Applications in Power Systems

### Load Forecasting

Explain the influence of temperature, hour, weekdays, and lagged load.

### Renewable Forecasting

Assess irradiance, wind, weather, and temporal features.

### Fault Detection

Identify waveform regions or measurements driving a classification.

### State Estimation

Show which measurements support each estimated state.

### Voltage Stability

Reveal buses and variables influencing a security decision.

### OPF Surrogates

Explain which loads, limits, and network features affect outputs.

## 11. تطبيقات XAI في نظم القدرة

تستخدم لشرح التنبؤ والأعطال وتقدير الحالة والاستقرار وبدائل OPF.

## 12. Physics-Based Validation

Explanations should be compared with engineering expectations, sensitivity factors, power-flow equations, protection logic, and operating constraints.

$$\Delta P \approx JP_{\theta} \Delta \theta + JP_V \Delta V$$

Agreement with physics increases confidence, while disagreement should trigger investigation rather than automatic rejection or acceptance.

## 12. التحقق الفيزيائي

نقارن التفسير مع الحساسية ومعادلات تدفق القدرة ومنطق الحماية وحدود التشغيل.


## 13. Common Pitfalls

- Confusing explanation with causality.
- Ignoring feature correlation.
- Using unrealistic perturbations.
- Showing only one explanation method.
- Ignoring uncertainty and distribution shift.
- Interpreting attention weights as complete explanations.
- Using visual appeal instead of quantitative fidelity.

## 13. الأخطاء الشائعة

تشمل الخلط بين التفسير والسببية، وتجاهل الترابط، واستخدام عينات غير واقعية، والاعتماد على رسم جذاب دون تقييم كمي.

## 14. Engineering Workflow



1. Clarify whether a global or local explanation is required.
2. Use more than one explanation method where practical.
3. Check sensitivity to reference data and perturbations.
4. Compare findings with engineering knowledge.
5. Document limitations before operational use.



## 14. سير العمل الهندسي

نحدد نوع الشرح المطلوب، ونختبر دقته واستقراره، ثم نتحقق منه بالفيزياء قبل استخدامه تشغيليًا.



### Research Corner

**Emerging directions:** causal XAI, uncertainty-aware explanations, physics-informed explanations, explanation monitoring, counterfactuals under grid constraints, and human-in-the-loop validation.

## زاوية البحث العلمي

تشمل الاتجاهات الحديثة التفسير السببي، وعدم اليقين، والقيود الفيزيائية، والتفسيرات المضادة للواقع، والتحقق البشري.



## Review Questions

1. What is the difference between interpretability and explainability?
2. How do global and local explanations differ?
3. How is permutation importance calculated?
4. What are the main limitations of PDP and LIME?
5. Explain the SHAP additive formula.
6. Why do correlated features complicate attribution?
7. Why is explanation not causality?
8. How should an explanation be validated physically?

## أسئلة المراجعة

1. ما الفرق بين قابلية الفهم والتفسير؟
2. ما الفرق بين التفسير العام والمحلي؟
3. كيف تحسب أهمية التبدل؟
4. ما قيود PDP و LIME؟
5. اشرح الصيغة الجمعية لـ SHAP.
6. لماذا تعقد الميزات المترابطة توزيع المساهمات؟
7. لماذا لا يعد التفسير سببية؟
8. كيف نتحقق من التفسير فيزيائياً؟

## References | المراجع

المراجع العامة المستخدمة في هذا المقرر

[1] A. Gabash, *Flexible Optimal Operations of Energy Supply Networks with Renewable Energy Generation and Battery Storage*. Saarbrücken, Germany: Südwestdeutscher Verlag für Hochschulschriften, 2014.

[2] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th Global ed. Harlow, U.K.: Pearson Education Limited, 2022.

[3] A. Gabash, "Energy Market Transition and Climate Change: A Review of TSOs-DSOs C++ Framework from 1800 to Present," *Energies*, vol. 16, no. 17, Art. no. 6139, 2023, doi: 10.3390/en16176139.

[4] A. Gabash, *AI Applications in Electrical Power Systems*, Version 1.0, 2026. [Online]. Available: <https://aoussgabash.com>

## Publication Information | معلومات النشر

|                  |                                                               |
|------------------|---------------------------------------------------------------|
| Document         | Lecture 13 · Explainable Artificial Intelligence              |
| Course           | AI Applications in Electrical Power Systems                   |
| Author           | Dr.-Ing. Aouss Gabash                                         |
| Version          | 1.0                                                           |
| Publication year | 2026                                                          |
| Official website | <a href="https://aoussgabash.com">https://aoussgabash.com</a> |
| Citation style   | IEEE                                                          |

### Recommended citation:

Gabash, A. (2026). Explainable Artificial Intelligence. AI Applications in Electrical Power Systems, Lecture 13, Version 1.0. <https://aoussgabash.com>

المرجع المقترح:

أوس غباش، 2026، محاضرة 13، تطبيقات الذكاء الاصطناعي في أنظمة الطاقة الكهربائية، الإصدار 1.0، <https://aoussgabash.com>

© 2026 Dr.-Ing. Aouss Gabash. Educational use with attribution to the author and official website.



## Interactive Quiz — Lecture 13

اختبار تفاعلي — المحاضرة 13

1. Explainable AI primarily aims to:

1. يهدف الذكاء الاصطناعي القابل للتفسير أساساً إلى:

- ☐ Hide model behavior  
إخفاء سلوك النموذج
- ☐ Make model decisions understandable  
جعل قرارات النموذج قابلة للفهم
- ☐ Increase file size  
زيادة حجم الملف
- ☐ Remove validation  
إلغاء التحقق

2. SHAP values are based on ideas from:

2. تعتمد قيم SHAP على أفكار من:

- ☐ Circuit theory only  
نظرية الدارات فقط

- **Fourier optics**

بصريات فورييه

- **Cooperative game theory**

نظرية الألعاب التعاونية

- **Database indexing**

فهرسة قواعد البيانات

### 3. A local explanation describes:

3. يصف التفسير المحلي:

- **One specific prediction**

تنبؤًا محددًا واحدًا

- **Only the entire dataset average**

متوسط البيانات كاملة فقط

- **A physical cable**

كابلًا فيزيائيًا

- **A browser setting**

إعدادات متصفح

### 4. Feature importance alone may be misleading because it may not show:

4. قد تكون أهمية الميزات مضللة لأنها قد لا تظهر:

- **The model name**

اسم النموذج

- **The number of files**

عدد الملفات

- The webpage language

لغة الصفحة

- Direction, interactions, or causality

الاتجاه أو التفاعلات أو السببية

## 5. Why is XAI valuable in power-system operation?

5. لماذا يفيد XAI في تشغيل أنظمة القدرة؟

- It eliminates operators

يلغي المشغلين

- It supports trust, diagnosis, and validation

يدعم الثقة والتشخيص والتحقق

- It guarantees no faults

يضمن عدم وجود أعطال

- It replaces all protection

يستبدل جميع الحماية

تُحفظ نتيجتك في هذا المتصفح فقط | Your result is stored only in this browser.