

# Explainable Artificial Intelligence

## الذكاء الاصطناعي القابل للتفسير

Understanding, validating, and communicating AI decisions in power systems

فهم قرارات الذكاء الاصطناعي والتحقق منها وشرحها في أنظمة القدرة

Prepared by | إعداد: Dr.-Ing. Aouss Gabash | د. م. أوس غباش

### Learning Objectives

- Distinguish interpretability, explainability, transparency, and causality.
- Differentiate global and local explanations.
- Understand permutation importance, partial dependence, LIME, and SHAP.
- Explain Shapley values mathematically.
- Identify explanation pitfalls in correlated power-system data.
- Use XAI for load forecasting, fault detection, and state estimation.

### أهداف التعلم

- التمييز بين قابلية الفهم والتفسير والشفافية والسببية.
- التمييز بين التفسير العام والمحلي.
- فهم أهمية التبديل و PDP و LIME و SHAP.
- شرح قيم شابلي رياضيًا.
- معرفة أخطاء التفسير في البيانات المترابطة.
- استخدام XAI في التنبؤ والأعطال وتقدير الحالة.

## 1. Why Explainability Matters

Power systems are safety-critical. Engineers need to understand why an AI model recommends a decision, especially when the recommendation affects protection, dispatch, voltage control, or reliability.

High predictive accuracy does not automatically imply physical validity, robustness, fairness, or operational safety.

## 1. لماذا نحتاج إلى التفسير؟

تعمل نماذج الذكاء الاصطناعي في تطبيقات حرجية، لذلك يجب معرفة سبب القرار قبل استخدامه في الحماية أو التشغيل أو التحكم.

## 2. Interpretability, Explainability, and Transparency

### Interpretability

How directly a human can understand the model.

### Explainability

Methods used to explain a prediction or behavior.

### Transparency

Visibility of data, training, assumptions, and implementation.

## 2. قابلية الفهم والتفسير والشفافية

النموذج البسيط قد يكون مفهومًا بذاته، بينما يحتاج النموذج المعقد إلى أدوات تفسير. أما الشفافية فتشمل البيانات وطريقة التدريب والافتراضات.

### 3. Global and Local Explanations

#### Global explanation

How the model behaves across the full dataset.

#### Local explanation

Why the model made one specific prediction.

A feature can be globally important but unimportant for one specific operating point, and vice versa.

### 3. التفسير العام والمحلي

يشرح التفسير العام سلوك النموذج ككل، بينما يشرح التفسير المحلي قرارًا واحدًا أو حالة تشغيل محددة.

### 4. Intrinsic and Post-Hoc Explanations

| Type      | Example                  | Advantage                      | Limitation                      |
|-----------|--------------------------|--------------------------------|---------------------------------|
| Intrinsic | Linear model, small tree | Model itself is understandable | May sacrifice flexibility       |
| Post-hoc  | SHAP, LIME, PDP          | Works with complex models      | Explanation is an approximation |

## 4. التفسير الذاتي واللاحق

بعض النماذج قابلة للفهم بذاتها، بينما تحتاج النماذج المعقدة إلى أدوات تفسير بعد التدريب.

## 5. Feature Importance

Feature importance ranks predictors according to their influence on model performance or structure.

Importance does not indicate the direction of influence and does not prove causality.

## 5. أهمية الميزات

تحدد أهمية الميزات أي المتغيرات أكثر تأثيرًا، لكنها لا توضح دائمًا اتجاه التأثير ولا تثبت علاقة سببية.

## 6. Permutation Importance

$$Imp(j) = Loss(X \text{ with feature } j \text{ permuted}) - Loss(X)$$

If permuting a feature destroys predictive structure, model loss increases and the feature is considered important.

When predictors are strongly correlated, one feature can replace another, causing importance to be underestimated.

## 6. أهمية التبديل

نبدل قيم ميزة واحدة عشوائيًا ثم نقيس زيادة الخطأ. إذا ازداد الخطأ كثيرًا كانت الميزة مهمة للنموذج.

## 7. Partial Dependence

$$PD_j(z) = E_X[-j][f(z, X_{-j})]$$

Partial dependence estimates the average prediction when one feature is fixed to  $z$  and all other features retain their observed values.

## 7. الاعتماد الجزئي

يقيس PDP متوسط خرج النموذج عند تثبيت ميزة على قيمة محددة مع إبقاء بقية الميزات كما هي في البيانات.

## 8. Individual Conditional Expectation

ICE curves show one response curve per observation rather than only the average curve.

PDP may hide heterogeneous behavior. ICE reveals whether different operating points respond differently to the same feature.

### 8. منحنيات ICE

تعرض ICE منحنى لكل عينة، ولذلك تكشف اختلاف استجابة حالات التشغيل التي قد يخفيها المتوسط في PDP.

## 9. LIME

LIME creates perturbed samples around a query point, obtains black-box predictions, and fits a weighted simple surrogate.

$$g^* = \operatorname{argmin}_g [L(f, g, \pi_x) + \Omega(g)]$$

**L**

Local fidelity to the black-box model.

$\Omega$

Penalty that keeps the surrogate simple.

## 9. طريقة LIME

تنشئ LIME عينات قريبة من الحالة المطلوب تفسيرها، ثم تدرب نموذجًا بسيطًا موزونًا ليقلد النموذج المعقد محليًا.

## 10. Limits of LIME

- Results depend on the neighborhood definition.
- Different random perturbations may produce different explanations.
- The surrogate may have poor local fidelity.
- Perturbed samples may be physically impossible.

## 10. قيود LIME

تعتمد النتيجة على تعريف الجوار والعينات الاصطناعية، وقد تكون بعض العينات غير واقعية فيزيائيًا.

## 11. Shapley Values

SHAP is based on cooperative game theory. Predictors are players and the model prediction is the payout.

Extra close brace or missing open brace

The contribution of feature  $j$  is averaged over all possible coalitions of other features.

## 11. قيم شابلي

تعامل SHAP الميزات كلاعبين في لعبة تعاونية، وتوزع التنبؤ بينهم بحسب مساهمة كل ميزة عبر جميع المجموعات الممكنة.

## 12. SHAP Additive Explanation

$$f(x) = \varphi_0 + \sum_j \varphi_j$$

$\varphi_0$  is the baseline prediction. Positive SHAP values increase the prediction; negative values decrease it.

## 12. التفسير الجمعي في SHAP

يتكون التنبؤ من قيمة أساس زائد مساهمات جميع الميزات. المساهمة الموجبة ترفع التنبؤ والسالبة تخفضه.

## 13. SHAP Properties

### Local accuracy

Contributions sum to the prediction.

### Missingness

Absent features receive zero contribution.

### Consistency

Increased model influence should not reduce attribution.

## 13. خصائص SHAP

تتميز بالدقة المحلية وانعدام مساهمة الميزة الغائبة والاتساق في توزيع المساهمات.

## 14. Correlated Features

In power systems, load, temperature, hour, and previous load values are often correlated.

Attributions can be split among correlated predictors or assigned differently depending on the background distribution and conditional assumptions.

## 14. الميزات المترابطة

قد تتوزع المساهمة بين ميزات مترابطة مثل الحمل السابق والساعة والحرارة، لذلك يجب تفسير النتائج بحذر.

## 15. Explanation Is Not Causality

$$Predictive\ association \neq\ causal\ effect$$

A high SHAP value means the model used a feature strongly for this prediction. It does not prove that changing the feature will physically cause the predicted change.

### 15. التفسير ليس سببية

توضح SHAP كيف استخدم النموذج الميزة، لكنها لا تثبت أن تغيير الميزة يسبب فعليًا تغيير الخرج.

## 16. Explanation Fidelity

An explanation should be evaluated, not merely visualized.

- Local surrogate  $R^2$
- Stability under small perturbations
- Consistency across similar samples
- Agreement with physical knowledge
- Sensitivity to background data

### 16. جودة التفسير

## 17. XAI for Load Forecasting

### Global

Rank temperature, hour, weekday, and lagged loads.

### Local

Explain why tomorrow's 18:00 peak is high.

## 17. XAI في التنبؤ بالحمل

يمكن ترتيب أهمية الحرارة والساعة والأيام وقيم الحمل السابقة، ثم تفسير توقع قمة محددة محليًا.

## 18. XAI for Fault Detection

Explanations can identify which current, voltage, harmonic, or sequence components drove a fault classification.

An explanation that highlights physically relevant phases and time intervals increases engineering confidence, but still requires validation.

## 18. XAI في كشف الأعطال

يمكن للتفسير تحديد الأطوار أو المركبات أو المقاطع الزمنية التي أثرت في تصنيف العطل.


## 19. XAI for State Estimation and Stability

Feature attribution can indicate influential measurements, buses, or contingencies for a predicted state or stability margin.

### 19. XAI في تقدير الحالة والاستقرار

يمكن تحديد القياسات والقضبان والحالات الطارئة الأكثر تأثيرًا في التقدير أو هامش الاستقرار المتوقع.

## 20. Explanation Workflow



### 20. سير عمل التفسير

بعد تدريب النموذج وفحص دقته، نبدأ بالتفسير العام ثم المحلي ونقارن النتائج بالمعرفة الفيزيائية.

## 21. Common Mistakes

### **Cherry-picking**

Showing only explanations that look reasonable.

### **Ignoring correlation**

Reading attribution as independent influence.

### **No fidelity check**

Trusting a poor surrogate.

### **Causal language**

Claiming explanation proves cause.

## **21. الأخطاء الشائعة**

من الأخطاء اختيار أمثلة مريحة فقط، تجاهل الارتباط، عدم تقييم دقة الشرح، واستخدام لغة سببية دون دليل.



## **Research Corner**

**Emerging directions:** physics-consistent explanations, graph-based XAI, counterfactual explanations, uncertainty-aware attributions, causal XAI, and human-centered explanation interfaces for control rooms.

من الاتجاهات الحديثة التفسيرات المتوافقة مع الفيزياء وGraph-XAI والتفسيرات المضادة للواقع وعدم اليقين والسببية وواجهات غرف التحكم.

### Review Questions

1. Differentiate global and local explanations.
2. Explain permutation importance.
3. Derive the idea behind LIME.
4. What does a SHAP value represent?
5. Why are correlated predictors difficult?
6. Why is explanation not causality?

### أسئلة المراجعة

1. ما الفرق بين التفسير العام والمحلي؟
2. اشرح أهمية التبديل.
3. اشرح فكرة LIME.
4. ماذا تمثل قيمة SHAP؟
5. لماذا تصعب الميزات المترابطة؟
6. لماذا لا يعني التفسير السببية؟