

# Generative AI and Large Language Models

## الذكاء الاصطناعي التوليدي والنماذج اللغوية الكبيرة

From tokens and embeddings to retrieval-augmented engineering assistants  
من الرموز والتمثيلات إلى المساعدات الهندسية المعززة بالاسترجاع

د. م. أوس غباش | إعداد: Dr.-Ing. Aouss Gabash

### Learning Objectives

- Explain generative modeling and autoregressive language modeling.
- Understand tokenization, embeddings, positional information, and decoder transformers.
- Describe pretraining, instruction tuning, and preference alignment.
- Explain prompting, context windows, and hallucination.
- Design a retrieval-augmented generation pipeline.
- Evaluate engineering assistants for accuracy, traceability, and safety.

### أهداف التعلم

- فهم النمذجة التوليدية والتوليد اللغوي الذاتي.
- فهم التقسيم إلى رموز والتمثيلات والترميز الموضعي و Decoder Transformer.
- شرح التدريب المسبق وضبط التعليمات ومواءمة التفضيلات.
- فهم الأوامر وسياق الإدخال والهלוسة.
- تصميم نظام RAG.
- تقييم المساعد الهندسي من حيث الدقة والتتبع والأمان.

## 1. What Is Generative AI?

Generative AI learns a probability distribution over data and produces new samples such as text, images, code, waveforms, or structured engineering reports.

$$\hat{x} \sim p_{\theta}(x)$$

A discriminative model predicts a label or value. A generative model produces new content consistent with learned patterns.

### 1. ما هو الذكاء الاصطناعي التوليدي؟

يتعلم توزيعًا احتماليًا للبيانات ثم يولد محتوى جديدًا، مثل النصوص والصور والأكواد والتقارير الهندسية.

## 2. Autoregressive Language Modeling

$$P(w_1, \dots, w_n) = \prod_t P(w_t | w_1, \dots, w_{t-1})$$

The model generates one token at a time by estimating the probability of the next token given previous tokens.

### 2. النمذجة اللغوية الذاتية

يولد النموذج رمزًا بعد آخر اعتمادًا على الرموز السابقة، ويختار الرمز التالي من توزيع احتمالي.

### 3. Tokenization

Text is split into tokens. A token can be a whole word, part of a word, punctuation, or a symbol.

"voltage stability"  $\rightarrow$  [token<sub>1</sub>, token<sub>2</sub>, token<sub>3</sub>, ...]

Tokenization affects sequence length, multilingual performance, formulas, and the representation of technical terminology.

### 3. التقسيم إلى رموز

يُقسَّم النص إلى رموز قد تكون كلمات كاملة أو أجزاء كلمات أو علامات. ويؤثر ذلك في طول السياق وفهم المصطلحات الهندسية.

### 4. Embeddings

$$e_t = E[token_t] \in R^d$$

Each token is mapped to a vector. Similar contexts often produce related vector representations.

### Token embedding

Represents lexical meaning.


### Document embedding

Represents a sentence, paragraph, or chunk for retrieval.

## 4. التمثيلات المتجهية

يُحوّل كل رمز أو مستند إلى متجه عددي يمكن استخدامه للمقارنة والاسترجاع والتعلم.

## 5. Decoder Transformer



$$P(token_t | token_1, \dots, token_{t-1}) = \text{softmax}(Wh_t)$$

## 5. بنية Decoder Transformer

تستخدم الانتباه الذاتي المقنَّع حتى لا يرى الموضع الرموز المستقبلية، ثم تنتج احتمالات الرمز التالي.

## 6. Causal Masking

$$Attention score(i, j) = -\infty \text{ for } j > i$$

The mask prevents a token from attending to future tokens during autoregressive training.

### 6. القناع السببي

يمنع النموذج من رؤية الرموز اللاحقة أثناء التدريب، ويحافظ على طبيعة التوليد خطوة بخطوة.

## 7. Pretraining

During pretraining, the model learns statistical structure from large text collections by minimizing next-token prediction loss.

$$L = - \sum_t \log P_{\theta}(w_t | w_1, \dots, w_{t-1})$$

### 7. التدريب المسبق

يتعلم النموذج البنية اللغوية والمعلومات العامة عبر تقليل خطأ توقع الرمز التالي على مجموعات نصية كبيرة.

## 8. Instruction Tuning and Alignment

### Pretraining

Learn language and broad patterns.

### Instruction tuning

Learn to follow task descriptions.

### Preference alignment

Improve helpfulness, safety, and style.

## 8. ضبط التعليمات والمواءمة

بعد التدريب المسبق، يُضبط النموذج على تعليمات، ثم تُستخدم تفضيلات بشرية أو آلية لتحسين السلوك.

## 9. Prompting

A prompt defines the task, context, constraints, expected format, and sometimes examples.

Good engineering prompts specify units, assumptions, data boundaries, output format, and whether uncertainty must be stated.

## 9. صياغة الأوامر

يجب أن يحدد الأمر المهمة والسياق والقيود والوحدات وشكل الخرج والافتراضات المطلوبة.

## 10. Zero-Shot, Few-Shot, and Structured Prompting

| Method     | Description              | Engineering use              |
|------------|--------------------------|------------------------------|
| Zero-shot  | Instruction only         | Simple summarization         |
| Few-shot   | Include examples         | Consistent report formatting |
| Structured | Explicit sections/schema | JSON, tables, checklists     |

## 10. الأوامر دون أمثلة ومع أمثلة

يمكن إعطاء التعليمات فقط، أو إضافة أمثلة، أو فرض بنية واضحة للخروج مثل جدول أو JSON.

## 11. Context Window

The context window contains the prompt, retrieved documents, conversation, and generated output.

More context is not always better. Irrelevant text can distract the model and increase cost and latency.

## 11. نافذة السياق

تضم الأمر والمستندات المسترجعة والمحادثة والخرج. وقد يؤدي السياق الزائد وغير المرتبط إلى نتائج أضعف.

## 12. Sampling

### Temperature

Controls randomness of token selection.

### Top-p

Restricts sampling to a probability mass.

For engineering calculations and factual extraction, lower randomness is usually preferable.

## 12. أخذ العينات

تتحكم Temperature و Top-p بدرجة العشوائية. وتناسب القيم المنخفضة المهام الهندسية الدقيقة غالبًا.



## 13. Hallucination


A hallucination is a plausible-sounding output that is unsupported, incorrect, or fabricated.

Language-model confidence is not a calibrated probability of factual correctness.

## 13. الهلوسة

قد يولد النموذج إجابة مقنعة لغويًا لكنها خاطئة أو غير مدعومة. ولا تعني الصياغة الواثقة صحة المعلومة.

## 14. Retrieval-Augmented Generation



RAG does not retrain the model. It supplies relevant external knowledge at query time.

## 14. التوليد المعزز بالاسترجاع RAG

يحوّل السؤال إلى تمثيل، ويسترجع المقاطع الأقرب، ثم يضيفها إلى الأمر قبل توليد الإجابة مع المصادر.

## 15. Chunking

Documents are divided into chunks before indexing.

### Small chunks

Precise retrieval but limited context.

### Large chunks

More context but less retrieval precision.

## 15. تقسيم المستندات

تُقسَّم المستندات إلى مقاطع. المقاطع الصغيرة أدق في الاسترجاع، والكبيرة توفر سياقًا أوسع.

## 16. Similarity Search

$$\cos(q, d) = q^T d / (\|q\| \cdot \|d\|)$$

The query embedding is compared with document-chunk embeddings. The highest-scoring chunks are returned.

## 16. البحث بالتشابه

تُقارن متجهات السؤال بالمقاطع باستخدام تشابه جيب التمام، ثم تُسترجع المقاطع الأعلى تشابهًا.

## 17. Grounded Engineering Answers

A grounded assistant should:

- Use only retrieved evidence for factual claims.
- Cite the source chunk.
- State when evidence is missing.
- Preserve units and equations.
- Avoid inventing standards or limits.

### 17. الإجابات الهندسية المستندة إلى المصادر

يجب الاعتماد على الأدلة المسترجعة، وذكر المصدر، والتصريح عند نقص المعلومات، والحفاظ على الوحدات والمعادلات.

## 18. Tool Use and Agents

An LLM can call external tools such as calculators, simulators, databases, or optimization software.

Plan → Tool call → Observation → Revised plan → Answer

Tool output must be validated. A correct tool call does not guarantee the model interpreted the result correctly.

## 18. استخدام الأدوات والوكلاء

يمكن للنموذج استدعاء حاسبة أو محاكي أو قاعدة بيانات، ثم استخدام الناتج في الإجابة. ويجب التحقق من تفسير النتائج.

## 19. Applications in Power Engineering

### Operator assistant

Retrieve procedures and explain alarms.

### Report generation

Draft event and maintenance reports.

### Code assistant

Generate MATLAB or Python prototypes.

### Knowledge search

Search manuals, theses, and standards.

### Training tutor

Explain concepts and create exercises.

## Data interface

Translate natural language into queries.

## 19. التطبيقات في هندسة القدرة

تشمل مساعد المشغل وتوليد التقارير ومساعدة البرمجة والبحث في الوثائق والتعليم والتفاعل مع البيانات.

## 20. Security and Privacy

- Do not expose confidential grid data unnecessarily.
- Separate trusted and untrusted documents.
- Protect against prompt injection.
- Log sources and tool calls.
- Apply access control and data minimization.

## 20. الأمن والخصوصية

يجب حماية بيانات الشبكة وفصل المصادر الموثوقة وتقييد الصلاحيات ومقاومة حقن الأوامر وتسجيل الاستدعاءات.

## 21. Evaluation

### Retrieval quality

Did the system retrieve the right evidence?

### Faithfulness

Is the answer supported by evidence?

### Completeness

Did it address all required points?

### Engineering validity

Are units, equations, and limits correct?

## 21. التقييم

يجب تقييم جودة الاسترجاع ووفاء الإجابة بالمصادر واكتمالها وصحتها الهندسية.



## Research Corner

**Emerging directions:** multimodal grid assistants, small domain-specific language models, structured generation, agentic simulation workflows, long-context engineering search, and uncertainty-aware RAG.

من الاتجاهات الحديثة المساعدات متعددة الوسائط والنماذج الصغيرة المتخصصة والتوليد المنظم والوكلاء والمحاكاة والسياق الطويل و RAG مع عدم اليقين.

### Review Questions

1. Derive autoregressive factorization.
2. What is the role of tokenization?
3. Why is causal masking required?
4. What causes hallucination?
5. Explain the RAG pipeline.
6. How should an engineering assistant be evaluated?

### أسئلة المراجعة

1. اشتق التحليل الذاتي الاحتمالي.
2. ما دور التقسيم إلى رموز؟
3. لماذا نحتاج القناع السببي؟
4. ما أسباب الهلوسة؟
5. اشرح RAG.
6. كيف يُقَيَّم المساعد الهندسي؟