

LECTURE 17 | المحاضرة 17

Physics-Informed Artificial Intelligence

الذكاء الاصطناعي الموجه بالقوانين الفيزيائية

Embedding power-system equations and constraints into learning models

دمج معادلات أنظمة القدرة وقيودها داخل نماذج التعلم

Prepared by | إعداد: Dr.-Ing. Aouss Gabash

Learning Objectives

- Explain the difference between purely data-driven and physics-informed learning.
- Construct a physics-informed loss function.
- Use automatic differentiation to evaluate differential-equation residuals.
- Apply PINNs to power flow, state estimation, and dynamic stability.
- Understand hard and soft physical constraints.
- Recognize identifiability, scaling, and optimization challenges.

أهداف التعلم

- التمييز بين التعلم المعتمد على البيانات والتعلم الموجه بالفيزياء.
- بناء دالة خسارة فيزيائية.
- استخدام الاشتقاق التلقائي لحساب متبقي المعادلات التفاضلية.
- تطبيق PINNs في تدفق القدرة وتقدير الحالة والاستقرار الديناميكي.
- فهم القيود الفيزيائية الصلبة والمرنة.
- معرفة تحديات قابلية التعرف والتحجيم والتحسين.

1. Why Physics-Informed AI?

Purely data-driven models can fit historical samples while violating Kirchhoff laws, energy balance, dynamic equations, or equipment limits.

Physics-informed AI combines observations with equations so that the learned model is encouraged to remain physically meaningful.

1. لماذا نحتاج الذكاء الاصطناعي الموجه بالفيزياء؟

قد يحقق النموذج دقة عالية على البيانات، لكنه يخالف قوانين كيرشوف أو اتزان القدرة أو القيود التشغيلية. لذلك نضيف الفيزياء إلى عملية التعلم.

2. Three Learning Paradigms

Data-driven

Learn only from input-output samples.

Model-based

Solve explicit physical equations.

Physics-informed

Combine data, equations, and constraints.

2. ثلاثة أساليب للتعلم

الأول يعتمد على البيانات فقط، والثاني على النموذج الفيزيائي فقط، والثالث يجمع البيانات والمعادلات والقيود.

3. General PINN Formulation

Suppose the unknown state $u(x,t)$ satisfies:

$$N[u(x,t); \lambda] = 0$$

A neural network $\hat{u}_\theta(x,t)$ approximates the solution. Automatic differentiation computes required derivatives.

3. الصياغة العامة لـ PINN

تقرب الشبكة العصبية الحل المجهول، ثم تحسب مشتقاته تلقائيًا وتُقارن بالمعادلة الفيزيائية.

4. Composite Loss Function

$$J(\theta) = \lambda_{data} J_{data} + \lambda_{phys} J_{physics} + \lambda_{IC} J_{initial} + \lambda_{BC} J_{boundary} + \lambda_{reg} J_{regularization}$$

Data loss

Agreement with measurements.

Physics loss

Residual of governing equations.

Initial/boundary loss

Enforce known conditions.

Regularization

Controls model complexity.

4. دالة الخسارة المركبة

تجمع الخسارة بين مطابقة القياسات ومتطلبات المعادلات الفيزيائية والشروط الابتدائية والحدودية والتنظيم.

5. Soft and Hard Constraints

Constraint	Implementation	Property
Soft	Add penalty to loss	May be slightly violated
Hard	Build into architecture/output transform	Satisfied exactly

$$\hat{u}(t) = u_0 + t \cdot NN\theta(t)$$

This transformation enforces $\hat{u}(0)=u_0$ exactly.

5. القيود المرنة والصلبة

تضاف القيود المرنة كعقوبات، بينما تُبنى القيود الصلبة في شكل الخرج بحيث تتحقق تمامًا.

6. Automatic Differentiation

PINNs require derivatives of network outputs with respect to inputs.

$$d\hat{u}/dt, d^2\hat{u}/dt^2, \partial\hat{u}/\partial x, \partial^2\hat{u}/\partial x^2$$

Automatic differentiation evaluates exact derivatives of the computational graph up to floating-point precision, avoiding finite-difference truncation errors.

6. الاشتقاق التلقائي

يحسب مشتقات خرج الشبكة بالنسبة إلى الزمن أو المكان مباشرة من الرسم الحسابي، دون استخدام فروق عددية تقريبية.

7. Collocation Points

Physics residuals are evaluated at points in the problem domain, even when no measurements exist there.

$$J_{physics} = (1/Nf) \sum_i |N[\hat{u}\theta(x_i, t_i)]|^2$$

7. نقاط الفحص الفيزيائي

تُقيم المعادلة عند نقاط داخل المجال، حتى لو لم توجد قياسات عندها، مما يسمح باستخدام الفيزياء كإشراف إضافي.

8. Power-Flow Physics

$$P_i = \sum_j |V_i||V_j|(G_{ij}\cos\theta_{ij} + B_{ij}\sin\theta_{ij})$$

$$Q_i = \sum_j |V_i||V_j|(G_{ij}\sin\theta_{ij} - B_{ij}\cos\theta_{ij})$$

A physics-informed estimator can penalize active- and reactive-power mismatches.

8. فيزياء تدفق القدرة

يمكن إضافة متبقي معادلات القدرة الفعالة والردية إلى خسارة نموذج تقدير الجهود والزوايا.

9. Kirchhoff-Informed Learning

$$\sum P_{generation} - \sum P_{load} - \sum P_{flow} = 0$$

$$\sum I_{in} = \sum I_{out}$$

Network balance constraints can be enforced at every bus.

9. التعلم الموجّه بقوانين كيرشوف

تُفرض معادلات اتزان القدرة أو التيار عند كل عقدة، مما يقلل الحلول غير الفيزيائية.

10. Swing Equation

$$Md^2\delta/dt^2 + Dd\delta/dt = P_m - P_e(\delta)$$

$$P_e(\delta) = P_m \sin \delta$$

The swing equation describes rotor-angle dynamics after disturbances.

10. معادلة التآرجح

تصف ديناميكا زاوية الدوار اعتمادًا على العطالة والتخميد والقدرة الميكانيكية والكهربائية.

11. PINN Residual for the Swing Equation

$$r(t) = M\delta''(t) + D\delta'(t) - P_m + P_m \sin(\delta(t))$$

$$J_{physics} = \text{mean}(r(t)^2)$$

Initial-angle and initial-speed conditions are added to the loss or enforced exactly.

11. متبقي PINN لمعادلة التآرجح

يُحسب متبقي المعادلة من خرج الشبكة ومشتقاته، ثم يُصَفَّر متوسط مربعه أثناء التدريب.

12. Forward and Inverse Problems

Forward problem

Known parameters, unknown state trajectory.

Inverse problem

Measurements available, unknown physical parameters.

Learn M, D , or line parameters jointly with the state.

12. المسائل المباشرة والعكسية

في المسألة المباشرة نعرف المعاملات ونبحث عن الحالة، وفي العكسية نتعلم معاملات مجهولة مثل العطالة أو التخمين من القياسات.

13. Hybrid Models

Physics can be incorporated at different levels:

- Physics-based features
- Physics penalties
- Physics layers
- Residual correction models
- Neural differential equations

13. النماذج الهجينة

يمكن دمج الفيزياء كمميزات أو عقوبات أو طبقات أو نماذج تصحيح أو معادلات تفاضلية عصبية.

14. Benefits

Less labeled data

Equations provide additional supervision.

Physical consistency

Reduces impossible predictions.

Parameter estimation

Supports inverse problems.

Generalization

Can improve behavior outside dense data regions.

14. الفوائد

قد تقل الحاجة إلى البيانات وتزداد الاتساق الفيزيائي وإمكانات تقدير المعاملات والتعميم.

15. Challenges

Loss imbalance

One loss component may dominate.

Stiff dynamics

Multiple time scales are difficult to train.

Scaling

Variables and residuals have different magnitudes.

Optimization

Nonconvex training can stagnate.

15. التحديات

تشمل عدم توازن مكونات الخسارة، والأنظمة الصلبة، واختلاف المقاييس، وصعوبة التحسين غير المحدب.

16. Adaptive Loss Weighting

$$J = \sum_k \lambda_k J_k$$

Weights can be adjusted using gradient magnitudes, uncertainty, or curriculum learning.

A small total loss does not guarantee that every physical residual is acceptably small.

16. الموازنة التكيفية للخسائر

يمكن تعديل أوزان مكونات الخسارة حسب التدرجات أو عدم اليقين أو مراحل التدريب.

17. Applications in Power Systems

Power flow surrogates

Fast physically constrained approximations.

State estimation

Measurements plus network equations.

Dynamic stability

Learn trajectories and parameters.

Parameter identification

Estimate inertia, damping, and impedances.

Battery models

Combine electrochemical dynamics and data.

Renewable systems

Embed converter and plant equations.

17. التطبيقات

تشمل تقريب تدفق القدرة وتقدير الحالة والاستقرار وتحديد المعاملات ونماذج البطاريات والطاقة المتجددة.

18. Validation

- Compare with a trusted numerical solver.
- Evaluate equation residuals separately.
- Test unseen disturbances and parameters.
- Check conservation laws.
- Report uncertainty and failure cases.

18. التحقق

يجب المقارنة مع محلل عددي موثوق وفحص المتبقي الفيزيائي والحالات غير المرئية وقوانين الحفظ وحالات الفشل.



Research Corner

Emerging directions: physics-informed graph networks, operator learning, differentiable power-flow solvers, neural ODEs, uncertainty-aware PINNs, and domain decomposition for large grids.

زاوية البحث العلمي

من الاتجاهات الحديثة GNN الموجهة بالفيزياء، والمؤثرات العصبية، ومحللات تدفق القدرة القابلة للاشتقاق، وNeural ODE، وعدم اليقين، وتقسيم المجال.



Review Questions

1. Construct a composite physics-informed loss.
2. What is the difference between hard and soft constraints?
3. How does automatic differentiation support PINNs?
4. Write the swing-equation residual.
5. What is an inverse PINN problem?
6. Why is loss scaling important?

أسئلة المراجعة

1. ابن دالة خسارة موجهة بالفيزياء.
2. ما الفرق بين القيود الصلبة والمرنة؟
3. كيف يدعم الاشتقاق التلقائي PINNs؟
4. اكتب متبقي معادلة التآرجح.
5. ما المسألة العكسية؟
6. لماذا تحجيم الخسائر مهم؟

References | المراجع

المراجع العامة المستخدمة في هذا المقرر

[1] A. Gabash, *Flexible Optimal Operations of Energy Supply Networks with Renewable Energy Generation and Battery Storage*. Saarbrücken, Germany: Südwestdeutscher Verlag für Hochschulschriften, 2014.

[2] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th Global ed. Harlow, U.K.: Pearson Education Limited, 2022.

[3] A. Gabash, "Energy Market Transition and Climate Change: A Review of TSOs-DSOs C++ Framework from 1800 to Present," *Energies*, vol. 16, no. 17, Art. no. 6139, 2023, doi: 10.3390/en16176139.

[4] A. Gabash, *AI Applications in Electrical Power Systems*, Version 1.0, 2026. [Online]. Available: <https://aoussgabash.com>

Publication Information | معلومات النشر

Document	Lecture 17 · Physics-Informed Artificial Intelligence
Course	AI Applications in Electrical Power Systems
Author	Dr.-Ing. Aouss Gabash
Version	1.0
Publication year	2026
Official website	https://aoussgabash.com
Citation style	IEEE

Recommended citation:

Gabash, A. (2026). Physics-Informed Artificial Intelligence. AI Applications in Electrical Power Systems, Lecture 17, Version 1.0. <https://aoussgabash.com>

المرجع المقترح:

أوس غباش، 2026، محاضرة 17، تطبيقات الذكاء الاصطناعي في أنظمة الطاقة الكهربائية، الإصدار 1.0، <https://aoussgabash.com>

© 2026 Dr.-Ing. Aouss Gabash. Educational use with attribution to the author and official website.