

LECTURE 17 | المحاضرة 17

Physics-Informed Artificial Intelligence

الذكاء الاصطناعي الموجه بالقوانين الفيزيائية

Embedding Power-System Equations and Constraints into Learning Models

دمج معادلات أنظمة القدرة وقيودها داخل نماذج التعلم

Motivation

PINN Formulation

Constraints

Power Flow

Dynamics

Workflow

Prepared by | إعداد | Dr.-Ing. Aouss Gabash



Learning Outcomes

مخرجات التعلم

- Design an intelligent controller and compare it with conventional control.
تصميم متحكم ذكي ومقارنته بالتحكم التقليدي.
- Interpret the governing mathematical or algorithmic principles.
تفسير المبادئ الرياضية أو الخوارزمية الحاكمة.
- Connect the topic to practical electrical-power-engineering applications.
ربط الموضوع بتطبيقات عملية في هندسة الطاقة الكهربائية.



Prerequisites

المتطلبات
السابقة

Fuzzy logic, control systems, and dynamic models.

المنطق الضبابي وأنظمة التحكم والنماذج الديناميكية.

Intelligent Control and Fuzzy Logic |

التحكم الذكي والمنطق الضبابي



Learning Objectives

- Distinguish data-driven, model-based, and physics-informed learning.
- Construct a composite physics-informed loss.
- Use automatic differentiation for physical residuals.
- Apply PINNs to power flow, state estimation, and dynamic stability.
- Understand hard and soft constraints.

- Identify scaling, identifiability, and optimization challenges.
- Validate learned solutions using physical and numerical criteria.

أهداف التعلم

- التمييز بين التعلم البياني والقائم على النموذج والموجه بالفيزياء.
- بناء دالة خسارة فيزيائية مركبة.
- استخدام الاشتقاق التلقائي لحساب المتبقي الفيزيائي.
- تطبيق PINNs في تدفق القدرة وتقدير الحالة والاستقرار الديناميكي.
- فهم القيود الصلبة والمرنة.
- معرفة تحديات التحجيم وقابلية التعرف والتحسين.
- التحقق من الحلول المتعلمة فيزيائيًا وعدديًا.

1. Why Physics-Informed AI?

Purely data-driven models can fit historical samples while violating Kirchhoff laws, energy balance, dynamic equations, or equipment limits.

Physics-informed AI combines measurements with equations so the learned model is encouraged to remain physically meaningful.

1. لماذا نحتاج إلى الذكاء الاصطناعي الموجه بالفيزياء؟

قد يحقق النموذج دقة عالية على البيانات لكنه يخالف قوانين كيرشوف أو اتزان القدرة أو القيود التشغيلية، لذلك ندمج الفيزياء داخل عملية التعلم.

2. Three Learning Paradigms

Data-Driven

Learns only from input-output samples.

Model-Based

Solves explicit physical equations.

Physics-Informed

Combines data, equations, and constraints.

Hybrid Residual

Uses AI to correct a physical model.

2. أساليب التعلم


يمكن الاعتماد على البيانات أو الفيزياء أو الجمع بينهما، كما يمكن استخدام نموذج ذكاء اصطناعي لتصحيح خطأ نموذج فيزيائي.

3. General PINN Formulation

Suppose an unknown state $u(x,t)$ satisfies a governing equation:

$$N[u(x,t); \lambda] = 0$$

A neural network $\hat{u}_\theta(x,t)$ approximates the solution, and automatic differentiation computes the derivatives required by N .



3. الصياغة العامة لـ PINN

تقرب الشبكة الحل المجهول، ثم تُحسب مشتقاته تلقائيًا وتُقارن بالمعادلة الفيزيائية.

4. Composite Loss Function

$$J(\theta) = \lambda_d J_{data} + \lambda_p J_{physics} + \lambda_{IC} J_{initial} + \lambda_{BC} J_{boundary} + \lambda_r J_{reg}$$

Data Loss

Agreement with measurements.

Physics Loss

Residual of governing equations.

Initial/Boundary Loss

Known conditions.

Regularization

Controls complexity and smoothness.

Poor weighting can cause one loss component to dominate and prevent meaningful training.

4. دالة الخسارة المركبة

تجمع الخسارة بين القياسات والمعادلات والشروط الابتدائية والحدودية والتنظيم، ويجب موازنة أوزانها بعناية.

5. Soft and Hard Constraints

Constraint	Implementation	Property
Soft	Penalty in loss	May be slightly violated
Hard	Architecture or output transform	Satisfied exactly

$$\hat{u}(t) = u_0 + t \cdot NN\theta(t)$$

This output transform enforces $\hat{u}(0)=u_0$ exactly.

5. القيود المرنة والصلبة

تُضاف القيود المرنة كعقوبات، بينما تُبنى القيود الصلبة في شكل الخرج بحيث تتحقق تمامًا.

6. Automatic Differentiation

$$d\hat{u}/dt, d^2\hat{u}/dt^2, \partial\hat{u}/\partial x, \partial^2\hat{u}/\partial x^2$$

Automatic differentiation evaluates derivatives of the computational graph to floating-point precision and avoids finite-difference truncation errors.

6. الاشتقاق التلقائي

يُحسب مشتقات خرج الشبكة بالنسبة إلى الزمن أو المكان مباشرةً من الرسم الحسابي دون فروق عددية تقريبية.

7. Collocation Points

Physics residuals are evaluated at points throughout the domain, including locations with no measurements.

$$J_{physics} = (1/Nf) \sum |N[\hat{u}\theta(xi, ti)]|^2$$

Adaptive sampling can concentrate collocation points where residuals are largest.

7. نقاط الفحص الفيزيائي

تُقيّم المعادلة عند نقاط داخل المجال حتى دون وجود قياسات، ويمكن زيادة كثافة النقاط في المناطق ذات الخطأ الأكبر.

8. Power-Flow Physics

$$P_i = \sum_j |V_i| |V_j| (G_{ij} \cos \theta_{ij} + B_{ij} \sin \theta_{ij})$$

$$Q_i = \sum_j |V_i| |V_j| (G_{ij} \sin \theta_{ij} - B_{ij} \cos \theta_{ij})$$

$$JPF = \sum_i [(P_i - \hat{P}_i)^2 + (Q_i - \hat{Q}_i)^2]$$

A physics-informed estimator can penalize active- and reactive-power mismatch while fitting measured voltages and injections.

8. فيزياء تدفق القدرة

يمكن إضافة متبقي معادلات القدرة الفعالة والردية إلى خسارة نموذج تقدير الجهود والزوايا.

9. Kirchhoff-Informed Learning

$$\sum P_{\text{generation}} - \sum P_{\text{load}} - \sum P_{\text{flow}} = 0$$

$$\sum I_{\text{in}} = \sum I_{\text{out}}$$

Enforcing nodal balance reduces physically impossible predictions and improves diagnostic value.

9. التعلم الموجّه بقوانين كيرشوف

تفرض معادلات اتزان القدرة أو التيار عند كل عقدة، مما يقلل الحلول غير الفيزيائية.

10. Physics-Informed State Estimation

$$z = h(x) + e$$

$$J = \|z - h(\hat{x}\theta)\|^2 + \lambda \|g(\hat{x}\theta)\|^2$$

The first term fits measurements and the second penalizes violated power-system equations or limits.

Physics-informed estimation does not remove the need for observability and bad-data analysis.

10. تقدير الحالة الموجّه بالفيزياء

تجمع الخسارة بين مطابقة القياسات واحترام معادلات الشبكة، مع بقاء الرصد وكشف البيانات السيئة ضروريين.

11. Swing Equation

$$M d^2\delta/dt^2 + D d\delta/dt = P_m - P_e(\delta)$$

$$P_e(\delta) = P_{max} \sin\delta$$

The swing equation describes rotor-angle dynamics following a disturbance.

11. معادلة التّأرجح

تصف ديناميكا زاوية الدوار اعتمادًا على العطالة والتخميد والقدرة الميكانيكية والكهربائية.

12. PINN Residual for Dynamic Stability

$$r(t) = M \delta^{\prime\prime}(t) + D \delta^{\prime}(t) - P_m + P_{max} \sin \delta^{\prime}(t)$$

$$J_{physics} = \text{mean}[r(t)^2]$$

Initial angle and speed can be enforced through penalties or exact output transformations.

12. متبقي PINN للاستقرار الديناميكي

يُحسب متبقي معادلة التآرجح من خرج الشبكة ومشتقاته ثم يُصَغَّر أثناء التدريب.

13. Forward and Inverse Problems

Forward Problem

Known parameters, unknown state trajectory.

Inverse Problem

Measurements available, unknown physical parameters.

Learn $M, D, line$ parameters, or load dynamics jointly with the state.

Identifiability must be checked: different parameter combinations may explain the same measurements.

13. المسائل المباشرة والعكسية

في المسألة المباشرة نعرف المعاملات ونبحث عن الحالة، وفي العكسية نتعلم معاملات مجهولة من القياسات مع ضرورة فحص قابلية التعرف.

14. Hybrid Physics-AI Architectures

- Physics-based input features.
- Physics penalties in the loss.
- Differentiable physics layers.
- Residual correction models.
- Neural ordinary differential equations.
- Graph neural networks with network constraints.

$$\hat{y} = y_{physics} + \Delta y_{AI}$$

14. البنى الهجينة

يمكن دمج الفيزياء كمميزات أو عقوبات أو طبقات قابلة للاشتقاق أو نماذج تصحيح أو معادلات تفاضلية عصبية.

15. Benefits

Less Labeled Data

Equations provide additional supervision.

Physical Consistency

Reduces impossible predictions.

Parameter Estimation

Supports inverse problems.

Generalization

Can improve behavior outside dense data regions.

15. الفوائد

قد تقل الحاجة إلى البيانات وتزداد الاتساق الفيزيائي وإمكانات تقدير المعاملات والتعميم.

16. Challenges and Failure Modes

Loss Imbalance

One objective dominates training.

Stiff Dynamics

Multiple time scales are hard to learn.

Scaling

Variables and residuals differ greatly in magnitude.

Optimization

Nonconvex training can stagnate.

Model Error

Incorrect physics can bias the solution.

Identifiability

Parameters may not be uniquely recoverable.

16. التحديات وأنماط الفشل

تشمل عدم توازن الخسارة والأنظمة الصلبة واختلاف المقاييس وصعوبة التحسين وخطأ النموذج وعدم قابلية التعرف.

17. Training Improvements

- Nondimensionalize inputs and residuals.
- Use adaptive loss weighting.
- Apply curriculum or staged training.
- Use residual-based adaptive sampling.
- Combine Adam with second-stage quasi-Newton optimization.
- Monitor each physical residual separately.

17. تحسين التدريب

يساعد توحيد المقاييس والأوزان التكميلية والتدريب المرحلي وأخذ العينات التكيفي ومراقبة كل متبقٍ على تحسين التقارب.

18. Validation


1. Compare with trusted numerical solvers.
2. Check equation residuals and operating limits.
3. Test unseen disturbances and parameters.
4. Quantify uncertainty and sensitivity.
5. Check conservation laws independently of training loss.
6. Evaluate computational cost and reproducibility.

$$\varepsilon_{phys} = \|N[\hat{u}\theta]\|, \varepsilon_{data} = \|y - \hat{y}\|$$

18. التحقق

نقارن الحل بمحاكٍ موثوق ونفحص المتبقي والحدود والحالات غير المرئية وعدم اليقين وقابلية إعادة النتائج.

19. Engineering Workflow



1. Define governing equations, constraints, and unknowns.
2. Determine which quantities are measured and which are latent.
3. Choose soft, hard, or hybrid constraint enforcement.
4. Normalize variables and balance loss terms.
5. Validate against solvers, measurements, and conservation laws.

19. سير العمل الهندسي

نحدد المعادلات والبيانات والمجهولات، ثم نصمم الخسارة ونوازنها ونتحقق من الحل بالفيزياء والمحاكاة.



Research Corner

Emerging directions: physics-informed graph neural networks, operator learning, differentiable power-flow solvers, uncertainty-aware PINNs, multi-fidelity learning, and online physics-informed adaptation.

زاوية البحث العلمي

تشمل الاتجاهات الحديثة الشبكات البيانية الموجهة بالفيزياء وتعلم المؤثرات ومحاكيات تدفق القدرة القابلة للاشتقاق وPINNs مع عدم اليقين والتعلم متعدد الدقة.



Review Questions

1. How does physics-informed learning differ from purely data-driven learning?
2. Construct a composite PINN loss.
3. What is automatic differentiation?
4. How can power-flow equations be added to training?
5. What is the difference between hard and soft constraints?
6. How is an inverse problem formulated?
7. Why can loss imbalance cause failure?
8. How should a physics-informed model be validated?

أسئلة المراجعة

1. كيف يختلف التعلم الموجّه بالفيزياء عن التعلم البياني؟
2. ابن دالة خسارة PINN مركبة.
3. ما الاشتقاق التلقائي؟
4. كيف تضاف معادلات تدفق القدرة إلى التدريب؟
5. ما الفرق بين القيود الصلبة والمرنة؟
6. كيف تصاغ المسألة العكسية؟
7. لماذا يؤدي عدم توازن الخسارة إلى الفشل؟
8. كيف نتحقق من نموذج موجّه بالفيزياء؟

References | المراجع

المراجع العامة المستخدمة في هذا المقرر

- [1] A. Gabash, *Flexible Optimal Operations of Energy Supply Networks with Renewable Energy Generation and Battery Storage*. Saarbrücken, Germany: Südwestdeutscher Verlag für Hochschulschriften, 2014.
- [2] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th Global ed. Harlow, U.K.: Pearson Education Limited, 2022.
- [3] A. Gabash, "Energy Market Transition and Climate Change: A Review of TSOs-DSOs C+++ Framework from 1800 to Present," *Energies*, vol. 16, no. 17, Art. no. 6139, 2023, doi: 10.3390/en16176139.
- [4] A. Gabash, *AI Applications in Electrical Power Systems*, Version 1.0, 2026. [Online]. Available: <https://aoussgabash.com>

Recommended citation:

Gabash, A. (2026). Physics-Informed Artificial Intelligence. AI Applications in Electrical Power Systems, Lecture 17, Version 1.0. <https://aoussgabash.com>

المرجع المقترح:

أوس غباش، 2026، محاضرة 17، تطبيقات الذكاء الاصطناعي في أنظمة الطاقة الكهربائية، الإصدار 1.0، <https://aoussgabash.com>

© 2026 Dr.-Ing. Aouss Gabash. Educational use with attribution to the author and official website.