

Federated Learning for Smart Grids

التعلم الاتحادي للشبكات الذكية

Collaborative AI without centralizing raw operational data

ذكاء اصطناعي تعاوني دون تجميع البيانات التشغيلية الخام

Prepared by | إعداد | Dr.-Ing. Aouss Gabash | د. م. أوس غباش

Learning Objectives

- Compare centralized, local, and federated machine learning.
- Derive the Federated Averaging (FedAvg) update.
- Explain client selection, local training, aggregation, and communication rounds.
- Understand non-IID data, client drift, and system heterogeneity.
- Distinguish privacy from security and explain secure aggregation and differential privacy.
- Evaluate communication cost, convergence, fairness, robustness, and deployment risks.
- Apply federated learning to smart meters, substations, EV fleets, and distributed energy resources.

أهداف التعلم

- المقارنة بين التعلم المركزي والمحلي والاتحادي.
- اشتقاق تحديث متوسط النماذج الاتحادي FedAvg.
- شرح اختيار العملاء والتدريب المحلي والدمج وجولات الاتصال.
- فهم البيانات غير المتجانسة وانجراف العملاء واختلاف الأجهزة.
- التمييز بين الخصوصية والأمان وشرح التجميع الآمن والخصوصية التفاضلية.

- تقييم كلفة الاتصال والتقارب والعدالة والامتانة ومخاطر النشر.
- تطبيق التعلم الاتحادي على العدادات الذكية والمحطات والمركبات الكهربائية ومصادر الطاقة الموزعة.

1. Why Federated Learning?

Power-system data are naturally distributed among utilities, substations, buildings, smart meters, microgrids, and EV fleets. Moving all raw data to one server may be costly, legally restricted, operationally sensitive, or undesirable for privacy.

Federated Learning (FL) moves the model to the data, not the raw data to the model.



1. لماذا التعلم الاتحادي؟

تتوزع بيانات أنظمة القدرة بين جهات وأجهزة كثيرة. يسمح التعلم الاتحادي بتدريب نموذج مشترك مع إبقاء البيانات الخام محليًا وإرسال تحديثات النموذج فقط.

2. Centralized, Local, and Federated Learning

Approach	Data location	Strength	Limitation
Centralized	All data on one server	Simple global optimization	Privacy, bandwidth, ownership, single-point risk
Local only	Each client trains independently	No data sharing	Limited data diversity and weak generalization
Federated	Raw data remain local	Collaborative learning with reduced data movement	Communication, heterogeneity, privacy leakage from updates

2. التعلم المركزي والمحلي والاتحادي

يجمع التعلم المركزي البيانات في خادم واحد، بينما يدرّب التعلم المحلي نموذجًا منفصلاً لكل عميل. أما التعلم الاتحادي فيدمج تحديثات النماذج دون نقل البيانات الخام.

3. Global Optimization Objective

Assume client k has n_k samples and local objective $F_k(w)$. The global objective is:

$$\min_w F(w) = \sum_{k=1}^K \frac{n_k}{N} F_k(w), \quad N = \sum_{k=1}^K n_k$$

The sample-weighted formulation gives more influence to clients containing more training examples.

3. دالة الهدف العامة

تُكتب دالة الهدف العامة كمجموع موزون لدوال الهدف المحلية، وتتناسب أوزان العملاء عادةً مع عدد العينات لديهم.

4. Federated Averaging (FedAvg)

1. The server initializes a global model w^0 .
2. A subset of clients receives the current model.
3. Each client performs several local optimization steps.
4. Clients return updated parameters or parameter differences.
5. The server computes a weighted average.

$$w_k^{t+1} = \text{LocalTrain}(w^t, D_k, E, \eta)$$


$$w^{t+1} = \sum_{k \in S_t} \frac{n_k}{\sum_{j \in S_t} n_j} w_k^{t+1}$$

Here, E is the number of local epochs and η is the local learning rate.

4. خوارزمية FedAvg

يرسل الخادم النموذج العام إلى مجموعة من العملاء، ويدرب كل عميل النموذج محليًا، ثم يعيد المعلومات المحدثة ليحسب الخادم متوسطًا موزونًا ويبدأ جولة جديدة.

5. One Communication Round



$$w_{k,e+1} = w_{k,e} - \eta \nabla F_k(w_{k,e})$$

More local epochs reduce communication frequency but can increase client drift when local data distributions differ strongly.

5. جولة اتصال واحدة

تتضمن الجولة اختيار العملاء وإرسال النموذج والتدريب المحلي ورفع التحديثات والدمج. تقلل زيادة التدريب المحلي عدد الرسائل لكنها قد تزيد اختلاف النماذج المحلية.

6. Non-IID Data

Smart-grid clients rarely have identically distributed data. One feeder may contain industrial loads, another residential PV, and another a fleet of EV chargers.

$$P_k(x, y) \neq P_j(x, y)$$

Feature shift

Different weather, voltage, load, or device ranges.

Label shift

Different event or fault frequencies.

Concept shift

Different relationship between measurements and targets.

A high global accuracy can hide poor performance for smaller or unusual clients.

6. البيانات غير المتجانسة

لا تتبع بيانات العملاء عادةً التوزيع نفسه. تختلف طبيعة الأحمال والطقس والأعطال والأجهزة، وقد يؤدي ذلك إلى بطء التقارب أو ضعف الأداء لدى بعض العملاء.

7. Client Drift and Stabilization

When clients perform several local steps on different objectives, their models move in different directions.

$$\|\nabla F_k(w) - \nabla F(w)\| > 0$$

Common mitigation approaches include fewer local epochs, smaller learning rates, proximal regularization, control variates, clustering, and personalized models.

$$F_k^{prox}(w) = F_k(w) + \frac{\mu}{2} \|w - w^t\|^2$$

7. انجراف العملاء وثبيت التدريب

تتحرك النماذج المحلية في اتجاهات مختلفة عندما تختلف البيانات. يمكن تقليل ذلك بتقليل العصور المحلية أو إضافة حد يقي النموذج المحلي قريبًا من النموذج العام.

8. System Heterogeneity

Clients differ in processor speed, memory, battery level, network quality, and availability. Slow or disconnected clients create the straggler problem.

Synchronous FL

The server waits for selected clients before aggregating.

Asynchronous FL

The server updates when client results arrive.

Partial participation

Only a fraction of clients join each round.

8. اختلاف الأنظمة والأجهزة

تختلف قدرة العملاء الحاسوبية وجودة الاتصال والتوافر. لذلك قد يستخدم النظام مشاركة جزئية أو تحديثًا غير متزامن بدل انتظار جميع الأجهزة.

9. Communication Efficiency

Communication often dominates the cost of federated learning.

$$C_{comm} \approx R \times M \times B$$

where **R** is the number of rounds, **M** the participating clients per round, and **B** the transmitted model size.

- Model quantization.
- Sparse updates.
- Periodic communication.
- Smaller models or knowledge distillation.
- Client selection based on channel and energy conditions.

9. كفاءة الاتصال

قد تكون كلفة الاتصال أكبر من كلفة الحساب. تُخفض باستخدام ضغط النموذج والتحديثات المتناثرة وتقليل عدد الجولات واختيار العملاء بكفاءة.

10. Privacy Is Not Automatic

Keeping raw data local improves privacy, but gradients and parameters may still reveal information through reconstruction, membership inference, or property inference.

Federated learning is a training architecture, not a complete privacy guarantee.

10. الخصوصية ليست تلقائية

عدم إرسال البيانات الخام لا يمنع جميع أشكال التسرب، فقد تكشف تحديثات النموذج معلومات عن العينات أو خصائص العملاء.

11. Secure Aggregation

Secure aggregation allows the server to learn only the sum of client updates, not each individual update.

Server obtains $\sum_k \Delta w_k$ but not individual Δw_k

Cryptographic masking and secret sharing can protect individual contributions, but increase protocol and dropout-handling complexity.

11. التجميع الآمن

يتيح التجميع الآمن للخادم معرفة مجموع التحديثات فقط دون الاطلاع على تحديث كل عميل منفردًا، باستخدام تقنيات تشفير وإخفاء مناسبة.

12. Differential Privacy

Differential privacy limits how much the output changes when one data record is added or removed.

$$\tilde{g} = \text{clip}(g, C) + \mathcal{N}(0, \sigma^2 C^2 I)$$

Gradients are clipped and noise is added. Stronger privacy generally reduces model utility.

$$P[M(D) \in S] \leq e^\epsilon P[M(D') \in S] + \delta$$

12. الخصوصية التفاضلية

تُحدّد التدرجات ثم تضاف ضوضاء محسوبة للحد من تأثير أي عينة واحدة. توجد مفاضلة بين مستوى الخصوصية ودقة النموذج.

13. Security Threats

Threat	Effect	Possible defense
Data poisoning	Corrupt local training data	Validation, reputation, robust training
Model poisoning	Malicious parameter updates	Clipping, robust aggregation, anomaly detection
Backdoor attack	Hidden malicious behavior on trigger inputs	Testing, pruning, update inspection
Sybil attack	One attacker controls many fake clients	Authentication and enrollment controls
Inference attack	Extract private information from updates	Secure aggregation and differential privacy

13. التهديدات الأمنية

تشمل تصميم البيانات والنموذج والأبواب الخلفية والعملاء الوهميين وهجمات الاستدلال. تتطلب الدفاعات مصادقة العملاء ودمجًا متينًا وفحصًا للتحديثات.

14. Robust Aggregation

Simple averaging is sensitive to extreme malicious updates. Robust alternatives include coordinate-wise median, trimmed mean, norm clipping, and similarity-based filtering.

$$w_j^{t+1} = \text{median}\{w_{1j}, w_{2j}, \dots, w_{Kj}\}$$

Robust aggregation can also reject legitimate but unusual clients, so security and fairness must be evaluated together.

14. الدمج المتين

قد يتأثر المتوسط البسيط بالتحديثات الخبيثة. يمكن استخدام الوسيط أو المتوسط المشذب أو قص معيار التحديث، مع الانتباه إلى عدم استبعاد العملاء المختلفين بصورة مشروعة.

15. Personalization

A single global model may not serve every feeder or device equally well. Personalized FL adapts part or all of the model to each client.

$$w_k^{personal} = \alpha w^{global} + (1 - \alpha) w_k^{local}$$

- Fine-tune the global model locally.
- Share common layers and keep a private output head.
- Cluster clients with similar behavior.
- Use meta-learning for fast adaptation.

15. تخصيص النماذج

قد لا يناسب نموذج عالمي واحد جميع العملاء. يمكن تخصيصه بالتدريب المحلي أو بمشاركة طبقات عامة والإبقاء على طبقات خاصة لكل عميل.

16. Smart-Grid Applications

Application	Client	Prediction task	Why FL?
Load forecasting	Home, building, feeder	Future demand	Consumption privacy
PV forecasting	Plant or inverter	Solar generation	Distributed weather and production data
EV charging	Vehicle or charging station	Arrival, demand, flexibility	Mobility and user privacy
Fault detection	Substation or relay	Event classification	Sensitive disturbance records
Asset health	Transformer or wind turbine	Failure risk and RUL	Cross-owner collaboration

16. تطبيقات الشبكات الذكية

تشمل التنبؤ بالأحمال والطاقة الشمسية وشحن المركبات وكشف الأعطال وصحة المعدات، خصوصًا عندما تكون البيانات حساسة وموزعة بين جهات مختلفة.

17. Worked Example

Three distribution operators train local linear load-forecast models using 1000, 2000, and 7000 samples.

$$n = [1000, 2000, 7000], \quad N = 10000$$

$$w^{t+1} = 0.1w_1^{t+1} + 0.2w_2^{t+1} + 0.7w_3^{t+1}$$

The third client receives the largest weight because it contributes most of the training samples. This does not necessarily guarantee fairness across operators.

17. مثال محلول

عند امتلاك ثلاثة مشغلين 1000 و 2000 و 7000 عينة، تصبح أوزان الدمج 0.1 و 0.2 و 0.7. لكن الوزن القائم على حجم البيانات لا يضمن العدالة بين العملاء.

18. Evaluation Metrics


- Global validation loss and accuracy.
- Per-client performance and worst-client performance.
- Rounds to target accuracy.
- Total transmitted bytes and energy use.
- Participation and dropout rates.
- Privacy budget and attack success rate.
- Robustness under malicious or unreliable clients.

$$\text{Worst-client metric} = \min_k \text{Performance}_k$$

18. مؤشرات التقييم

لا يكفي تقييم الدقة العامة، بل يجب فحص أداء كل عميل وأسوأ عميل وكلفة الاتصال والانسحاب والخصوصية والمتانة ضد الهجمات.

19. Deployment Workflow



1. Define the prediction task and operational risk.
2. Specify client identity, data boundaries, and governance.
3. Choose model, aggregation, and participation policy.
4. Add authentication, secure aggregation, and privacy controls.
5. Validate global and per-client performance.
6. Test dropouts, attacks, communication limits, and distribution shift.
7. Monitor models and retrain under controlled versioning.

19. خطوات النشر

يبدأ النشر بتحديد المهمة والجهات المشاركة وحدود البيانات، ثم اختيار النموذج وسياسة الدمج والحماية، وبعدها التحقق من الأداء ومراقبة الانحراف والهجمات والتحديثات.

20. Key Takeaways

- Federated learning enables collaborative training while keeping raw data local.

- FedAvg combines locally trained models using sample-based weights.
- Non-IID data and unequal client capabilities are central challenges.
- FL alone does not guarantee privacy or security.
- Secure aggregation, differential privacy, authentication, and robust aggregation address different risks.
- Smart-grid deployment must evaluate communication, fairness, robustness, governance, and operational safety.

20. الخلاصة

- يتيح التعلم الاتحادي تدريبًا تعاونيًا مع إبقاء البيانات الخام محليًا.
- تدمج FedAvg النماذج المحلية بأوزان تعتمد غالبًا على حجم البيانات.
- تعد البيانات غير المتجانسة واختلاف قدرات العملاء من أهم التحديات.
- لا يضمن التعلم الاتحادي الخصوصية أو الأمان تلقائيًا.
- يعالج كل من التجميع الآمن والخصوصية التفاضلية والدمج المتين خطرًا مختلفًا.

Review Questions

1. How does federated learning differ from centralized learning?
2. Derive the sample-weighted FedAvg update.
3. Why can many local epochs cause client drift?
4. What is non-IID data in a smart-grid context?
5. Why does federated learning not automatically guarantee privacy?
6. What is the difference between secure aggregation and differential privacy?
7. How can malicious clients influence the global model?
8. Why should worst-client performance be reported?

أسئلة المراجعة

1. ما الفرق بين التعلم الاتحادي والتعلم المركزي؟
2. اشتق تحديث FedAvg الموزون بعدد العينات.

3. لماذا تسبب العصور المحلية الكثيرة انجراف العملاء؟
4. ما معنى البيانات غير المتجانسة في الشبكات الذكية؟
5. لماذا لا يضمن التعلم الاتحادي الخصوصية تلقائيًا؟
6. ما الفرق بين التجميع الآمن والخصوصية التفاضلية؟
7. كيف يؤثر العميل الخبيث في النموذج العام؟
8. لماذا يجب إظهار أداء أسوأ عميل؟