

LECTURE 18 | المحاضرة 18

Federated Learning for Smart Grids

التعلم الاتحادي للشبكات الذكية

Collaborative AI without Centralizing Raw Operational Data

ذكاء اصطناعي تعاوني دون تجميع البيانات التشغيلية الخام

Motivation

FedAvg

Heterogeneity

Privacy

Robustness

Applications

Prepared by | إعداد | : Dr.-Ing. Aouss Gabash

Learning Objectives

- Compare centralized, local, and federated learning.
- Derive the Federated Averaging update.
- Explain client selection, local training, aggregation, and communication rounds.
- Understand non-IID data, client drift, and system heterogeneity.
- Distinguish privacy from security.
- Explain secure aggregation and differential privacy.
- Evaluate convergence, fairness, robustness, and deployment risk.
- Apply FL to smart meters, substations, EV fleets, and DERs.

أهداف التعلم


- المقارنة بين التعلم المركزي والمحلي والاتحادي.
- اشتقاق خوارزمية FedAvg.
- شرح اختيار العملاء والتدريب المحلي والدمج وجولات الاتصال.
- فهم البيانات غير المتجانسة وانجراف العملاء واختلاف الأجهزة.
- التمييز بين الخصوصية والأمان.
- شرح التجميع الآمن والخصوصية التفاضلية.

- تقييم التقارب والعدالة والمتانة ومخاطر النشر.
- تطبيق التعلم الاتحادي على العدادات والمحطات والمركبات والمصادر الموزعة.

1. Why Federated Learning?

Power-system data are distributed among utilities, substations, buildings, meters, microgrids, and EV fleets. Centralizing all raw data can be costly, restricted, sensitive, or undesirable.

Federated learning moves the model to the data instead of moving raw data to one central server.



1. لماذا التعلم الاتحادي؟

يسمح بتدريب نموذج مشترك مع إبقاء البيانات التشغيلية الخام محليًا وإرسال تحديثات النموذج فقط.

2. Centralized, Local, and Federated Learning

Approach	Data Location	Strength	Limitation
Centralized	One server	Simple global optimization	Privacy, bandwidth, ownership
Local	Each client	No data movement	Weak generalization
Federated	Raw data remain local	Collaborative learning	Communication and heterogeneity

2. التعلم المركزي والمحلي والاتحادي

يجمع التعلم المركزي البيانات، بينما يدرب المحلي نماذج منفصلة، ويجمع الاتحادي تحديثات النماذج دون نقل البيانات الخام.

3. Global Objective

$$\min_w F(w) = \sum_k = 1K(nk/N)Fk(w), N = \sum_k nk$$

The standard objective weights clients according to their number of local samples.

3. دالة الهدف العامة

تكتب دالة الهدف العامة كمجموع موزون لدوال الهدف المحلية، ويعتمد الوزن عادةً على عدد عينات كل عميل.

4. Federated Averaging

1. The server initializes a global model.
2. A subset of clients receives the model.
3. Each client performs local optimization.
4. Clients return updated parameters.
5. The server computes a weighted average.


$$w_{kt} + 1 = LocalTrain(w_t, D_k, E, \eta)$$

$$w_t + 1 = \sum_k \in Stnk / \sum_j \in Stnj \cdot w_{kt} + 1$$

4. خوارزمية FedAvg

يرسل الخادم النموذج إلى العملاء، يدرب كل عميل محليًا، ثم يدمج الخادم النماذج المحدثة بمتوسط موزون.

5. One Communication Round



$$w_{k,e+1} = w_{k,e} - \eta \nabla F_k(w_{k,e})$$

More local epochs reduce communication frequency but may increase client drift.

5. جولة اتصال واحدة

تتضمن اختيار العملاء وإرسال النموذج والتدريب المحلي ورفع التحديثات والدمج.

6. Non-IID Data

$$P_k(x, y) \neq P_j(x, y)$$

Feature Shift

Different load, voltage, weather, or device ranges.

Label Shift

Different fault or event frequencies.

Concept Shift

Different input-output relationships.

Temporal Shift

Changing operating conditions over time.

High global accuracy can hide poor performance for small or unusual clients.

6. البيانات غير المتجانسة

تختلف توزيعات الأحمال والطقس والأحداث بين العملاء، وقد يضعف ذلك التقارب والأداء المحلي.

7. Client Drift and FedProx

$$\|\nabla F_k(w) - \nabla F(w)\| > 0$$

$$Fkprox(w) = Fk(w) + (\mu/2)\|w - wt\|^2$$

The proximal term keeps local models closer to the current global model.

7. انجراف العملاء وFedProx

تتحرك النماذج المحلية باتجاهات مختلفة عندما تختلف البيانات، ويساعد الحد التقريبي على إبقائها قريبة من النموذج العام.

8. System Heterogeneity

Synchronous FL

The server waits for selected clients.

Asynchronous FL

The server updates as results arrive.

Partial Participation

Only some clients join each round.

Stragglers

Slow clients delay aggregation.

8. اختلاف الأنظمة والأجهزة

تختلف سرعة الأجهزة وجودة الاتصال والتوافر، لذلك قد نستخدم مشاركة جزئية أو تحديثًا غير متزامن.

9. Communication Efficiency

$$C_{comm} \approx R \times M \times B$$

R is the number of rounds, M the clients per round, and B the transmitted model size.

- Quantization and compression.
- Sparse updates.
- Periodic communication.
- Smaller models or distillation.
- Channel-aware client selection.

9. كفاءة الاتصال

تُخفض الكلفة عبر ضغط النموذج والتحديثات المتناثرة وتقليل الجولات واختيار العملاء بكفاءة.

10. Privacy Is Not Automatic

Keeping raw data local improves privacy, but gradients and parameters may still leak information through reconstruction or inference attacks.

Federated learning is a training architecture, not a complete privacy guarantee.

10. الخصوصية ليست تلقائية

قد تكشف تحديثات النموذج معلومات رغم بقاء البيانات الخام محليًا.

11. Secure Aggregation

Server obtains $\sum \Delta w_k$, not individual Δw_k

Cryptographic masking protects individual updates while allowing the server to compute their aggregate.

11. التجميع الآمن

يتعلم الخادم مجموع التحديثات دون الاطلاع على تحديث كل عميل منفردًا.

12. Differential Privacy

$$\Delta \tilde{w}_k = \text{clip}(\Delta w_k, C) + N(0, \sigma^2 C^2 I)$$

Clipping bounds each client's influence, and noise limits information leakage.

Stronger privacy usually reduces model accuracy and may slow convergence.

12. الخصوصية التفاضلية

نقص التحديثات إلى حد معين ثم نضيف ضوضاء محسوبة لتقليل إمكانية استنتاج معلومات حساسة.

13. Security and Poisoning

Data Poisoning

Malicious local training data.

Model Poisoning

Manipulated parameter updates.

Backdoors

Hidden trigger behavior.

Sybil Attacks

One attacker controls many clients.

$$wt + 1 = \text{RobustAggregate}(wkt + 1)$$

Defenses include clipping, anomaly detection, robust statistics, reputation, and trusted validation data.

13. الأمان وتسميم النموذج

قد يرسل عميل خبيث تحديثات مضللة، لذلك نستخدم كشف الشذوذ والتجميع المتين والتحقق.

14. Personalization and Fairness

One global model may not fit every feeder or customer group.

Fine-Tuning

Adapt the global model locally.

Clustered FL

Train separate models for similar clients.

Multi-Task FL

Learn related client-specific tasks.

Fair Aggregation

Protect small and difficult clients.

$$Fairnessgap = \max Metrick - \min Metrick$$

14. التخصيص والعدالة

قد نحتاج إلى ضبط محلي أو نماذج مجمعة حتى لا يخدم النموذج العام العملاء الكبار فقط.

15. Smart-Grid Applications

Smart Meters

Load forecasting and anomaly detection.

Substations

Fault and asset-health models.

EV Fleets

Charging demand and battery health.

Microgrids

Forecasting and energy management.

DERs

PV and storage prediction.

Utilities

Cross-organization collaborative learning.

15. تطبيقات الشبكات الذكية

تشمل التنبؤ بالحمل وكشف الشذوذ وصحة الأصول و شحن المركبات والطاقة المتجددة والتعاون بين المؤسسات.


16. Evaluation

- Global accuracy and per-client accuracy.
- Communication rounds and transmitted bytes.
- Convergence under non-IID data.
- Fairness across clients.
- Robustness to malicious or missing clients.
- Privacy budget and attack resistance.
- Energy and computational cost.

16. التقييم

نقيم الدقة العامة والمحلية وكلفة الاتصال والعدالة والمتانة والخصوصية والطاقة المستهلكة.

17. Engineering Workflow



1. Define client boundaries and data ownership.
2. Measure non-IID behavior and client resources.
3. Select FedAvg, FedProx, clustered, or personalized FL.
4. Design privacy and security controls.
5. Validate fairness, robustness, and communication cost.
6. Monitor drift and update participation policies.

17. سير العمل الهندسي

نحدد العملاء والبيانات، ثم نختار الخوارزمية ونصمم الحماية ونقيم العدالة والمتانة والكلفة.



Research Corner

Emerging directions: federated graph learning, split learning, vertical FL, privacy-preserving digital twins, energy-aware client scheduling, and robust cross-utility collaboration.

زاوية البحث العلمي

تشمل الاتجاهات الحديثة التعلم البياني الاتحادي والتعلم المقسم والتعلم الاتحادي العمودي والتوائم الرقمية المحافظة على الخصوصية.



Review Questions

1. How does FL differ from centralized learning?
2. Derive the FedAvg update.
3. Why does non-IID data cause client drift?
4. How does FedProx stabilize training?
5. Why is FL not automatically private?
6. What is secure aggregation?
7. How does differential privacy affect accuracy?
8. How should fairness and robustness be evaluated?

أسئلة المراجعة

1. كيف يختلف التعلم الاتحادي عن المركزي؟
2. اشتق تحديث FedAvg.
3. لماذا تسبب البيانات غير المتجانسة انجراف العملاء؟
4. كيف يثبت FedProx التدريب؟
5. لماذا لا يضمن FL الخصوصية تلقائيًا؟
6. ما التجميع الآمن؟
7. كيف تؤثر الخصوصية التفاضلية في الدقة؟
8. كيف نقيم العدالة والمتانة؟

References | المراجع

المراجع العامة المستخدمة في هذا المقرر

- [1] A. Gabash, *Flexible Optimal Operations of Energy Supply Networks with Renewable Energy Generation and Battery Storage*. Saarbrücken, Germany: Südwestdeutscher Verlag für Hochschulschriften, 2014.
- [2] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th Global ed. Harlow, U.K.: Pearson Education Limited, 2022.
- [3] A. Gabash, "Energy Market Transition and Climate Change: A Review of TSOs-DSOs C+++ Framework from 1800 to Present," *Energies*, vol. 16, no. 17, Art. no. 6139, 2023, doi: 10.3390/en16176139.
- [4] A. Gabash, *AI Applications in Electrical Power Systems*, Version 1.0, 2026. [Online]. Available: <https://aoussgabash.com>

Recommended citation:

Gabash, A. (2026). Federated Learning for Smart Grids. AI Applications in Electrical Power Systems, Lecture 18, Version 1.0. <https://aoussgabash.com>

المرجع المقترح:

أوس غباش، 2026، محاضرة 18، تطبيقات الذكاء الاصطناعي في أنظمة الطاقة الكهربائية، الإصدار 1.0، <https://aoussgabash.com>

© 2026 Dr.-Ing. Aouss Gabash. Educational use with attribution to the author and official website.