

AI Cybersecurity for Power Systems

الأمن السيبراني المدعوم بالذكاء الاصطناعي لأنظمة القدرة

Threat detection, false-data attacks, adversarial learning, and resilient operation

كشف التهديدات وهجمات البيانات الكاذبة والتعلم الخصومي والتشغيل المرن

د. م. أوس غباش | Prepared by | إعداد: Dr.-Ing. Aouss Gabash

Learning Objectives


- Explain the cyber-physical attack surface of modern power systems.
- Model false-data injection and measurement residuals.
- Design AI-based intrusion and anomaly detection systems.
- Evaluate classifiers using confusion matrices, precision, recall, F1, and ROC-AUC.
- Understand adversarial examples, poisoning, evasion, and model extraction.
- Explain zero-trust principles, resilient control, and secure AI deployment.

أهداف التعلم

- شرح سطح الهجوم السيبراني الفيزيائي في أنظمة القدرة الحديثة.
- نمذجة حقن البيانات الكاذبة وبواقي القياس.
- تصميم أنظمة كشف اختراق وشذوذ بالذكاء الاصطناعي.
- تقييم المصنفات باستخدام مصفوفة الالتباس والدقة والاستدعاء و F1 و ROC-AUC.
- فهم الأمثلة الخصومية والتسميم والمراوغة واستخراج النماذج.
- شرح الثقة الصفريّة والتحكم المرن والنشر الآمن للذكاء الاصطناعي.

1. Cyber-Physical Security

Modern grids combine physical assets, sensors, communication networks, control software, cloud services, and AI models. An attack on information can therefore create physical consequences.



1. الأمن السيبراني الفيزيائي

تربط الشبكات الحديثة المعدات الفيزيائية بالحساسات والاتصالات وأنظمة التحكم والذكاء الاصطناعي، لذلك قد يؤدي التلاعب بالمعلومات إلى أثر مادي مباشر.

2. Threat Landscape

Layer	Examples	Impact
Field devices	Compromised IED, relay, inverter	Wrong switching or control
Communication	Replay, spoofing, denial of service	Delayed or false data
Control center	Credential theft, malware	Unauthorized commands
AI pipeline	Poisoning, evasion, model theft	Wrong predictions or hidden backdoors

2. مشهد التهديدات

قد تستهدف الهجمات أجهزة الحقل أو شبكات الاتصال أو مركز التحكم أو بيانات ونماذج الذكاء الاصطناعي.

3. False-Data Injection Attack

$$z = h(x) + e$$

An attacker changes measurements by adding an attack vector:

$$z_a = z + a$$

In a linear state-estimation model $\mathbf{z}=\mathbf{H}\mathbf{x}+\mathbf{e}$, a stealthy attack may use:

$$a = Hc$$

Then the corrupted data are consistent with the shifted state $\mathbf{x}+\mathbf{c}$, which may bypass a simple residual detector.

3. هجوم حقن البيانات الكاذبة

يضيف المهاجم متجهًا إلى القياسات. وإذا اختير بما يتوافق مع نموذج القياس فقد يبدو التلاعب كأنه حالة صحيحة جديدة ويتجاوز كاشف البواقي البسيط.

4. Residual-Based Detection

$$r = z - h(\hat{x})$$

$$J = r^T R^{-1} r$$

An alarm is raised when J exceeds a threshold. This works well for random bad data but may fail against carefully structured attacks.

4. الكشف المعتمد على البواقي

تقارن بواقي القياس بحد إحصائي. تنجح الطريقة مع الأخطاء العشوائية، لكنها قد تفشل أمام هجمات مصممة باستخدام نموذج الشبكة.

5. AI-Based Intrusion Detection

Supervised

Train on labeled normal and attack examples.

Unsupervised

Learn normal structure and detect outliers.

Hybrid

Combine rules, physics, and machine learning.

Features may include voltage, current, frequency, phase angle, packet timing, command sequences, residuals, and topology information.

5. كشف الاختراق بالذكاء الاصطناعي

يمكن استخدام التعلم الموجّه أو غير الموجّه أو الهجين، مع ميزات كهربائية وشبكية وزمنية وتشغيلية.

6. Classification Metrics

$$Precision = \frac{TP}{TP + FP}, \quad Recall = \frac{TP}{TP + FN}$$

$$F1 = 2 \frac{Precision \cdot Recall}{Precision + Recall}$$

Accuracy alone is misleading when attacks are rare. Missing a critical attack can be more costly than a false alarm.

6. مؤشرات التصنيف

لا تكفي الدقة العامة عندما تكون الهجمات نادرة. يجب تقييم Precision و Recall و F1 وموازنة الإنذارات الكاذبة مع الهجمات الفائتة.

7. Time-Series and Sequence Models

Many attacks are visible only across time. Recurrent networks, temporal convolution, transformers, and change-point detectors can learn sequential patterns.

$$P(y_t \mid x_{t-L+1:t})$$

7. نماذج السلاسل الزمنية

تظهر بعض الهجمات من خلال التسلسل الزمني لا من عينة منفردة، لذلك تستخدم نماذج زمنية ونقاط تغير وتحليل نوافذ متتابعة.

8. Graph-Based Detection

The power grid is naturally a graph. Graph Neural Networks can combine measurements with network connectivity.

$$h_i^{(l+1)} = \sigma \left(W_0 h_i^{(l)} + \sum_{j \in \mathcal{N}_i} W_1 h_j^{(l)} \right)$$

Graph-based methods can detect spatially inconsistent measurements and localize suspicious buses or devices.

8. الكشف المعتمد على الرسم البياني

تستخدم الشبكات العصبية البيانية ترابط العقد والخطوط لاكتشاف القياسات غير المتسقة مكانيًا وتحديد موقع الخلل.

9. Adversarial Machine Learning

Attack	Stage	Goal
Poisoning	Training	Corrupt learned behavior
Backdoor	Training	Trigger hidden malicious behavior
Evasion	Inference	Make an attack appear normal
Model extraction	Inference/API	Copy model behavior

$$x_{adv} = x + \delta, \quad \|\delta\| \leq \epsilon$$

9. التعلم الآلي الخصومي

قد يهاجم الخصم بيانات التدريب أو يضيف بابًا خلفيًا أو يعدل المدخلات أثناء التشغيل أو يحاول نسخ النموذج.

10. Physics-Informed Defense

AI decisions can be checked against power-system laws and operational limits.

$$P_i^{inj} = \sum_j V_i V_j (G_{ij} \cos \theta_{ij} + B_{ij} \sin \theta_{ij})$$

A detection system is stronger when statistical evidence, cyber logs, and physical consistency agree.

10. الدفاع المعتمد على الفيزياء

تُفحص نتائج الذكاء الاصطناعي باستخدام معادلات تدفق القدرة وحدود الجهد والتيار والتوازن، بدل الاعتماد على المصنف وحده.

11. Zero-Trust Architecture

- Verify every user, device, service, and model request.
- Apply least privilege and network segmentation.
- Use strong identity, authentication, and device attestation.
- Continuously monitor behavior and revoke access when risk changes.
- Protect model files, data pipelines, APIs, and update channels.

11. بنية الثقة الصفرية

لا تفترض الثقة تلقائيًا لأي مستخدم أو جهاز، بل تتحقق باستمرار وتطبق أقل صلاحية وتقسيم الشبكة وحماية قنوات التحديث.

12. Resilient Control

Detection is not sufficient. The system must continue operating safely during communication loss or suspected compromise.


- Local fallback controllers.
- Redundant sensing and communication paths.

- Graceful degradation.
- Isolation of compromised zones.
- Human confirmation for high-impact actions.

12. التحكم المرن

يجب أن يستمر النظام بأمان أثناء الهجوم باستخدام متحكمات محلية ومسارات بديلة وعزل المناطق المشبوهة وتأكيد بشري للقرارات الحرجة.

13. Secure AI Lifecycle



1. Track data and model provenance.
2. Scan data for poisoning and leakage.
3. Test adversarial robustness and distribution shift.
4. Version and cryptographically sign models.
5. Monitor drift, attacks, and unexpected outputs.
6. Maintain rollback and incident-response procedures.

13. دورة حياة أمانة للذكاء الاصطناعي

تبدأ بمصادر بيانات موثوقة وتنتهي بالمراقبة والتراجع الآمن، مع تتبع الإصدارات واختبار الهجمات وتوقيع النماذج.

14. Worked Example

A detector observes 10,000 samples: 200 are attacks. It detects 170 attacks and raises 90 false alarms.

$$TP = 170, FN = 30, FP = 90, TN = 9710$$

$$Precision = 170/260 = 65.4\%$$

$$Recall = 170/200 = 85\%$$

The high recall is useful, but operators must manage the false-alarm burden.

14. مثال محلول

اكتشف النظام 170 هجوماً من أصل 200 وأصدر 90 إنذاراً كاذباً. يكون الاستدعاء 85%، لكن الدقة الإيجابية نحو 65.4%، ما يوضح أهمية تقييم عبء الإنذارات.

15. Key Takeaways

- Power-system cybersecurity is cyber-physical, not purely digital.
- Stealthy false-data attacks can defeat simple residual tests.
- AI improves detection but creates new adversarial risks.

- Physics, cyber telemetry, and learning models should be combined.
- Secure deployment requires zero trust, lifecycle controls, monitoring, and fallback operation.

15. الخلاصة

- أمن أنظمة القدرة سيبراني فيزيائي.
- قد تتجاوز هجمات البيانات المصممة كواشف البواقي البسيطة.
- يحسن الذكاء الاصطناعي الكشف لكنه يضيف مخاطر خصوصية.
- يجب دمج الفيزياء وسجلات الشبكة والتعلم الآلي.
- يتطلب النشر الآمن مراقبة وثقة صفرية وتشغيلًا احتياطيًا.



Review Questions

1. How can a cyberattack create physical grid consequences?
2. Why can an attack vector $a=Hc$ bypass a residual detector?
3. Why is accuracy insufficient for rare attacks?
4. How can GNNs support attack localization?
5. What is the difference between poisoning and evasion?
6. How does physics-informed detection improve trust?
7. What does zero trust mean in a control environment?

أسئلة المراجعة

1. كيف يؤدي الهجوم السيبراني إلى أثر فيزيائي؟
2. لماذا قد يتجاوز الهجوم $a=Hc$ كاشف البواقي؟
3. لماذا لا تكفي الدقة العامة للهجمات النادرة؟
4. كيف تساعد GNN في تحديد موقع الهجوم؟
5. ما الفرق بين التسميم والمراوغة؟
6. كيف يزيد التحقق الفيزيائي موثوقية الكشف؟

7. ما معنى الثقة الصفرية في بيئة التحكم؟