

LECTURE 19 | المحاضرة 19

AI Cybersecurity for Power Systems

الأمن السيبراني المدعوم بالذكاء الاصطناعي لأنظمة القدرة

Threat Detection, False-Data Attacks, Adversarial Learning, and Resilient Operation

كشف التهديدات وهجمات البيانات الكاذبة والتعلم الخصومي والتشغيل المرن

Threats

False Data

AI Detection

Adversarial ML

Resilience

Workflow

Prepared by | إعداد | Dr.-Ing. Aouss Gabash

Learning Objectives


- Explain the cyber-physical attack surface of modern grids.
- Model false-data injection and residual-based detection.
- Design AI-based intrusion and anomaly detection systems.
- Evaluate classifiers using precision, recall, F1, and ROC-AUC.
- Understand poisoning, evasion, backdoors, and model extraction.
- Apply zero-trust, resilient control, and secure AI lifecycle principles.
- Combine cyber evidence with physical constraints.

أهداف التعلم

- شرح سطح الهجوم السيبراني الفيزيائي في الشبكات الحديثة.
- نمذجة حقن البيانات الكاذبة والكشف بالبقايا.
- تصميم أنظمة كشف اختراق وشذوذ بالذكاء الاصطناعي.
- تقييم المصنفات باستخدام Precision و Recall و F1 و ROC-AUC.
- فهم التسميم والمراوغة والأبواب الخلفية واستخراج النماذج.
- تطبيق الثقة الصفيرية والتحكم المرن ودورة حياة أمانة للذكاء الاصطناعي.
- دمج الأدلة السيبرانية مع القيود الفيزيائية.

1. Cyber-Physical Security

Modern grids combine physical assets, sensors, communication networks, control software, cloud services, and AI models. An information attack can therefore create direct physical consequences.



Cybersecurity must protect both information integrity and safe physical operation.

1. الأمن السيبراني الفيزيائي

ترتبط المعدات بالحساسات والاتصالات وأنظمة التحكم والذكاء الاصطناعي، لذلك قد يؤدي التلاعب بالمعلومات إلى أثر مادي مباشر.

2. Threat Landscape

Layer	Examples	Impact
Field Devices	Compromised relay, IED, inverter	Wrong switching or control
Communication	Replay, spoofing, denial of service	Delayed or false data
Control Center	Malware, credential theft	Unauthorized commands
AI Pipeline	Poisoning, evasion, model theft	Wrong predictions or backdoors

2. مشهد التهديدات

قد تستهدف الهجمات أجهزة الحقل أو الاتصال أو مركز التحكم أو بيانات ونماذج الذكاء الاصطناعي.

3. False-Data Injection

$$z = h(x) + e$$

$$za = z + a$$

For a linear model $z=Hx+e$, a stealthy attack may choose:

$$a = Hc$$

The corrupted measurements are then consistent with the shifted state $x+c$ and may bypass a simple residual detector.

3. حقن البيانات الكاذبة

إذا اختير متجه الهجوم بما يتوافق مع نموذج القياس فقد يبدو التلاعب كأنه حالة صحيحة جديدة ويتجاوز كاشف البواقي البسيط.

4. Residual-Based Detection

$$r = z - h(\hat{x})$$

$$J = r^T R^{-1} r$$

An alarm is raised when J exceeds a threshold.

Residual tests are effective against random bad data but may fail against structured attacks designed with knowledge of the grid model.

4. الكشف المعتمد على البواقي

تُقارن البواقي بحد إحصائي، لكنها قد لا تكشف الهجمات المصممة باستخدام نموذج الشبكة.

5. AI-Based Intrusion Detection

Supervised

Train on labeled normal and attack data.

Unsupervised

Learn normal behavior and flag outliers.

Semi-Supervised

Use a small labeled set with large unlabeled data.

Hybrid

Combine rules, physics, and ML.

Useful features include voltage, current, frequency, phase angle, packet timing, command sequences, residuals, and topology.

5. كشف الاختراق بالذكاء الاصطناعي

يمكن الجمع بين التعلم الموجّه وغير الموجّه والقواعد والفيزياء باستخدام ميزات كهربائية وشبكية وزمنية.

6. Classification Metrics

$$Precision = TP / (TP + FP)$$

$$Recall = TP / (TP + FN)$$

$$F1 = 2 \cdot Precision \cdot Recall / (Precision + Recall)$$

Accuracy alone is misleading when attacks are rare. Missing a critical attack may be much more costly than a false alarm.

6. مؤشرات التصنيف

يجب تقييم الدقة والاستدعاء وF1، لأن الدقة العامة وحدها قد تخفي فشل كشف الهجمات النادرة.

7. Time-Series Detection

$$P(y_t | x_{t-L+1:t})$$

RNNs, temporal CNNs, transformers, and change-point methods detect attacks that emerge across time rather than in a single sample.

7. الكشف الزمني

تظهر بعض الهجمات من خلال تسلسل زمني، لذلك نستخدم نماذج تتعامل مع النوافذ المتتالية ونقاط التغير.

8. Graph-Based Detection

$$h_i(l+1) = \sigma(W_0 h_i(l) + \sum_{j \in N_i} W_1 h_j(l))$$

Graph neural networks use grid topology to detect spatially inconsistent measurements and localize suspicious buses or devices.

8. الكشف البياني

تستخدم الشبكات البيانية ترابط العقد والخطوط لاكتشاف القياسات غير المتسقة مكانياً وتحديد موقع الخلل.

9. Adversarial Machine Learning

Attack	Stage	Goal
Poisoning	Training	Corrupt learned behavior
Backdoor	Training	Trigger hidden malicious behavior
Evasion	Inference	Make an attack appear normal
Model Extraction	API/Inference	Copy model behavior

$$x_{adv} = x + \delta, \|\delta\| \leq \epsilon$$

9. التعلم الآلي الخصومي

قد يستهدف الخصم التدريب أو يضيف بابًا خلفيًا أو يعدل المدخلات أثناء التشغيل أو يحاول نسخ النموذج.

10. Physics-Informed Defense

$$P_{in,j} = \sum_j V_i V_j (G_{ij} \cos \theta_{ij} + B_{ij} \sin \theta_{ij})$$

Detection is stronger when statistical evidence, cyber logs, topology, and physical consistency agree.

10. الدفاع الموجّه بالفيزياء

تُفحص قرارات الذكاء الاصطناعي باستخدام معادلات تدفق القدرة وحدود الجهد والتيار والتوازن.

11. Zero-Trust Architecture

- Verify every user, device, service, and model request.
- Apply least privilege and network segmentation.
- Use strong authentication and device attestation.
- Continuously monitor behavior.
- Protect model files, APIs, data pipelines, and update channels.

11. بنية الثقة الصفريّة

لا تُمنح الثقة تلقائيًا لأي مستخدم أو جهاز، بل تُتحقق الهوية والصلاحيّة باستمرار.

12. Resilient Control

Detection alone is insufficient. The system must continue operating safely during communication loss or suspected compromise.

- Local fallback controllers.


- Redundant sensing and communication.
- Graceful degradation.
- Isolation of compromised zones.
- Human confirmation for high-impact actions.

A secure design must preserve safe operation, not merely raise alarms.

12. التحكم المرن

يجب أن يستمر النظام بأمان باستخدام متحكمات محلية ومسارات بديلة وعزل المناطق المشبوهة.

13. Secure AI Lifecycle



1. Track data and model provenance.
2. Scan data for poisoning and leakage.
3. Test adversarial robustness and distribution shift.
4. Version and sign deployed models.
5. Monitor drift and unexpected outputs.
6. Maintain rollback and incident-response procedures.

13. دورة حياة أمانة للذكاء الاصطناعي

تشمل مصادر موثوقة وتدريبًا آمنًا وتحققًا وتوقيعًا رقميًا ومراقبة وإمكان التراجع.

14. Data and Model Governance

Provenance

Know where data and models came from.

Versioning

Track every deployed release.

Access Control

Limit who can modify models and data.

Auditability

Log decisions and changes.

14. حوكمة البيانات والنماذج

تتطلب الحوكمة تتبع المصدر والإصدارات والصلاحيات وسجلات التعديل والقرارات.


15. Evaluation Under Attack

- Detection delay.
- False-alarm rate.
- Recall for critical attack classes.
- Robustness under distribution shift.
- Performance under missing sensors.
- Physical impact after failed detection.
- Recovery time and safe fallback behavior.

15. التقييم أثناء الهجوم

يجب قياس سرعة الكشف والإنذارات الكاذبة والمتانة والأثر الفيزيائي وزمن الاستعادة.

16. Engineering Workflow



1. Define assets, attackers, trust boundaries, and failure consequences.
2. Combine electrical, communication, and operational features.
3. Train and calibrate detection models.
4. Test poisoning, evasion, missing data, and topology changes.
5. Integrate safe fallback and incident response.
6. Monitor continuously and update securely.

16. سير العمل الهندسي

نحدد نموذج التهديد والبيانات، ثم ندرب الكاشف ونختبره خصومياً ونربطه بخطة تشغيل واستجابة آمنة.



Research Corner

Emerging directions: cyber-physical digital twins, graph-based attack localization, adversarially robust state estimation, explainable intrusion detection, secure federated learning, and autonomous incident response.

زاوية البحث العلمي

تشمل الاتجاهات الحديثة التوائم السيبرانية الفيزيائية والكشف البياني والتقدير المتين والتفسير والتعلم الاتحادي الآمن.



Review Questions

1. What is a cyber-physical attack surface?
2. How can a false-data attack bypass residual detection?
3. Why is accuracy insufficient for rare attacks?
4. How can graph models improve localization?
5. What is the difference between poisoning and evasion?
6. How does physics-informed defense improve detection?
7. What does zero trust mean?
8. How should an AI cybersecurity system be validated?

أسئلة المراجعة

1. ما سطح الهجوم السيبراني الفيزيائي؟
2. كيف يتجاوز هجوم البيانات الكاذبة كشف البواقي؟
3. لماذا لا تكفي الدقة العامة؟
4. كيف تحسن النماذج البيانية تحديد موقع الهجوم؟
5. ما الفرق بين التسميم والمراوغة؟
6. كيف يحسن الدفاع الموجه بالفيزياء الكشف؟
7. ما معنى الثقة الصفرية؟
8. كيف نتحقق من نظام أمن سيبراني قائم على الذكاء الاصطناعي؟

References | المراجع

المراجع العامة المستخدمة في هذا المقرر

- [1] A. Gabash, *Flexible Optimal Operations of Energy Supply Networks with Renewable Energy Generation and Battery Storage*. Saarbrücken, Germany: Südwestdeutscher Verlag für Hochschulschriften, 2014.
- [2] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th Global ed. Harlow, U.K.: Pearson Education Limited, 2022.
- [3] A. Gabash, "Energy Market Transition and Climate Change: A Review of TSOs-DSOs C++ Framework from 1800 to Present," *Energies*, vol. 16, no. 17, Art. no. 6139, 2023, doi: 10.3390/en16176139.
- [4] A. Gabash, *AI Applications in Electrical Power Systems*, Version 1.0, 2026. [Online]. Available: <https://aoussgabash.com>

Recommended citation:

Gabash, A. (2026). AI Cybersecurity for Power Systems. AI Applications in Electrical Power Systems, Lecture 19, Version 1.0. <https://aoussgabash.com>

المرجع المقترح:

أوس غباش، 2026، محاضرة 19، تطبيقات الذكاء الاصطناعي في أنظمة الطاقة الكهربائية، الإصدار 1.0، <https://aoussgabash.com>

© 2026 Dr.-Ing. Aouss Gabash. Educational use with attribution to the author and official website.